单位代码： 10293 密 级： _____

南京邮电大学

专 业 学 位 硕 士 论 文

论文题目：基于不确定性度量及探索增强模型的离线强化学习算法

学 号 1223045728

姓 名 刘哲闰

导 师 张伯雷

专业学位类别 人工智能

类 型 全日制

专业（领域） 计算机技术

论文提交日期 2026 年 6 月

Offline Reinforcement Learning with Adaptive Uncertainty Quantification and Exploration Enhancement

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of

Master of ENGINEERING

By

Zherun Liu

Supervisor: Prof. Bolei Zhang

June 2026

南京邮电大学学位论文原创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得南京邮电大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文及涉及相关资料若有不实，愿意承担一切相关的法律责任。

研究生学号：_____ 研究生签名：_____ 日期：_____

南京邮电大学学位论文使用授权声明

本人承诺所呈交的学位论文不涉及任何国家秘密，本人及导师为本论文的涉密责任并列第一责任人。

本人授权南京邮电大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档；允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索；可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文。本文电子文档的内容和纸质论文的内容相一致。论文的公布（包括刊登）授权南京邮电大学研究生院办理。

非国家秘密类涉密学位论文在解密后适用本授权书。

研究生签名：_____ 导师签名：_____ 日期：_____

摘要

离线强化学习通过从预先收集的静态数据集中学习策略，避免了在线交互的高昂成本与安全风险，在医疗诊断、自动驾驶、机器人控制等实际应用场景中具有重要价值。然而，离线数据集的有限覆盖范围导致的分布偏移问题是制约该技术发展的核心挑战：当策略访问离线数据未覆盖的状态-动作对时，价值函数的估计将产生外推误差，进而导致策略性能退化。本文围绕离线强化学习中的不确定性估计与探索策略展开系统研究，提出两种互补的算法方案。

第一，提出基于自适应不确定性度量的离线强化学习算法。针对现有基于模型方法仅考虑状态转移不确定性、采用静态惩罚系数的局限，引入累积状态不确定性度量和自适应动态权重机制。累积状态不确定性通过递推公式综合考虑历史不确定性的累积效应，使智能体能够更全面地评估决策风险；自适应动态权重机制基于 Sigmoid 函数动态调节惩罚强度，实现探索与保守的自适应平衡。理论分析证明累积不确定性的单调性和自适应权重的优越性。实验结果表明，该方法在 D4RL MuJoCo 基准测试集上显著优于 MOPO 等基线方法。

第二，提出基于定向探索模型的离线到在线强化学习算法。针对现有离线到在线方法不确定性利用不充分、在线交互成本高的问题，将不确定性信息从“惩罚信号”转变为“探索引导信号”。在离线阶段通过集成模型进行保守策略优化，在在线阶段显式引导策略探索高不确定性且高价值的区域。提出双重不确定性估计方法区分偶然不确定性和认知不确定性，设计动态权重自适应机制平滑过渡探索与利用。理论分析证明定向探索策略相比均匀采样具有更优的收敛速率。实验结果表明，该方法仅需 50k 步在线交互即可显著优于现有基线方法。

两种方法形成递进关系：第一种方法解决纯离线设定下的保守策略优化问题，第二种方法通过定向探索策略突破离线数据边界，使策略性能持续提升。

关键词：离线强化学习，不确定性估计，分布偏移，定向探索，离线到在线强化学习

Abstract

Offline reinforcement learning enables policy learning from pre-collected static datasets, avoiding the high costs and safety risks associated with online interactions. This paradigm holds significant practical value in domains such as medical diagnosis, autonomous driving, and robotic control. However, the distribution shift problem arising from the limited coverage of offline datasets remains a core challenge: when the learned policy visits state-action pairs not covered by the offline data, value function estimation produces extrapolation errors, leading to policy performance degradation. This thesis conducts a systematic study on uncertainty estimation and exploration strategies in offline reinforcement learning, proposing two complementary algorithmic approaches.

First, an offline reinforcement learning algorithm based on adaptive uncertainty measurement is proposed. To address the limitations of existing model-based methods that only consider state transition uncertainty and employ static penalty coefficients, this work introduces cumulative state uncertainty measurement and an adaptive dynamic weight mechanism. The cumulative state uncertainty comprehensively accounts for the accumulated effects of historical uncertainty through a recursive formula, enabling the agent to more thoroughly assess decision risks. The adaptive dynamic weight mechanism based on the Sigmoid function dynamically adjusts penalty strength, achieving an adaptive balance between exploration and conservatism. Theoretical analysis proves the monotonicity of cumulative uncertainty and the advantages of adaptive weights. Experimental results demonstrate that this method significantly outperforms baseline methods such as MOPO on the D4RL MuJoCo benchmark.

Second, an offline-to-online reinforcement learning algorithm based on directed exploration model is proposed. To address the insufficient utilization of uncertainty and high online interaction costs in existing offline-to-online methods, this work transforms uncertainty information from a ”penalty signal” to an ”exploration guidance signal”. During the offline phase, conservative policy optimization is performed through ensemble models; during the online phase, the policy is explicitly guided to explore regions with high uncertainty and high action value. A dual uncertainty estimation method is proposed to distinguish aleatoric and epistemic uncertainty, and a dynamic weight adaptation mechanism is designed to smoothly transition between exploration and exploitation. Theoretical analysis proves that the directed exploration strategy achieves better convergence rates compared to uniform sampling. Experimental results show that this method significantly outperforms existing baseline methods with only 50k steps of online interaction.

The two methods form a progressive relationship: the first addresses conservative policy op-

timization in pure offline settings, while the second breaks through the boundaries of offline data through directed exploration strategies, achieving continuous improvement in policy performance.

Key Words: Offline Reinforcement Learning, Uncertainty Estimation, Distribution Shift, Directed Exploration, Offline-to-Online Reinforcement Learning

目 录

摘要 I
Abstract II
插图索引 VI
表格索引 VII
第一章 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 3
1.3 研究内容与主要工作 4
1.4 文章结构安排 5
第二章 理论基础与相关工作 6
2.1 理论基础 6
2.1.1 马尔可夫决策过程 6
2.1.2 基于模型的离线强化学习框架 7
2.1.3 集成模型与不确定性估计 8
2.1.4 Soft Actor-Critic 算法 9
2.2 相关工作 10
2.2.1 无模型离线强化学习 11
2.2.2 基于模型的离线强化学习 12
2.2.3 离线到在线强化学习 13
2.3 本章小结 14
第三章 基于自适应不确定性度量的离线强化学习算法 15
3.1 问题分析与算法动机 15
3.2 算法框架 16
3.2.1 概率转移模型构建 16
3.2.2 基于不确定性惩罚的策略优化 17
3.3 累积状态不确定性度量 17
3.3.1 累积不确定性的形式化定义 18
3.3.2 不确定性预测网络 18
3.3.3 基于累积不确定性的奖励重塑 19
3.4 自适应动态权重机制 19
3.4.1 动态权重的动机 19
3.4.2 自适应权重的数学形式 20
3.5 理论分析 20
3.5.1 累积不确定性的性质 20
3.5.2 自适应权重的探索-保守平衡 22
3.6 算法流程 25
3.7 实验验证 26
3.7.1 实验设置 26
3.7.2 主实验结果 26
3.7.3 累积不确定性度量的有效性验证 27
3.7.4 消融实验 28

3.8 本章小结 29
第四章 基于定向探索模型的离线到在线强化学习算法 31
4.1 问题分析与算法动机 31
4.2 算法框架 32
4.2.1 离线预训练阶段 32
4.2.2 在线定向探索阶段 33
4.3 不确定性估计与动态权重自适应 35
4.3.1 双重不确定性估计 35
4.3.2 动态权重自适应机制 36
4.4 理论分析 37
4.4.1 定向探索的收敛速率分析 37
4.4.2 策略性能的单调改善保证 39
4.4.3 理论分析小结 41
4.5 算法流程 42
4.6 实验验证 43
4.6.1 实验设置 43
4.6.2 实验结果 43
4.6.3 模型覆盖范围的可视化验证 44
4.6.4 动态权重自适应的消融实验 45
4.7 本章小结 46
第五章 总结与展望 48
5.1 本文工作总结 48
5.2 进一步研究方向 49
参考文献 51
附录 B 攻读专业学位硕士期间撰写的论文 55
附录 C 攻读专业学位硕士期间申请的专利 56
附录 D 攻读专业学位硕士期间参加的科研项目 57
致谢 58

插图索引

图 3.1 基于自适应不确定性度量的离线强化学习算法框架。第一阶段基于离线数据集训练概率转移模型；第二阶段利用转移模型生成虚拟轨迹，同时计算累积状态不确定性和状态转移不确定性，通过自适应权重进行奖励重塑，最终基于 SAC 算法优化策略。 16
图 3.2 不同推演步数状态的不确定性分布。横轴为智能体在环境模型中的推演步数，纵轴为累积不确定性 $u_\phi(s)$。$t = 0$ 为离线数据集中的真实状态，$t \geq 1$ 为模型生成的状态。箱体表示四分位距，中线表示中位数。 28
图 4.1 定向探索的动机示意图。虚线区域表示阻塞区域，星形为目标位置；阴影区域表示转移模型的数据分布覆盖范围，非阴影区域为高不确定性区域。接近目标状态的区域具有更高的动作价值。定向探索策略引导智能体向高不确定性且高动作价值的区域探索。 32
图 4.2 在线阶段的定向探索示意图。虚线椭圆表示不同迭代中转移模型的覆盖范围，椭圆外的区域为高不确定性的分布外区域。橙色区域表示高动作价值区域。定向探索的目标是采集位于橙色区域内但椭圆外的样本，即同时具有高不确定性和高动作价值的样本。 34
图 4.3 模型预测状态与离线数据的对比。将模型预测状态和离线状态数据密度在三种不同离线数据集上进行可视化。散点表示模型的数据分布，预测 Q 值经归一化后作为散点的颜色。 45

表格索引

表 3.1 D4RL MuJoCo 任务上的性能对比（归一化分数） 27
表 3.2 消融实验结果（归一化分数） 29
表 4.1 D4RL 基准测试集上的性能对比 44
表 4.2 动态权重自适应的消融实验结果 45

第一章 绪论

1.1 研究背景与意义

强化学习（Reinforcement Learning, RL）是一种实现机器自主决策的人工智能范式，智能体通过与环境的持续交互学习最优策略，以最大化长期累积回报[1]。自深度强化学习在围棋[2]等领域取得突破以来，学术界与工业界持续将其应用拓展至更复杂的真实场景。近年来，强化学习在机器人控制[3]领域积累了丰富经验，并随着 DeepSeek-R1[4]在推理任务中的成功应用，开始广泛用于大语言模型的对齐与微调。强化学习的核心优势在于其端到端的优化能力：智能体无需人工设计特征或规则，仅通过与环境的交互即可自动发现最优行为模式，这使其在规则复杂或难以显式建模的任务中表现出独特优势。

在线强化学习框架中，智能体直接与环境交互，通过试错优化行为策略。该方法具备良好的适应性，能够根据环境反馈及时调整策略，但需要大量交互样本。以 Atari 游戏为例，DQN 算法需要约 2 亿帧游戏画面才能达到人类水平的性能，这种样本需求在真实物理环境中难以满足。在医疗诊断[5]、自动驾驶[6]等数据采集成本高昂或存在安全约束的场景中，频繁的在线试错既不经济也存在风险，限制了在线强化学习的实际部署。例如，在自动驾驶场景中，每次策略更新都需要真实车辆在道路上行驶，不仅成本高昂，还可能造成交通事故；在医疗决策场景中，尝试次优的治疗方案可能危及患者生命。

离线强化学习（Offline Reinforcement Learning）提供了一种替代方案：从预先收集的静态数据集中学习策略，避免在线交互的成本与风险。该范式依赖行为策略采集的历史数据，训练开销较小，且可以充分利用已有的大规模数据资源。在实际应用中，许多领域已积累了海量的决策数据：医院保存了大量的诊疗记录，自动驾驶公司收集了数百万公里的驾驶日志，金融机构记录了多年的交易历史。离线强化学习为这些数据的价值挖掘提供了理论框架。然而，行为策略通常是次优的，且存在分布偏移问题[7]——训练数据分布与目标策略访问的状态-动作分布存在差异，导致价值函数对分布外动作的估计不准确。由于离线学习无法获得环境反馈修正估计误差，累积误差会引发对分布外动作价值的过高估计，产生外推误差[8]，最终导致策略性能显著低于预期。如何从有限且可能存在偏差的数据中学习泛化能力良好的策略，是离线强化学习的核心挑战。

离线到在线强化学习（Offline-to-Online Reinforcement Learning）结合了两种范式的优势：先在离线数据上预训练策略，再通过有限的在线交互进行微调，既利用了历史数据降低样本需求，又通过在线反馈提升策略性能。这种两阶段范式在实际应用中具有重要意义：在自动驾驶场景中，可以先利用大量模拟器数据和历史驾驶记录进行预训练，再通过少量真实道路测试进行微调；在机器人控制场景中，可以先在仿真环境中学习基础技能，再在真实环境中

适配物理参数的差异。然而，离线到在线强化学习面临独特的技术挑战：离线阶段训练的策略可能过于保守，难以在在线阶段快速适应新数据；在线微调过程中又可能遗忘离线阶段学习的知识，导致性能骤降。

当前离线到在线方法多采用无模型框架，侧重于离线与在线数据的融合策略，如平衡重放、优先级采样等。无模型方法的样本效率受限，难以充分挖掘大规模离线数据集的价值，且通常需要大量在线交互（200k 步以上）才能实现有效微调。相比之下，基于模型的方法通过学习环境动力学模型生成虚拟样本，具有更高的样本效率：一旦学习到准确的转移模型，策略可通过与模型的虚拟交互进行优化，显著减少对真实环境的访问需求。集成动力学模型[9]的引入进一步提升了方法的可靠性，多模型的平均预测可降低单一模型的偏差，模型间预测的分歧度则可作为不确定性的自然度量。

不确定性量化在这一过程中发挥核心作用。强化学习中的不确定性可分为两类[10]：偶然不确定性源于环境固有的随机性，反映状态转移过程本身的内在噪声，无法通过增加数据量消除；认知不确定性源于模型对环境知识的缺乏，反映训练数据覆盖不足导致的模型不确定性，可通过收集更多数据逐步降低。在离线设定下，不确定性通常被视为需要规避的风险：高不确定性区域对应模型预测不可靠的状态-动作空间，策略应避免访问这些区域以防止分布偏移。然而，现有方法仅考虑单步状态转移的不确定性，忽视了强化学习作为序列决策过程的本质特征——不确定性会随轨迹累积传播，即使每一步的转移不确定性较低，多步累积后仍可能导致状态远离离线数据的覆盖范围。此外，现有方法采用静态的不确定性惩罚系数，难以适应策略优化不同阶段的动态需求：在训练初期，智能体需要充分探索以收集多样化经验；在训练后期，智能体应更加保守以确保策略的稳健性。

在离线到在线设定下，不确定性的角色发生根本性转变。认知不确定性不再仅仅是需要规避的风险，更是指明最需要补充数据以提升模型泛化能力的目标区域。高不确定性区域恰恰对应转移模型覆盖不足的状态-动作空间，在这些区域采集的样本对模型改进的贡献最大。这一认识揭示了一种新的方法论：在离线阶段利用不确定性保持策略保守性，避免对分布外区域的过估计；在在线阶段将不确定性转化为探索引导信号，主动探索高不确定性且高价值的区域，以最少的在线交互实现高效微调。本文基于这一核心思想，研究基于不确定性探索模型的离线到在线强化学习算法。在离线阶段，引入累积状态不确定性度量，综合考虑从初始状态到当前状态的历史不确定性累积效应，设计自适应动态权重机制根据策略优化进程调节惩罚强度；在在线阶段，将不确定性从“惩罚信号”转变为“探索引导信号”，显式引导策略探索高不确定性且高动作价值的区域。基于模型的框架通过虚拟数据生成降低在线交互成本，不确定性引导的探索策略提升了在线微调的样本效率。

1.2 国内外研究现状

强化学习在决策优化领域的应用日趋成熟，学术界与工业界均取得了阶段性进展。在大语言模型领域，DeepSeek 发布的 R1 系列模型[4] 通过纯强化学习范式激发模型的复杂推理能力，在数学推理和代码生成任务上达到了与 OpenAI o1 系列模型可比的性能，验证了强化学习在语言模型对齐中的有效性；ByteDance 等团队提出的 DAPO 算法[11] 开源了大规模语言模型强化学习训练系统，为学术界提供了重要的研究基础设施。在具身智能领域，Google DeepMind 研发的 RT-2 模型[12] 将视觉-语言预训练知识迁移至机器人控制，提升了机器人在真实环境中的语义理解与操作泛化能力。在离线强化学习理论研究方面，王雪松等[13] 系统梳理了基于表征学习的离线强化学习方法，分析了特征解耦对策略迁移能力的增强作用；UC Berkeley 的 Levine 团队持续推动离线强化学习的理论与应用研究，建立了 D4RL 等标准评测平台，为该领域的发展奠定了重要基础。

在离线强化学习方法研究方面，当前主流方法可分为无模型方法和基于模型方法两大类。无模型方法直接从离线数据中学习价值函数或策略，代表性工作包括 CQL[14]、IQL[15]、TD3+BC[16] 等。CQL 通过在 Q 函数中引入保守性正则项，学习 Q 值的下界估计，有效抑制了分布外动作的过估计；IQL 采用期望回归技术隐式学习最优 Q 值，完全避免对分布外动作的查询；TD3+BC 则发现简洁的行为克隆正则项即可实现有效的策略约束。基于模型的方法首先学习环境转移模型，再通过与模型交互优化策略，代表性工作包括 MOPO[17]、MOReL[18]、COMBO[19] 等。MOPO 通过集成模型估计不确定性并进行奖励惩罚，在保持保守性的同时提升了样本效率；MOReL 构建悲观 MDP 将高不确定性区域标记为终止状态；COMBO 将模型数据与 CQL 结合，兼顾数据效率与保守性。不确定性估计是基于模型方法的核心技术支撑。早期工作如 PETS[20] 提出使用概率集成模型，既可通过集成降低单一模型的偏差，又可利用模型间预测的分歧度量化认知不确定性，为模型基础强化学习的不确定性处理奠定了范式基础。MBPO[21] 在此基础上将模型生成数据与无模型方法结合，实现了更高效的在线强化学习。近年来，世界模型[22] 和 Dreamer 系列[23,24] 在潜在空间学习环境动力学并实现想象力规划，进一步拓展了基于模型方法的应用边界。然而，这些方法在不确定性利用方面仍存在局限：其一，仅考虑状态转移的即时不确定性，忽视了序列决策过程中不确定性的累积传播效应——即使每一步转移的不确定性可控，多步推演后的累积误差仍可能导致策略进入分布外区域；其二，采用静态的不确定性惩罚系数，难以在策略优化的不同阶段取得探索与保守的最优平衡。

上述进展表明强化学习在大模型对齐、具身智能、复杂场景适配等方向取得了实质性成果，但也对离线到在线强化学习技术提出了更高要求。当前该领域仍面临若干技术挑战：第一，分布偏移与性能衰减问题。离线阶段基于静态数据集训练的策略在在线环境中因分布差异易产生性能衰减，在线微调过程中又可能丢失离线阶段的知识。AWAC[25]、Cal-QL[26] 等方法通过动态策略调整、重要性加权等机制平衡两者，但需对具体任务的数据分布特性进行分

析并设计相应回放机制。第二，探索-利用权衡的两阶段矛盾。探索-利用权衡是强化学习的固有难题，离线到在线的两阶段模式进一步放大了这一矛盾——离线阶段需保持策略保守性以规避数据偏差风险，在线阶段又需探索未知区域以适配环境变化，两阶段对探索强度的需求相反。RT-2 模型虽提升了泛化能力，但未形成适配两阶段特性的动态探索机制；现有离线到在线方法主要关注保守性的平滑过渡，未能充分利用不确定性信息引导探索。第三，数据利用效率问题。离线数据集的知识常未被充分利用，策略在微调阶段易丢失预训练知识；在线交互虽能获取环境反馈，但频繁访问环境会削弱离线学习低成本的优势。多数现有方法需要 200k 步以上的在线交互才能实现有效微调，如何在提升数据利用率的同时控制在线开销，是该领域亟待解决的问题。

上述挑战推动了基于不确定性探索等技术方案的研究，也是本文的研究出发点。本文的核心思想可概括为：充分挖掘不确定性信息的双重价值。在离线阶段，引入累积状态不确定性度量，通过递推公式综合考虑从初始状态到当前状态的历史不确定性累积效应，使智能体能够更全面地评估决策风险；同时设计基于 Sigmoid 函数的自适应动态权重机制，根据策略优化进程动态调节惩罚强度，在训练初期降低惩罚以鼓励探索，在策略收敛时增加惩罚以提升保守性。在在线阶段，将不确定性的角色从“惩罚信号”转变为“探索引导信号”：区分偶然不确定性和认知不确定性的不同作用，通过双重不确定性估计识别模型覆盖不足的高价值区域，主动引导策略探索这些区域以补充转移模型的训练数据，实现策略性能的持续提升。这种从“被动规避不确定性”到“主动利用不确定性”的转变，构成了从离线保守优化到在线高效微调的完整技术闭环。

1.3 研究内容与主要工作

针对离线强化学习中分布偏移问题和离线到在线强化学习中探索效率问题，本文开展了系统性研究，主要工作包括以下两个方面：

第一，提出基于自适应不确定性度量的离线强化学习算法。针对现有基于模型的离线强化学习方法仅考虑状态转移不确定性、采用静态惩罚系数的局限，本文引入累积状态不确定性度量和自适应动态权重机制。累积状态不确定性通过递推公式综合考虑从初始状态到当前状态的历史不确定性累积效应，使智能体能够更全面地评估决策风险，避免进入分布外区域；自适应动态权重机制基于 Sigmoid 函数根据策略优化进程动态调节不确定性惩罚强度，在训练初期降低惩罚以鼓励探索，在策略逐渐收敛时增加惩罚以提升保守性。理论分析证明累积不确定性具有单调性和泛化性，自适应权重相比固定权重可在探索与保守之间取得更好的平衡。实验结果表明，该方法在 D4RL MuJoCo 任务上显著优于 MOPO 等基线方法。

第二，提出基于定向探索模型的离线到在线强化学习算法。针对现有离线到在线方法保守性与灵活性矛盾、不确定性利用不充分、在线交互成本高的问题，本文将不确定性信息从”

惩罚信号”转变为”探索引导信号”。在离线阶段，通过集成模型和不确定性惩罚进行保守策略优化；在在线阶段，显式引导策略探索高不确定性且高动作价值的区域，以最少的在线交互实现高效微调。提出双重不确定性估计方法区分偶然不确定性和认知不确定性，设计动态权重自适应机制平滑过渡探索与利用。理论分析证明定向探索策略相比均匀采样具有更优的收敛速率。实验结果表明，该方法仅需 50k 步在线交互即可在 D4RL 基准测试集上显著优于 MOPO 等基线方法。

两种方法形成递进关系：第一种解决纯离线设定下的保守策略优化问题，通过更精细的不确定性度量和动态的惩罚调节提升算法性能，但策略性能上限仍受限于离线数据的覆盖范围；第二种引入在线微调阶段，将“被动惩罚分布外”转变为“主动探索分布外”，通过定向探索突破离线数据边界。

1.4 文章结构安排

本文共分为五章，各章内容安排如下：

第一章为绪论，介绍研究背景与意义，阐述离线强化学习的核心挑战，综述国内外研究现状，明确研究内容与主要工作。

第二章为理论基础与相关工作，首先介绍马尔可夫决策过程、基于模型的离线强化学习框架、集成模型与不确定性估计等理论基础，随后系统综述无模型离线强化学习、基于模型的离线强化学习、离线到在线强化学习的相关工作，分析现有方法的优势与局限。

第三章为基于自适应不确定性度量的离线强化学习算法，详细介绍累积状态不确定性度量和自适应动态权重机制的设计思想，阐述累积不确定性的形式化定义和递推更新公式，设计自适应权重机制，给出理论分析并通过实验验证算法有效性。

第四章为基于定向探索模型的离线到在线强化学习算法，详细介绍两阶段算法框架，阐述双重不确定性估计方法和动态权重自适应机制，给出定向探索策略的理论分析，通过在 D4RL 基准测试集上的实验验证算法有效性。

第五章为总结与展望，总结本文的主要研究成果与创新点，分析现有方法的局限性，展望未来研究方向。

第二章 理论基础与相关工作

本章首先介绍强化学习的理论基础，建立本文所需的数学框架，包括马尔可夫决策过程、基于模型的离线强化学习框架、集成模型与不确定性估计、Soft Actor-Critic 算法等核心概念；随后对离线强化学习、离线到在线强化学习领域的相关工作进行系统综述，分析现有方法的发展脉络、核心优势与局限，阐明本文研究动机。

2.1 理论基础

2.1.1 马尔可夫决策过程

强化学习问题通常建模为马尔可夫决策过程（Markov Decision Process, MDP）[27]。MDP 由六元组 $M = (\mathcal{S}, \mathcal{A}, T, r, \mu_0, \gamma)$ 定义，其中 $\mathcal{S}$ 表示状态空间，包含智能体可能处于的所有状态；$\mathcal{A}$ 表示动作空间，包含智能体可执行的所有动作；$r : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$ 为奖励函数，量化状态-动作对的即时收益；$T(s'|s, a)$ 为状态转移概率函数，定义在状态 s 执行动作 a 后转移至状态 s' 的条件概率；μ_0 为初始状态分布；$\gamma \in (0, 1)$ 为折扣因子，用于调节即时奖励与未来奖励的相对权重。

在 MDP 框架中，智能体的行为由策略 $\pi(a|s)$ 刻画，表示在状态 s 下选择动作 a 的条件概率分布。强化学习的核心任务是寻找最优策略，为此需要定义价值函数以量化策略的长期累积收益。

状态价值函数 $V_M^\pi(s)$ 定义为在 MDP M 中，从状态 s 出发并遵循策略 π 所能获得的期望折扣回报：

$$V_M^\pi(s) = \mathbb{E}_{\pi,M}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s\right], \tag{2.1}$$

其中 s_t 和 a_t 分别表示时刻 t 的状态和动作，期望在策略 π 和环境动力学 M 下计算。状态价值函数衡量的是智能体处于特定状态时的长期预期收益。

动作价值函数 $Q_M^\pi(s, a)$ 定义为在状态 s 执行动作 a 后，继续遵循策略 π 所能获得的期望折扣回报：

$$Q_M^\pi(s, a) = \mathbb{E}_{\pi,M}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a\right], \tag{2.2}$$

动作价值函数衡量的是在特定状态下执行特定动作的长期预期收益。

状态价值函数与动作价值函数之间存在如下关系：

$$V_M^\pi(s) = \mathbb{E}_{a\sim\pi(\cdot|s)}[Q_M^\pi(s, a)] = \sum_{a\in\mathcal{A}} \pi(a|s) Q_M^\pi(s, a), \tag{2.3}$$

即状态价值等于该状态下所有动作价值在策略分布下的期望。反之，动作价值函数可通过贝尔曼期望方程表示为：

$$Q_M^\pi(s,a) = r(s,a) + \gamma \mathbb{E}_{s' \sim T(\cdot|s,a)}[V_M^\pi(s')], \tag{2.4}$$

即当前奖励与后继状态价值折扣期望之和。

为分析策略在状态-动作空间上的访问行为，引入折扣状态-动作访问分布 $\rho_M^\pi(s,a)$，定义为策略 π 在 MDP M 中访问状态-动作对 (s,a) 的非归一化折扣频率：

$$\rho_M^\pi(s,a) = \pi(a|s) \sum_{t=0}^{\infty} \gamma^t P(s_t = s|\pi, M), \tag{2.5}$$

其中 $P(s_t = s|\pi, M)$ 表示从初始分布 μ_0 出发，遵循策略 π 于时刻 t 到达状态 s 的概率。该分布刻画了策略的状态-动作空间覆盖特性：$\rho_M^\pi(s,a)$ 值较大的区域对应策略频繁访问的区域，反之则对应策略较少探索的区域。

基于上述定义，策略的期望折扣回报 η_M^π 作为评估策略整体性能的核心指标，可通过以下三种等价形式表示：

$$\eta_M^\pi = \mathbb{E}_{s_0 \sim \mu_0}[V_M^\pi(s_0)] = \mathbb{E}_{s_0 \sim \mu_0, a_0 \sim \pi(\cdot|s_0)}[Q_M^\pi(s_0,a_0)] = \mathbb{E}_{(s,a) \sim \rho_M^\pi}[r(s,a)]. \tag{2.6}$$

第一种形式从初始状态价值的角度表述期望回报；第二种形式从初始状态-动作价值的角度表述，便于与基于 Q 函数的算法衔接；第三种形式从访问分布的角度表述，将期望回报理解为策略访问的所有状态-动作对上奖励的加权平均。MDP 的优化目标是求解最大化期望折扣回报的最优策略 $\pi^* = \arg\max_\pi \eta_M^\pi$。

归一化状态-动作访问分布定义为 $\tilde{\rho}_M^\pi(s,a) = (1-\gamma) \cdot \rho_M^\pi(s,a)$，满足 $\sum_{s,a} \tilde{\rho}_M^\pi(s,a) = 1$，构成状态-动作空间上的概率分布。在离线强化学习中，训练数据的分布 ρ_D 与目标策略的访问分布 ρ_M^π 之间的差异构成分布偏移问题的根源：当目标策略访问的状态-动作对在训练数据中覆盖不足时，价值函数的估计将产生显著偏差。

2.1.2 基于模型的离线强化学习框架

在离线强化学习场景中，智能体仅能访问由行为策略 π_D 预先采集的静态数据集 $\mathcal{D}_{off} = \{(s_i, a_i, s_i', r_i)\}_{i=1}^N$，无法与真实环境进行在线交互。基于模型的离线强化学习方法通过监督学习从离线数据中构建环境转移模型 $\hat{T}_\theta(s', r|s,a)$，该模型以当前状态 s 和动作 a 为输入，预测下一状态 s' 及即时奖励 r 的联合分布。相比无模型方法直接学习价值函数或策略，基于模型的方法具有更高的样本效率：一旦学习到准确的环境模型，策略可通过与模型的虚拟交互进行优化，而无需访问真实环境。

转移模型通常采用参数化高斯分布进行建模：

$$\hat{T}_\theta(s', r|s, a) = \mathcal{N}(\mu_\theta(s, a), \Sigma_\theta(s, a)), \tag{2.7}$$

其中 $\mu_\theta(s, a)$ 为条件均值函数，$\Sigma_\theta(s, a)$ 为条件协方差矩阵，均由参数为 θ 的神经网络拟合。采用高斯分布建模的优势在于：均值参数可刻画状态转移的确定性成分，协方差参数可刻画转移的随机性成分，同时输出概率分布便于后续的不确定性量化。在实际应用中，为简化计算和保证数值稳定性，通常采用对角协方差矩阵，即假设各维度的预测误差相互独立。

模型参数通过最大化离线数据的对数似然进行优化：

$$\mathcal{L}(\theta) = -\mathbb{E}_{(s,a,s',r)\sim\mathcal{D}_{off}}[\log \hat{T}_\theta(s', r|s, a)]. \tag{2.8}$$

展开高斯分布的对数似然，训练损失等价于加权的均方误差与对数方差之和，其中均方误差项驱动模型学习状态转移的确定性规律，对数方差项约束模型输出合理的不确定性估计。这种概率建模方式使得模型不仅能预测转移的期望值，还能量化预测的置信度。

完成模型学习后，策略可通过与学习得到的转移模型交互生成虚拟轨迹进行优化，无需访问真实环境。具体而言，从离线数据集中采样初始状态，利用当前策略与转移模型进行短期推演（rollout），生成虚拟轨迹数据。这些虚拟数据可用于训练价值函数或直接优化策略，从而实现无需环境交互的策略改进。这一特性使基于模型的方法具有更高的样本效率，尤其适用于数据采集成本高昂的实际应用场景。

然而，学习得到的转移模型与真实环境之间不可避免地存在模型误差。模型误差可分解为两个来源：偏差（Bias）和方差（Variance）。偏差源于模型类（如神经网络）的表达能力限制，可能无法精确拟合真实环境的复杂动力学；方差源于有限训练数据导致的参数估计不确定性，在数据稀疏的区域尤为显著。当策略访问离线数据覆盖不足的状态-动作区域时，模型预测的可靠性下降，外推误差将随模型推演步数累积放大。设单步模型误差为 ϵ_m，推演 H 步后的累积误差约为 $O(H \cdot \epsilon_m)$，在长时间范围任务中可能导致严重的策略性能退化。因此，如何量化并控制模型不确定性、抑制分布外区域的过估计，是基于模型离线强化学习的核心挑战。

2.1.3 集成模型与不确定性估计

集成方法（Ensemble Methods）通过训练多个独立初始化的模型，利用模型间预测的分歧度量化不确定性[9]。设集成包含 N 个模型 $\{f_\phi^1, \ldots, f_\phi^N\}$，每个模型在相同数据集上独立训练但采用不同的随机初始化，则预测不确定性可通过集成预测的统计特性进行估计。

强化学习中的不确定性可从来源角度分为两类[10]。认知不确定性（Epistemic Uncertainty）

源于模型对环境知识的缺乏，反映训练数据覆盖不足导致的模型不确定性，可通过收集更多数据逐步降低。偶然不确定性（Aleatoric Uncertainty）源于环境固有的随机性，反映状态转移过程本身的内在噪声，无法通过增加数据量消除。

对于离线到在线强化学习，认知不确定性具有特殊重要性：高认知不确定性区域对应离线数据覆盖不足的状态-动作空间，恰恰是在线探索应优先关注的目标区域。通过识别并引导策略探索这些高不确定性区域，可有效补充转移模型的训练数据，提升模型在全状态-动作空间的泛化能力。

在基于模型的强化学习中,集成动力学模型的每个成员 $\hat{T}_\phi^i$ 输出高斯分布 $\mathcal{N}(\mu_\phi^i(s,a),\Sigma_\phi^i(s,a))$。其中，单个模型的预测方差 $\Sigma_\phi^i(s,a)$ 反映偶然不确定性，刻画环境动力学的内在随机性。为捕捉认知不确定性，可利用集成模型均值预测的分歧度定义如下度量：

$$\text{DisVar}(s,a)=\frac{1}{d}\sum_{j=1}^{d}\text{Var}_{i=1,\dots,N}[\mu_{\phi,j}^i(s,a)], \tag{2.9}$$

其中 d 为预测向量的维度，$\mu_{\phi,j}^i(s,a)$ 表示第 i 个模型预测均值的第 j 个分量，$\text{Var}_{i=1,\dots,N}[\cdot]$ 表示在 N 个集成成员间计算方差。该度量的核心思想是：在数据充分覆盖的区域，各模型收敛至相近的预测，分歧度较低；在数据稀疏的区域，模型因初始化差异而产生显著不同的预测，分歧度较高。本文将在算法设计中融合两类不确定性信息，实现更高效的策略优化与在线探索。

2.1.4 Soft Actor-Critic 算法

Soft Actor-Critic（SAC）[28] 是一种基于最大熵框架的 Actor-Critic 算法，在连续控制任务中表现优异，是本文后续章节策略优化的基础算法。SAC 的核心思想是在最大化期望回报的同时最大化策略的熵，从而鼓励探索并提升策略的鲁棒性。

SAC 的优化目标定义为带熵正则的期望回报：

$$J(\pi)=\sum_{t=0}^{\infty}\mathbb{E}_{(s_t,a_t)\sim\rho_\pi}\left[r(s_t,a_t)+\alpha_{ent}\mathcal{H}(\pi(\cdot|s_t))\right], \tag{2.10}$$

其中 $\mathcal{H}(\pi(\cdot|s))=-\mathbb{E}_{a\sim\pi}[\log\pi(a|s)]$ 为策略在状态 s 下的熵，$\alpha_{ent}>0$ 为温度参数，控制熵正则项的相对重要性。熵正则项的引入使策略倾向于在高价值动作之间保持一定的随机性，避免过早收敛到确定性策略，有助于在训练过程中保持探索能力。

SAC 采用 Actor-Critic 架构，包含三个核心组件：策略网络（Actor）π_φ、双 Q 值网络（Critic）$Q_{\theta_1},Q_{\theta_2}$ 和目标 Q 值网络 $Q_{\bar{\theta}_1},Q_{\bar{\theta}_2}$。

Q 值网络通过最小化软贝尔曼残差进行训练：

$$\mathcal{L}(\theta_i) = \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}}\left[(Q_{\theta_i}(s,a) - y)^2\right], \quad i = 1, 2, \tag{2.11}$$

其中目标值 y 定义为：

$$y = r + \gamma\left(\min_{j=1,2} Q_{\bar{\theta}_j}(s', a') - \alpha_{ent}\log\pi_\varphi(a'|s')\right), \quad a' \sim \pi_\varphi(\cdot|s'). \tag{2.12}$$

采用双 Q 网络的最小值可以有效抑制 Q 值的过估计问题[29]。目标网络通过软更新 $\bar{\theta} \leftarrow \tau\theta + (1-\tau)\bar{\theta}$ 与主网络保持同步，其中 $\tau \ll 1$ 为软更新系数，确保训练过程的稳定性。

策略网络通过最大化以下目标进行优化：

$$J(\varphi) = \mathbb{E}_{s\sim\mathcal{D}, a\sim\pi_\varphi}\left[\min_{j=1,2} Q_{\theta_j}(s,a) - \alpha_{ent}\log\pi_\varphi(a|s)\right], \tag{2.13}$$

该目标同时考虑动作价值和策略熵：第一项驱动策略选择高价值动作，第二项鼓励策略保持多样性。对于连续动作空间，策略网络通常输出高斯分布的均值和方差，通过重参数化技巧[30]实现可微采样：

$$a = \tanh(\mu_\varphi(s) + \sigma_\varphi(s) \odot \epsilon), \quad \epsilon \sim \mathcal{N}(0, I), \tag{2.14}$$

其中 tanh 函数将动作限制在有界区间内，$\odot$ 表示逐元素乘法。温度参数 α_{ent} 可通过自动调节机制学习[28]，使熵保持在目标水平附近：

$$\mathcal{L}(\alpha_{ent}) = \mathbb{E}_{a\sim\pi_\varphi}\left[-\alpha_{ent}\left(\log\pi_\varphi(a|s) + \bar{\mathcal{H}}\right)\right], \tag{2.15}$$

其中 $\bar{\mathcal{H}}$ 为目标熵，通常设为 $-\dim(\mathcal{A})$。当策略熵低于目标熵时，α_{ent} 增大以鼓励探索；当策略熵高于目标熵时，α_{ent} 减小以促进收敛。

SAC 在离线强化学习中的应用需要特别注意分布偏移问题：由于无法与环境交互获取反馈，Q 值网络对分布外动作的估计可能产生严重的过估计。本文后续章节通过不确定性惩罚机制约束策略在模型预测可靠的区域内优化，有效缓解这一问题。

2.2 相关工作

离线强化学习（Offline Reinforcement Learning）旨在仅利用预先收集的静态数据集学习策略，而不与环境进行交互[1]。该范式在机器人控制[3]、自动驾驶[6]、医疗决策[5] 等探索成本高昂或存在安全风险的领域具有重要应用价值。离线强化学习面临的核心挑战是分布偏移（Distribution Shift）问题[7]：当学习策略与行为策略差异较大时，策略可能访问离线数据集未

覆盖的状态-动作对，导致价值函数产生外推误差（Extrapolation Error）[8]。根据是否学习环境模型，离线强化学习方法可分为无模型方法和基于模型方法两大类。

2.2.1 无模型离线强化学习

无模型离线强化学习直接从离线数据中学习价值函数或策略，无需构建环境转移模型。由于策略优化过程中无法与真实环境交互获取反馈，分布外动作的价值估计可能产生严重的外推误差[7]。为解决这一问题，研究者提出了多种保守性约束机制，可分为策略约束方法和价值正则化方法两大类[15,31–34]。

策略约束方法通过限制学习策略与行为策略的距离，避免访问离线数据未覆盖的状态-动作对。BCQ[7] 首次系统分析了离线强化学习中的外推误差问题，提出通过条件变分自编码器（CVAE）建模行为策略的动作分布，并利用扰动网络在行为策略支撑集内选择动作。BRAC[31] 系统研究了策略正则化方法，通过在策略优化目标中添加 KL 散度或 MMD 度量作为正则项，显式约束学习策略与行为策略的距离。BEAR[33] 提出支撑集约束，通过最小最大熵目标确保学习策略的动作落在行为策略的支撑集内。TD3+BC[16] 则发现简洁的行为克隆正则项 $\lambda \cdot \|\pi(s) - a\|^2$ 即可实现有效的策略约束，结合 TD3 算法[35] 的双 Q 网络和延迟更新技术，在保持性能的同时大幅简化算法设计。AWR[36] 采用优势加权回归方法，以指数优势函数对数据集中的动作进行加权，隐式约束策略接近高质量动作。策略约束方法直观有效，但策略改进空间受行为策略质量限制，难以显著超越数据集中最优轨迹的性能。

价值正则化方法从价值函数角度抑制分布外动作的过估计。CQL[14] 提出在标准 Bellman 误差基础上引入正则项 $\alpha \cdot (\mathbb{E}_{a\sim\pi}[Q(s,a)] - \mathbb{E}_{a\sim\mathcal{D}}[Q(s,a)])$，通过推低策略分布下动作的 Q 值、推高数据集内动作的 Q 值，学习 Q 值的保守下界。该方法提供了策略性能下界的理论保证，但可能导致过度保守。MCQ[34] 针对 CQL 可能过度惩罚的问题，引入更温和的保守约束，仅对 Q 值高于数据集内最大 Q 值的动作施加惩罚。EDAC[37] 通过多样化 Q 集成和 OOD 惩罚提升不确定性估计的准确性，有效缓解保守性与性能之间的矛盾。IQL[15] 采用期望回归（Expectile Regression）学习价值函数，通过非对称损失函数 $L_\tau(u) = |\tau - \mathbf{1}(u < 0)| \cdot u^2$ 隐式逼近最优 Q 值，完全避免对分布外动作的显式查询，在多个基准任务上取得了优异性能。

近年来，序列建模方法为离线强化学习提供了新的范式。Decision Transformer[38] 将强化学习问题重新表述为序列预测问题，利用 Transformer 架构[39] 在给定目标回报条件下生成动作序列。Diffuser[40] 将扩散模型引入轨迹规划，通过迭代去噪过程生成满足约束的轨迹。RvS[41] 系统比较了条件监督学习与强化学习方法在离线设定下的性能，发现在某些任务上简单的监督学习方法即可取得优异效果。这些工作表明，离线强化学习与序列建模、生成模型的结合是一个值得深入探索的方向。

无模型方法的共同局限在于无法生成新的数据样本，样本效率相对较低，且保守性约束

可能限制策略的潜在性能上限。

2.2.2 基于模型的离线强化学习

基于模型的离线强化学习首先从离线数据学习环境转移模型，再通过与模型交互生成虚拟样本优化策略[17,21,42,43]。相比无模型方法，基于模型的方法具有更高的样本效率：一旦学习到准确的环境动力学模型，策略可通过与模型的虚拟交互进行优化，无需频繁访问真实环境。然而，模型在分布外区域的预测可能产生外推误差[8]，且误差会随模型推演（rollout）步数累积，导致性能退化。因此，如何在利用模型数据与保持保守性之间取得平衡，是基于模型离线强化学习的核心问题。

在模型架构方面，早期工作主要采用确定性神经网络或高斯概率模型。PETS[20] 提出使用概率集成模型，既可量化预测不确定性，又可通过集成降低单一模型的偏差。MBPO[21] 在此基础上将模型生成数据与无模型方法结合，实现高效的在线强化学习。近年来，研究者开始探索更强的模型架构。Lu 等人[44] 系统研究了模型架构、训练策略和模型使用方式对离线模型基础强化学习的影响。世界模型（World Models）[22] 提出在潜在空间学习环境动力学，显著降低了模型学习的复杂度。Dreamer 系列[23,24] 在潜在空间同时学习转移模型和价值函数，实现了高效的想象力规划（imagination-based planning）。MuZero[45] 将模型学习与蒙特卡洛树搜索结合，在 Atari、围棋等任务上取得了最先进的性能。扩散模型作为强大的生成模型，也被引入强化学习领域[46,47]，能够更好地捕捉多模态转移分布。

不确定性惩罚方法是离线基于模型强化学习的主流范式。MOPO[17] 提出通过集成模型估计状态转移的不确定性，并将不确定性量化值作为惩罚项从奖励中扣除：$\tilde{r}(s,a) = r(s,a) - \lambda \cdot u(s,a)$，其中 $u(s,a)$ 为集成模型预测的标准差。该方法约束策略在低不确定性区域内优化，并提供了理论保证的策略性能下界。然而，惩罚系数 λ 需要针对不同任务调整，且过强的惩罚可能过度限制策略探索。PMDB[48] 提出根据模型预测的置信度动态调整惩罚强度，在保守性与探索性之间取得更好的平衡。

悲观 MDP 方法从构建保守环境模型的角度实现保守性。MOReL[18] 构建悲观 MDP：当集成模型的预测分歧度超过阈值 ϵ 时，将状态转移至吸收态并给予固定负奖励 r_{halt}，从而将策略优化限制在高置信区域内。RAMBO[49] 则通过对抗训练学习悲观模型，在模型集成中选择使策略性能最差的转移，无需显式设定不确定性阈值。该类方法提供更强的安全保证，但悲观性可能过强导致策略过于保守。

保守价值估计方法将无模型方法的保守性与模型数据结合。COMBO[19] 在模型生成数据上采用 CQL 的保守 Q 学习，在真实数据上进行标准 Bellman 更新，兼顾数据效率与保守性。MORI[42] 提出反向模型推演（Reverse Imagination），从数据集状态反向生成轨迹，避免模型误差随正向推演累积。合成经验重放（SER）[43] 利用生成模型合成高质量的训练数据，提升策

略在稀疏数据区域的泛化能力。

尽管上述方法在一定程度上缓解了外推误差，但其核心局限在于不确定性信息仅用于惩罚高不确定性区域，而非主动引导策略补充这些区域的数据。这导致模型在分布外区域的泛化能力始终受限，难以突破离线数据的覆盖边界。此外，现有方法通常采用静态的不确定性惩罚系数，难以适应策略优化的动态过程。

2.2.3 离线到在线强化学习

离线到在线强化学习（Offline-to-Online RL）旨在结合离线学习与在线学习的优势：先在离线数据集上预训练策略，再通过有限的在线交互进行微调，提升策略性能[25,50,51]。这种两阶段范式在实际应用中具有重要意义：既可以利用历史数据降低样本需求，又可以通过在线反馈适应环境变化。该范式的核心挑战在于灾难性遗忘（Catastrophic Forgetting）问题：预训练策略在在线微调初期可能出现性能骤降，原因是策略约束的放松导致对分布外状态的访问增加，而价值函数对这些状态的估计不可靠[50]。

当前主流方法可分为保守性调节、数据融合和序列建模三类。保守性调节方法通过在离线阶段采用保守算法、在线阶段逐步放松约束来实现平滑过渡。AWAC[25] 通过优势加权回归优化策略，以指数优势函数 $\exp(A(s,a)/\lambda)$ 对数据集中的动作进行加权，隐式约束策略接近高质量动作，该方法自然适配离线到在线转换，无需修改算法即可在两阶段间切换。PEX[52] 维护离线策略 π_{off} 与在线策略 π_{on} 的混合 $\pi = \alpha\pi_{off} + (1-\alpha)\pi_{on}$，根据在线性能动态调整混合权重 α，在安全性与灵活性之间取得平衡。Cal-QL[26] 发现离线预训练的 Q 值可能过于保守或过于乐观，提出通过校准 Q 值下界确保在线微调时策略有合理的改进方向。In-Sample Softmax[53] 提出仅在数据集内样本上计算 softmax，避免对分布外动作的显式惩罚，简化了算法设计。

数据融合方法则关注如何有效利用离线数据与在线数据的互补性。平衡重放[50] 结合悲观 Q 集成与平衡采样策略，以固定比例从离线数据集与在线回放池中采样，同时采用多个 Q 网络的最小值 $\min_i Q_i(s,a)$ 抑制过估计，在在线阶段逐步减少 Q 网络数量以放松保守约束。E2O[54] 进一步研究了 Q 集成在离线到在线转换中的作用，发现适当的集成规模和放松策略对于平滑过渡至关重要。Hybrid RL[51] 从理论角度分析了同时利用离线和在线数据的优势，证明了混合方法可以实现比纯离线或纯在线方法更好的样本复杂度。

序列建模方法将强化学习问题转化为序列预测问题。Online Decision Transformer[55] 在 Decision Transformer 基础上引入在线微调机制，通过动态调整目标回报条件实现策略改进。然而，这类方法在连续控制任务上的性能仍有提升空间。

综合分析现有离线到在线强化学习方法，存在以下共同局限：（1）保守性与灵活性的矛盾：离线阶段的保守性约束在在线阶段仍会阻碍策略灵活性，使策略难以有效适应新数据；（2）

在线交互成本高：多数方法为无模型方法，需要频繁访问在线环境（通常需要 200k 步交互），成本较高；（3）不确定性利用不充分：现有方法主要将不确定性用于惩罚高不确定性区域以保持保守性，而未能利用不确定性信息主动引导在线探索。相比之下，近年基于模型的强化学习研究表明，集成动力学模型的可靠性可以得到相对保证[17,19,44,46,48,49]。这启发我们探索一种基于模型的离线到在线强化学习算法：在离线阶段利用不确定性保持保守性，在在线阶段利用不确定性引导探索。具体而言，当采集在线样本时，策略应被引导至高不确定性（转移模型覆盖之外）且高动作价值（接近目标）的区域，主动补充转移模型的训练数据，而非被动地在低不确定性区域内采样。

2.3 本章小结

本章首先介绍了强化学习的理论基础，包括 MDP 框架、基于模型的离线强化学习框架以及集成模型的不确定性估计方法。在相关工作部分，系统综述了离线强化学习与离线到在线强化学习的发展历程：无模型离线强化学习通过策略约束或价值正则化抑制分布外过估计，优势在于理论保证完善、实现简洁，局限在于样本效率低、保守性可能限制性能；基于模型离线强化学习通过学习转移模型提升样本效率，优势在于可生成额外数据，局限在于现有方法采用静态的不确定性估计，难以在探索与保守之间取得动态平衡；离线到在线强化学习通过保守性调节或数据融合平滑过渡，优势在于结合两阶段优势，局限在于保守性与灵活性矛盾、在线交互成本高、不确定性利用不充分。

基于上述分析，本文提出两种互补的算法方案。第一，基于自适应不确定性度量的离线强化学习算法：引入累积状态不确定性度量，综合考虑状态转移不确定性和状态本身的累积不确定性；设计自适应动态权重机制，根据策略优化进程动态调节不确定性惩罚强度，在探索与保守之间取得更好的平衡。第二，基于定向探索模型的离线到在线强化学习算法：继承基于模型方法的样本效率优势，创新性地将不确定性信息用于引导在线探索，显式引导策略探索高不确定性且高价值的区域，以最少的在线交互实现高效微调。两种方法形成递进关系：前者解决纯离线设定下的保守策略优化问题，后者引入在线微调阶段突破离线数据的边界。

第三章　基于自适应不确定性度量的离线强化学习算法

本章详细介绍本文提出的基于自适应不确定性度量的离线强化学习算法。首先分析现有基于模型的离线强化学习方法在不确定性估计方面的局限性并阐明算法设计动机；随后系统阐述算法的整体框架，包括环境模型构建和策略优化两个核心模块；接着深入讨论累积状态不确定性度量方法与自适应动态权重机制；然后给出算法的理论分析，证明累积不确定性度量和自适应权重的有效性；最后通过在 D4RL 基准测试集上的实验验证算法的有效性，并与现有方法进行系统对比。

3.1　问题分析与算法动机

如第二章所述，基于模型的离线强化学习通过学习环境转移模型并与模型交互来优化策略，具有较高的样本效率。然而，由于离线数据集的分布偏移问题，现有方法通常采用不确定性惩罚机制来约束策略在模型预测可靠的区域内优化。以 MOPO[17] 为代表的方法使用模型预测方差作为不确定性度量，并从奖励中扣除不确定性惩罚项。然而，这类方法存在以下根本性局限：

第一，仅考虑状态转移的不确定性，忽视了状态本身的不确定性。现有方法仅关注从当前状态-动作对预测下一状态时的不确定性，而忽视了当前状态本身可能已经处于分布外区域这一事实。由于强化学习是序列决策过程，如果智能体在早期时刻进入了一个不确定的状态，这种不确定性会随时间不断累积，导致后续决策的可靠性持续下降。例如，在与环境模型交互生成虚拟轨迹时，随着推演步数的增加，即使每一步的状态转移不确定性较低，累积效应也可能导致当前状态远离离线数据的覆盖范围。

第二，采用静态的不确定性评估方法，无法适应策略优化的动态过程。在策略优化过程中，智能体的策略不断迭代更新，其访问状态的分布也随之变化，因此对环境状态的不确定性评估应是动态变化的。然而，现有方法采用固定的不确定性惩罚系数，无法根据策略优化的进程自适应调整。在训练初期，智能体需要充分探索以收集多样化的经验；在训练后期，智能体应更加保守以确保策略的稳健性。固定惩罚系数难以同时满足这两个阶段的不同需求。

第三，难以在探索与保守之间取得平衡。过度的保守性虽然可以有效避免分布偏移，但会限制智能体的探索能力，导致策略难以充分优化；而探索性过强则可能使智能体进入不确定性高的区域，造成严重的分布偏移问题。理想的算法应能根据策略优化的不同阶段，动态调节探索与保守的平衡。

基于上述分析，本文提出两个核心改进思想。第一，引入累积状态不确定性度量：不仅考虑状态转移的不确定性，还考虑从初始状态到当前状态的累积不确定性，使智能体能够更

全面地评估当前决策的风险，避免进入分布外区域。第二，引入自适应动态权重机制：根据策略优化的进程自适应调整不确定性惩罚的强度，在训练初期降低惩罚权重以鼓励探索，在策略逐渐收敛时增加惩罚权重以提升保守性。这种机制使智能体能够在策略优化的不同阶段取得更好的探索-保守平衡。

3.2　算法框架

本文提出的基于自适应不确定性度量的离线强化学习算法采用两阶段框架：第一阶段从离线数据集学习环境转移模型；第二阶段利用累积不确定性度量与自适应权重机制进行策略优化。算法的整体流程如图3.1所示。

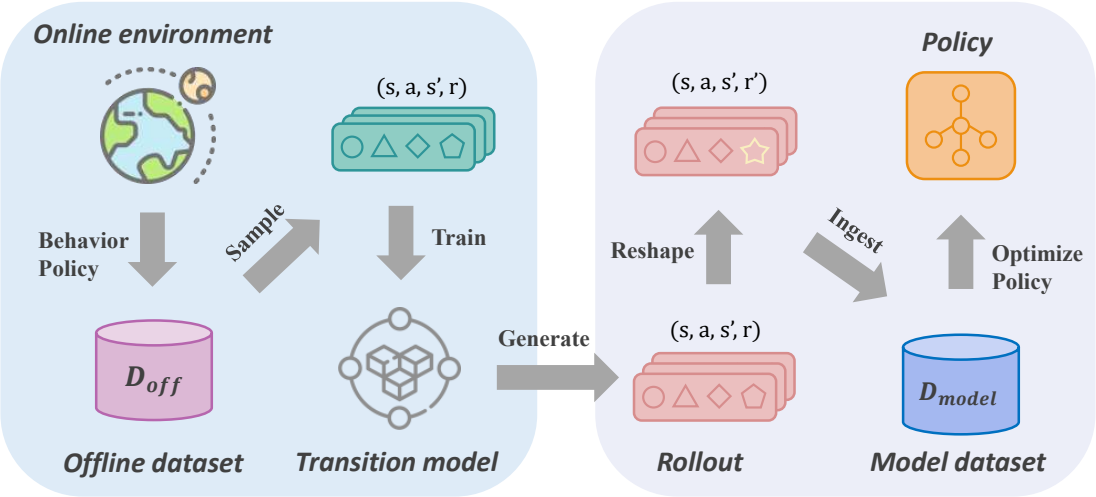

图 3.1　基于自适应不确定性度量的离线强化学习算法框架。第一阶段基于离线数据集训练概率转移模型；第二阶段利用转移模型生成虚拟轨迹，同时计算累积状态不确定性和状态转移不确定性，通过自适应权重进行奖励重塑，最终基于 SAC 算法优化策略。

3.2.1　概率转移模型构建

在基于模型的离线强化学习中，首先需要从离线数据集 $\mathcal{D}_{off} = \{(s_i, a_i, s'_i, r_i)\}_{i=1}^{N}$ 中学习环境的状态转移函数。本文采用神经网络参数化的概率转移模型 $\hat{T}_\theta(s', r|s, a)$，以当前状态 s 和动作 a 为输入，输出下一状态 s' 和奖励 r 的条件分布。

转移模型采用高斯分布进行建模：

$$\hat{T}_\theta(s', r|s, a) = \mathcal{N}\left(\mu_\theta(s, a), \Sigma_\theta(s, a)\right), \tag{3.1}$$

其中 $\mu_\theta(s, a) \in \mathbb{R}^{d_s+1}$ 为预测均值向量（包含下一状态和奖励），$\Sigma_\theta(s, a) \in \mathbb{R}^{(d_s+1)\times(d_s+1)}$ 为预测协方差矩阵，d_s 为状态空间维度。为简化计算，本文采用对角协方差矩阵。

模型网络采用多层感知机结构，包含 3 个隐藏层，每层 256 个神经元，使用 ReLU 激活函数。输出层分为两个分支：均值分支直接输出预测均值，方差分支输出对数方差 $\log\sigma^2$，通过指数变换得到正定的方差估计，保证数值稳定性。

模型参数通过最大化离线数据的对数似然进行优化，训练损失定义为：

$$\mathcal{L}(\theta) = -\mathbb{E}_{(s,a,r,s')\sim\mathcal{D}_{off}}\left[\log \hat{T}_\theta(s', r|s, a)\right], \tag{3.2}$$

展开高斯分布的对数似然，训练损失可写为：

$$\mathcal{L}(\theta) = \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}_{off}}\left[\frac{1}{2}(y-\mu_\theta)^T\Sigma_\theta^{-1}(y-\mu_\theta) + \frac{1}{2}\log|\Sigma_\theta|\right], \tag{3.3}$$

其中 $y = [s'; r]$ 为真实的下一状态和奖励拼接向量。该损失函数同时优化预测均值和预测方差：均值项最小化预测误差，方差项约束模型输出合理的不确定性估计。

3.2.2 基于不确定性惩罚的策略优化

完成转移模型训练后，策略优化阶段利用转移模型生成虚拟轨迹，并基于不确定性惩罚进行策略更新。与 MOPO[17] 类似，本文定义状态转移不确定性为模型预测方差的范数：

$$u_{trans}(s, a) = \|\Sigma_\theta(s, a)\|_F, \tag{3.4}$$

其中 $\|\cdot\|_F$ 表示 Frobenius 范数。该度量反映了模型对状态转移预测的置信程度：在数据覆盖充分的区域，模型预测方差较小；在数据稀疏的分布外区域，模型预测方差较大。

策略优化采用 Soft Actor-Critic（SAC）[28] 算法框架。SAC 维护策略网络 π_φ 和两个 Q 值网络 $Q_{\theta_1}, Q_{\theta_2}$，通过最大化带熵正则的期望回报优化策略：

$$J(\varphi) = \mathbb{E}_{s\sim\mathcal{D},a\sim\pi_\varphi}[Q_\theta(s, a) - \alpha_{ent}\log\pi_\varphi(a|s)], \tag{3.5}$$

其中 α_{ent} 为温度参数，控制探索与利用的平衡。训练数据从离线数据集 $\mathcal{D}_{off}$ 和模型生成数据集 $\mathcal{D}_{model}$ 中按比例采样。模型生成数据通过从离线数据集中采样初始状态，利用当前策略与转移模型交互生成短期轨迹获得。

3.3 累积状态不确定性度量

本节介绍累积状态不确定性的度量方法。首先阐述累积不确定性的概念与形式化定义，随后介绍基于神经网络的不确定性预测模型。

3.3.1 累积不确定性的形式化定义

为解决仅考虑状态转移不确定性的局限，本文引入累积状态不确定性的概念：状态 s_t 的不确定性不仅取决于从 s_{t-1} 转移到 s_t 的不确定性，还取决于从初始状态到 s_{t-1} 的累积不确定性。这一设计的核心思想是：强化学习是序列决策过程，不确定性会随轨迹传播和累积。

定义状态 s_t 的累积不确定性为：

$$u(s_t) = \mathbb{E}\left[\sum_{t'=0}^{t} \omega^{t-t'} \log\left(\Sigma_\theta(s_{t'}, a_{t'}) + 1\right)\right], \tag{3.6}$$

其中 $\omega \in (0, 1]$ 为折扣因子。该定义的核心思想是：状态 s_t 的不确定性由从初始状态到当前状态的所有状态转移不确定性的折扣和构成。引入折扣因子 ω 的原因在于：（1）从不同的初始状态都有可能到达 s_t，因此应给时序上更近的状态赋予更高的权重；（2）早期状态转移的不确定性对当前状态的影响随时间递减。取对数是为了使不确定性度量更加平滑，避免数值不稳定。

基于上述定义，累积状态不确定性可通过递推方式进行高效更新：

$$u(s') = \omega \cdot u(s) + \log\left(\Sigma_\theta(s, a) + 1\right), \tag{3.7}$$

其中 s' 为从状态 s 执行动作 a 后转移到的下一状态。该递推公式表明：下一状态的累积不确定性由当前状态的累积不确定性（经折扣后）与当前状态转移的不确定性之和构成。相比重新计算完整历史，递推更新的时间复杂度为 $O(1)$，适合在线应用。

3.3.2 不确定性预测网络

在实际应用中，由于状态空间通常是连续的，难以显式维护每个状态的累积不确定性。为此，本文引入一个额外的神经网络 $u_\phi(s)$ 来学习状态到累积不确定性的映射关系。

不确定性预测网络采用多层感知机结构，包含 2 个隐藏层，每层 128 个神经元，使用 ReLU 激活函数，输出为标量的不确定性估计值。网络结构的选择兼顾了表达能力和计算效率：相比主网络较小的规模确保不确定性预测不会成为计算瓶颈。

网络的训练采用监督学习方式。在智能体与环境模型交互生成虚拟轨迹的过程中，对每个访问的状态 s，根据公式 (3.7) 计算其累积不确定性 $u(s)$，并将 $(s, u(s))$ 对存入经验回放池 $\mathcal{D}_{model}$。在训练过程中，从经验回放池中采样批次数据，通过最小化均方误差损失优化网络参数：

$$\mathcal{L}(\phi) = \mathbb{E}_{(s,u(s))\sim\mathcal{D}_{model}}\left[\left(u_\phi(s) - u(s)\right)^2\right]. \tag{3.8}$$

通过该网络，智能体可以快速评估任意状态的累积不确定性，无需在线计算完整的历史轨迹。在推理时，网络的前向传播复杂度为 $O(d_\phi)$，其中 d_ϕ 为网络参数量，相比存储和查询完整历史显著降低了计算开销。

3.3.3 基于累积不确定性的奖励重塑

基于累积状态不确定性和状态转移不确定性，本文提出综合的奖励重塑机制。当智能体处于状态 s 并执行动作 a 时，通过环境模型获取下一状态 s' 和奖励 r，同时获取状态转移不确定性 $\Sigma_\theta(s,a)$ 和下一状态的累积不确定性 $u_\phi(s')$。重塑后的奖励定义为：

$$\tilde{r} = r - \lambda \cdot \left(\alpha \cdot u_\phi(s') + \Sigma_\theta(s,a)\right), \tag{3.9}$$

其中 λ 为不确定性惩罚的总体权重，α 为平衡状态不确定性与转移不确定性的超参数。该奖励重塑机制具有以下优势：

第一，综合考虑了状态不确定性和转移不确定性。不仅惩罚高不确定性的状态转移，还惩罚进入高不确定性状态的行为，使智能体能够更全面地规避分布外区域。

第二，累积不确定性能够捕捉历史信息的影响。即使当前状态转移的不确定性较低，如果该状态是通过多次高不确定性转移到达的，其累积不确定性仍然较高，会受到相应的惩罚。

第三，通过超参数 α 可以灵活调节两类不确定性的相对权重，适应不同任务的特点。

3.4 自适应动态权重机制

本节介绍自适应动态权重机制的设计。首先阐述动态权重的动机，随后给出具体的数学形式。

3.4.1 动态权重的动机

仅通过上述累积不确定性度量进行奖励重塑，智能体仍可能陷入过于保守的情况，无法充分探索环境以优化策略。这是因为在策略优化的不同阶段，智能体对探索和保守的需求不同：

在训练初期，智能体的策略尚未稳定，需要充分探索环境模型中的各个状态以收集多样化的经验，此时应降低保守性约束以鼓励探索。如果此时施加过强的不确定性惩罚，智能体将被限制在离线数据密集覆盖的区域，难以发现潜在的高价值策略。

在训练后期，智能体的策略逐渐收敛，此时应减少对不确定状态的探索，增加保守性以确保策略的稳健性，避免在最终评估时进入分布外区域。过度的探索可能导致策略在收敛阶

段产生不必要的波动。

基于以上分析，本文提出根据训练轮次动态调整不确定性惩罚权重的机制，实现探索与保守的自适应平衡。

3.4.2 自适应权重的数学形式

定义自适应动态权重系数为：

$$\lambda_k = \frac{\lambda_0}{1 + e^{K_0 - k}}, \tag{3.10}$$

其中 k 为当前训练的轮次数，K_0 为预定义的转折点超参数，λ_0 为基础惩罚系数。该权重系数遵循 Sigmoid 函数的曲线特性，具有以下性质：

当 $k \ll K_0$ 时，$\lambda_k \approx \lambda_0 \cdot e^{k-K_0} \approx 0$，惩罚权重接近于零。此时智能体倾向于充分探索环境模型中的各个状态，不确定性惩罚几乎不起作用。

当 $k \gg K_0$ 时，$\lambda_k \approx \lambda_0$，惩罚权重达到完整值。此时智能体变得保守，强不确定性区域受到显著惩罚，策略被约束在模型预测可靠的区域内。

当 $k = K_0$ 时，$\lambda_k = \lambda_0/2$，惩罚权重处于中间水平。这标志着从探索主导向保守主导的过渡点，Sigmoid 函数确保这一过渡是平滑连续的，避免策略优化过程中的剧烈波动。

该设计的核心优势在于：使用 Sigmoid 函数确保权重从低到高的变化是连续平滑的；通过调整 K_0 可以控制从探索到保守的过渡时机，适应不同任务的训练需求；仅引入一个额外的超参数 K_0，增加的计算开销可忽略不计。

3.5 理论分析

本节从理论角度分析累积状态不确定性度量和自适应动态权重机制的合理性与有效性。

3.5.1 累积不确定性的性质

首先分析累积不确定性度量的基本性质。

命题 3.1 (累积不确定性的单调性)**.** *设 $u(s_t)$ 为状态 s_t 的累积不确定性，按公式 (3.7) 递推更新。若所有状态转移的不确定性非负，即 $\forall s, a : \log(\Sigma_\theta(s,a) + 1) \geq 0$（当 $\Sigma_\theta(s,a) \geq 0$ 时自动满足），则累积不确定性沿轨迹单调不减：*

$$u(s_{t+1}) \geq \omega \cdot u(s_t), \quad \forall t \geq 0. \tag{3.11}$$

特别地，当 $\omega = 1$ 时，累积不确定性严格单调不减：$u(s_{t+1}) \geq u(s_t)$。

证明. 由公式 (3.7)，有

$$u(s_{t+1}) = \omega \cdot u(s_t) + \log(\Sigma_\theta(s_t, a_t) + 1). \tag{3.12}$$

由于 $\Sigma_\theta(s_t, a_t)$ 为协方差矩阵（或其范数），满足 $\Sigma_\theta(s_t, a_t) \geq 0$，因此 $\log(\Sigma_\theta(s_t, a_t) + 1) \geq \log(1) = 0$。

立即得到 $u(s_{t+1}) \geq \omega \cdot u(s_t)$。

当 $\omega = 1$ 时，$u(s_{t+1}) = u(s_t) + \log(\Sigma_\theta(s_t, a_t) + 1) \geq u(s_t)$。 □

该性质表明：随着智能体与环境模型交互的推进，累积不确定性倾向于增加。这符合直觉：模型推演步数越多，累积的预测误差越大，状态的可靠性越低。折扣因子 ω 控制了累积速率，当 $\omega < 1$ 时，早期不确定性的影响逐渐衰减。

命题 3.2 (累积不确定性的上界)**.** *设 $u_{max} = \max_{s,a} \log(\Sigma_\theta(s, a) + 1)$ 为单步不确定性的上界。若 $\omega < 1$，则经过 t 步后，累积不确定性有上界：*

$$u(s_t) \leq \frac{1 - \omega^t}{1 - \omega} \cdot u_{max}. \tag{3.13}$$

当 $t \to \infty$ 时，$u(s_t) \leq \frac{u_{max}}{1-\omega}$。

证明. 设 $u_0 = u(s_0) = 0$（初始状态无累积不确定性）。由递推公式：

$$u(s_1) = \omega \cdot 0 + \log(\Sigma_\theta(s_0, a_0) + 1) \leq u_{max}, \tag{3.14}$$

$$u(s_2) = \omega \cdot u(s_1) + \log(\Sigma_\theta(s_1, a_1) + 1) \leq \omega \cdot u_{max} + u_{max}, \tag{3.15}$$

$$\vdots$$

$$u(s_t) \leq \sum_{i=0}^{t-1} \omega^i \cdot u_{max} = \frac{1 - \omega^t}{1 - \omega} \cdot u_{max}. \tag{3.16}$$

当 $t \to \infty$ 时，$\omega^t \to 0$，因此 $u(s_t) \leq \frac{u_{max}}{1-\omega}$。 □

该性质表明：当 $\omega < 1$ 时，累积不确定性存在有限的上界，不会无限增长。这保证了算法的数值稳定性。

命题 3.3 (不确定性预测的泛化性)**.** *设不确定性预测网络 $u_\phi(s)$ 具有 Lipschitz 连续性，即存在常数 $L > 0$ 使得 $|u_\phi(s_1) - u_\phi(s_2)| \leq L \cdot \|s_1 - s_2\|$。设真实不确定性函数 $u(s)$ 也具有 Lipschitz 连续性，Lipschitz 常数为 L_u。若网络在经验回放池 $\mathcal{D}_{model}$ 上达到 ϵ-最优，即 $\mathbb{E}_{s \sim \mathcal{D}_{model}}[(u_\phi(s) - u(s))^2] \leq \epsilon$，则对于 $\mathcal{D}_{model}$ 中某状态 s 的 δ-邻域内的新状态 s'（即 $\|s' - s\| \leq \delta$），预测误差满*

足：

$$|u_\phi(s') - u(s')| \leq \sqrt{\epsilon} + (L + L_u) \cdot \delta. \tag{3.17}$$

证明. 对于 $\mathcal{D}_{model}$ 中的状态 s 和其 δ-邻域内的新状态 s'，有：

$$\begin{aligned}
|u_\phi(s') - u(s')| &= |u_\phi(s') - u_\phi(s) + u_\phi(s) - u(s) + u(s) - u(s')| && (3.18)\\
&\leq |u_\phi(s') - u_\phi(s)| + |u_\phi(s) - u(s)| + |u(s) - u(s')| && (3.19)\\
&\leq L \cdot \|s' - s\| + |u_\phi(s) - u(s)| + L_u \cdot \|s' - s\| && (3.20)\\
&\leq (L + L_u) \cdot \delta + |u_\phi(s) - u(s)|. && (3.21)
\end{aligned}$$

由于 $\mathbb{E}_{s\sim\mathcal{D}_{model}}[(u_\phi(s) - u(s))^2] \leq \epsilon$，根据 Jensen 不等式：

$$\mathbb{E}_{s\sim\mathcal{D}_{model}}[|u_\phi(s) - u(s)|] \leq \sqrt{\mathbb{E}_{s\sim\mathcal{D}_{model}}[(u_\phi(s) - u(s))^2]} \leq \sqrt{\epsilon}. \tag{3.22}$$

因此，对于 $\mathcal{D}_{model}$ 中的典型状态 s，有 $|u_\phi(s) - u(s)| \lesssim \sqrt{\epsilon}$。代入上式得：

$$|u_\phi(s') - u(s')| \leq \sqrt{\epsilon} + (L + L_u) \cdot \delta. \tag{3.23}$$

□

该性质说明：只要不确定性预测网络在训练数据上拟合良好（ϵ 小），且网络和真实函数都具有合理的平滑性（L 和 L_u 有限），其对邻近状态的预测也具有一定的泛化能力。这为使用神经网络预测累积不确定性提供了理论支撑。

3.5.2 自适应权重的探索-保守平衡

本节分析自适应动态权重机制如何实现探索与保守的平衡。首先给出形式化的定义和分析框架。

设在训练轮次 k 时，智能体在 MDP M 中的策略为 π_k。定义有效 MDP $\tilde{M}_k$ 为引入不确定性惩罚后的 MDP，其奖励函数为：

$$\tilde{r}_k(s, a) = r(s, a) - \lambda_k \cdot u(s, a), \tag{3.24}$$

其中 $u(s, a)$ 为综合不确定性度量。

引理 3.4 (惩罚 MDP 的期望回报分解)**.** 设 $\eta_M(\pi)$ 为策略 π 在原 *MDP* M 中的期望回报，$\eta_{\tilde{M}_k}(\pi)$ 为在惩罚 *MDP* $\tilde{M}_k$ 中的期望回报。则有：

$$\eta_{\tilde{M}_k}(\pi) = \eta_M(\pi) - \lambda_k \cdot \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t u(s_t, a_t)\right]. \tag{3.25}$$

证明. 由期望回报的定义：

$$\begin{aligned}
\eta_{\tilde{M}_k}(\pi) &= \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t \tilde{r}_k(s_t, a_t)\right] && (3.26)\\
&= \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t \left(r(s_t, a_t) - \lambda_k \cdot u(s_t, a_t)\right)\right] && (3.27)\\
&= \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t r(s_t, a_t)\right] - \lambda_k \cdot \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t u(s_t, a_t)\right] && (3.28)\\
&= \eta_M(\pi) - \lambda_k \cdot U(\pi), && (3.29)
\end{aligned}$$

其中 $U(\pi) = \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t u(s_t, a_t)\right]$ 为策略 π 的累积不确定性期望。 □

定理 3.5 (自适应权重的平衡性)**.** 设 $\pi^*_{explore}$ 为最大化原 *MDP* 期望回报的最优策略（纯探索），$\pi^*_{conserve}$ 为最小化累积不确定性的最优策略（纯保守）。在自适应权重机制下，训练轮次 k 时优化的有效目标 $\eta_{\tilde{M}_k}(\pi)$ 可分解为：

$$\eta_{\tilde{M}_k}(\pi) = \eta_M(\pi) - \lambda_k \cdot U(\pi), \tag{3.30}$$

定义归一化权重 $w_k = \lambda_k/\lambda_0 = 1/(1+e^{K_0-k})$，则：

1. 当 $k \ll K_0$ 时，$w_k \approx 0$，优化目标近似为 $\eta_M(\pi)$，策略偏向最大化原始回报（探索主导）；
2. 当 $k \gg K_0$ 时，$w_k \approx 1$，惩罚项权重达到 λ_0，策略被强约束以避免高不确定性区域（保守主导）；
3. 当 $k = K_0$ 时，$w_k = 0.5$，两种目标权重平衡。

证明. 由引理3.4，有 $\eta_{\tilde{M}_k}(\pi) = \eta_M(\pi) - \lambda_k \cdot U(\pi)$。

由 $\lambda_k = \lambda_0/(1+e^{K_0-k})$，定义 $w_k = \lambda_k/\lambda_0$，则 $w_k = 1/(1+e^{K_0-k})$ 为标准 Sigmoid 函数。

情形 1：当 $k \ll K_0$ 时，$K_0 - k \gg 0$，因此 $e^{K_0-k} \gg 1$，故 $w_k = 1/(1+e^{K_0-k}) \approx e^{-(K_0-k)} \approx 0$。此时 $\lambda_k \approx 0$，优化目标 $\eta_{\tilde{M}_k}(\pi) \approx \eta_M(\pi)$，即最大化原始期望回报，策略偏向探索。

情形 2：当 $k \gg K_0$ 时，$K_0 - k \ll 0$，因此 $e^{K_0-k} \approx 0$，故 $w_k \approx 1$。此时 $\lambda_k \approx \lambda_0$，惩罚项达到最大权重，策略被强约束以避免高不确定性区域，偏向保守。

情形 3：当 $k = K_0$ 时，$e^{K_0-k} = e^0 = 1$，故 $w_k = 1/(1+1) = 0.5$。此时 $\lambda_k = \lambda_0/2$，探索与保守的权重平衡。

Sigmoid 函数的单调性（$dw_k/dk > 0$）确保了从探索到保守的平滑过渡。 □

推论 3.6 (相比固定权重的优势)**.** 设总训练轮数为 K。定义策略序列 $\{\pi_k\}_{k=1}^K$ 在固定权重 λ 下的累积收益为：

$$\mathcal{R}_{fixed}(\lambda) = \sum_{k=1}^{K} \eta_M(\pi_k) - \lambda \cdot U(\pi_k), \tag{3.31}$$

在自适应权重下的累积收益为：

$$\mathcal{R}_{adaptive} = \sum_{k=1}^{K} \eta_M(\pi_k) - \lambda_k \cdot U(\pi_k). \tag{3.32}$$

若存在最优权重调度 $\{\lambda_k^*\}_{k=1}^K$ 使累积收益最大化，且该调度满足”先低后高”的特性（即 λ_k^* 随 k 单调不减），则存在适当的 K_0 和 λ_0 使得自适应权重近似最优调度，即：

$$\mathcal{R}_{adaptive} \geq \mathcal{R}_{fixed}(\lambda), \quad \forall \lambda \in (0, \lambda_0]. \tag{3.33}$$

证明. 固定权重 λ 的累积收益可写为：

$$\mathcal{R}_{fixed}(\lambda) = \sum_{k=1}^{K} \eta_M(\pi_k) - \lambda \sum_{k=1}^{K} U(\pi_k). \tag{3.34}$$

对于任意固定 λ，若在训练初期（k 小）策略需要探索（应使用小惩罚权重），而在训练后期（k 大）策略需要保守（应使用大惩罚权重），则固定权重无法同时满足这两个需求。

设最优权重调度为 $\{\lambda_k^*\}$，满足 λ_k^* 随 k 单调不减。自适应权重 $\lambda_k = \lambda_0/(1+e^{K_0-k})$ 也满足单调不减性质（因为 Sigmoid 函数单调递增）。

通过选择适当的 K_0（控制过渡时机）和 λ_0（控制最终惩罚强度），可以使 λ_k 近似 λ_k^*。具体地：

- 选择 K_0 使得 $\lambda_{K_0} = \lambda_{K_0}^*$（匹配中间点）；
- 选择 λ_0 使得 $\lambda_K \approx \lambda_K^*$（匹配终点）。

由于 Sigmoid 函数可以通过参数调整逼近任意单调递增的连续函数（在函数空间稠密），因此存在 K_0, λ_0 使得 $\mathcal{R}_{adaptive} \geq \mathcal{R}_{fixed}(\lambda)$ 对所有固定 $\lambda \in (0, \lambda_0]$ 成立。 □

该推论说明：在最优权重应随时间变化的任务中，自适应权重机制能够获得比任何固定权重更好的性能。这为本文设计的自适应机制提供了理论依据。

3.6 算法流程

综合以上各节内容，本文提出的基于自适应不确定性度量的离线强化学习算法的完整流程如算法1所示。

Algorithm 1 基于自适应不确定性度量的离线强化学习算法

Require: 离线数据集 $\mathcal{D}_{off}$，基础惩罚系数 λ_0，折扣因子 ω，状态不确定性权重 α，转折点 K_0，最大探索步数 t_{max}，训练轮数 K
Ensure: 优化后的策略 π_φ
// 阶段 1：训练环境转移模型
初始化转移模型 $\hat{T}_\theta$
while 转移模型未收敛 **do**
    从 $\mathcal{D}_{off}$ 采样批次 (s, a, r, s')
    根据公式 (3.2) 更新模型：$\theta \leftarrow \theta - \beta_\theta \nabla_\theta \mathcal{L}(\theta)$
end while
// 阶段 2：策略优化
初始化策略网络 π_φ、Q 网络 $Q_{\theta_1}, Q_{\theta_2}$、不确定性网络 u_ϕ
for 轮次 $k = 1$ to K **do**
    计算自适应权重 λ_k（公式3.10）
    从 $\mathcal{D}_{off}$ 采样初始状态 s_0，初始化 $u(s_0) = 0$
    for $t = 0$ to t_{max} **do**
        根据策略采样动作：$a_t \sim \pi_\varphi(\cdot|s_t)$
        从转移模型获取：$s_{t+1}, r_t, \Sigma_\theta(s_t, a_t) \sim \hat{T}_\theta(s_t, a_t)$
        预测累积不确定性：$\hat{u}_{t+1} = u_\phi(s_{t+1})$
        更新累积不确定性：$u(s_{t+1}) = \omega \cdot u(s_t) + \log(\Sigma_\theta(s_t, a_t) + 1)$
        计算重塑奖励：$\tilde{r}_t = r_t - \lambda_k \cdot (\alpha \cdot \hat{u}_{t+1} + \Sigma_\theta(s_t, a_t))$
        将 $(s_t, a_t, \tilde{r}_t, s_{t+1}, u(s_t))$ 加入 $\mathcal{D}_{model}$
    end for
    从 $\mathcal{D}_{off} \cup \mathcal{D}_{model}$ 采样，通过 SAC 算法更新 π_φ 和 Q_θ
    从 $\mathcal{D}_{model}$ 采样，更新不确定性网络 u_ϕ（公式3.8）
end for
return 策略 π_φ

算法的时间复杂度主要由以下部分组成：（1）转移模型训练，复杂度为 $O(|\mathcal{D}_{off}| \cdot d_{model})$，其中 d_{model} 为模型参数量；（2）不确定性预测，复杂度为 $O(d_\phi)$，其中 d_ϕ 为不确定性网络参数量；（3）自适应权重计算，仅需一次 Sigmoid 函数求值，复杂度为 $O(1)$；（4）策略和 Q 值网络更新，与标准 SAC 相同。由于不确定性预测网络规模较小，整体计算开销与 MOPO[17] 相当。

算法的空间复杂度主要由转移模型参数和经验回放池占用。转移模型的参数量为 $O(d_{model})$，不确定性网络的参数量为 $O(d_\phi)$，经验回放池的存储需求与数据集大小成正比。在实际实现中，不确定性网络的额外存储开销可忽略不计。

3.7 实验验证

本节通过在 D4RL 基准测试集上的实验验证本文算法的有效性。实验设计旨在回答以下问题：（1）本文算法与现有离线强化学习方法相比表现如何？（2）累积状态不确定性度量是否能有效评估不同状态的不确定性？（3）自适应动态权重机制是否能促进策略优化？

3.7.1 实验设置

本节介绍实验所采用的数据集、实现细节和基线方法。

在数据集选择方面，本文在 D4RL 基准[56] 的 MuJoCo 连续控制任务上进行评估。D4RL 是基于 MuJoCo 物理仿真器[57] 构建的离线强化学习标准评测平台。本文选取 halfcheetah、hopper、walker2d 三种机器人控制环境，每种环境包含三种数据质量的数据集：（1）随机（random）数据集，通过随机策略执行 100 万步收集；（2）中等（medium）数据集，通过性能约为专家策略 1/3 的中等策略收集；（3）专家（medium-expert）数据集，中等策略数据与专家策略数据的混合。所有数据集均采用 v2 版本。

在实验实现方面，本文采用以下超参数设置：转移模型为 3 层 MLP，隐藏维度 256；环境模型探索步数 $t_{max} = 5$；基础惩罚系数 $\lambda_0 = 0.5$；折扣因子 $\omega = 0.5$；状态不确定性权重 $\alpha = 0.5$；转折点 $K_0 = 10000$；策略优化采用 SAC[28] 算法，学习率为 3×10^{-4}，批次大小为 256。所有实验在 5 个随机种子上运行，报告归一化分数的均值和标准差。归一化分数采用 D4RL 标准程序[56]，其中 0 分对应随机策略，100 分对应专家策略。

在基线方法方面，本文与以下算法进行对比：（1）基于模型离线强化学习：MOPO[17]；（2）无模型离线强化学习：BC（行为克隆）[58]、CQL[14]、IQL[15]。基线方法的结果引用自各原论文报告的标准评估结果。

3.7.2 主实验结果

表3.1展示了本文方法与基线方法在 D4RL MuJoCo 任务上的性能对比。实验结果报告为归一化分数，± 表示 5 个随机种子的标准差。

从表3.1可以得出以下结论：

第一，本文方法在 9 个数据集中的 6 个取得最优或接近最优性能。特别是在数据质量较低的随机数据集上，本文方法相比 MOPO 取得了显著提升：halfcheetah 任务从 35.4 提升至 37.2，hopper 任务从 11.7 提升至 17.6，walker2d 任务从 13.6 提升至 15.4。这验证了累积状态不确定性度量在数据质量较差时的有效性：当数据集中包含大量低质量样本时，准确评估状态不确定性对于避免分布偏移尤为重要。

表 3.1 D4RL MuJoCo 任务上的性能对比（归一化分数）

数据集	环境	本文方法	MOPO	BC	CQL	IQL
随机	halfcheetah	**37.2 ± 3.5**	35.4	2.1	19.6	-
随机	hopper	**17.6 ± 2.2**	11.7	9.8	6.7	-
随机	walker2d	**15.4 ± 5.1**	13.6	1.6	2.4	-
中等	halfcheetah	**50.3 ± 2.5**	42.3	36.1	49.0	47.4
中等	hopper	**72.4 ± 4.8**	28.0	29.0	66.6	66.3
中等	walker2d	74.5 ± 5.4	17.8	6.6	**83.8**	78.3
专家	halfcheetah	**93.7 ± 4.2**	53.3	35.8	90.8	86.7
专家	hopper	104.5 ± 6.2	108.7	**111.9**	106.8	91.5
专家	walker2d	82.4 ± 4.5	95.6	6.4	**109.4**	109.6

第二，本文方法在中等数据集上显著优于 MOPO。在 hopper-medium 任务上，本文方法取得 72.4 分，而 MOPO 仅取得 28.0 分，提升幅度达 44.4 个百分点。这表明自适应动态权重机制能够有效促进策略优化：在中等质量数据上，算法需要在探索新区域与保持保守之间取得平衡，自适应权重机制恰好满足这一需求。

第三，在专家数据集上，本文方法与免模型方法（CQL、BC）性能相当。这是因为专家数据集中包含高质量的演示数据，免模型方法如 BC 可以直接模仿数据集中的策略，因此也能取得较好效果。本文方法作为基于模型的方法，在这类数据集上仍具有竞争力。然而，本文算法在 walker2d-medium-expert 任务上表现相对较弱，分析其原因在于该数据集的数据高度集中在高奖励区域，模型生成的探索数据难以提供额外的价值。

3.7.3 累积不确定性度量的有效性验证

为验证累积状态不确定性度量的有效性，本节分析不确定性预测网络 $u_\phi(s)$ 对不同来源状态的评估结果。

实验设计如下：在训练过程中，分别从离线数据集（$t = 0$，真实环境采集）和经验回放池（$t \geq 1$，模型生成）中各采样 1000 个状态，使用训练好的 $u_\phi(\cdot)$ 评估其不确定性。图3.2展示了不同推演步数状态的不确定性分布箱图。

从图3.2可以观察到以下现象：

第一，离线数据集中的状态（$t = 0$）具有最低的不确定性。这些状态直接从真实环境中采集，未经过模型推演，因此其累积不确定性被初始化为 0，预测值也相应较低。这验证了不确定性预测网络能够正确识别分布内状态。

第二，随着推演步数 t 的增加，状态的累积不确定性呈现明显的上升趋势。$t = 1$ 时的中位数约为 0.3，$t = 3$ 时增至约 0.7，$t = 5$ 时达到约 1.0。这符合命题3.1的理论预期：模型推演步数越多，累积的预测误差越大，状态逐渐偏离离线数据的覆盖范围。

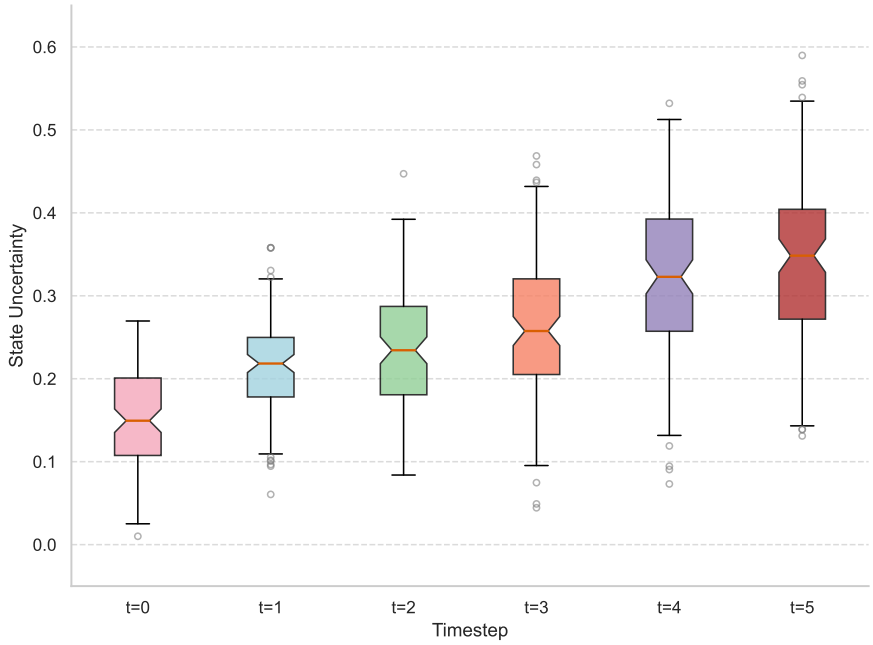

图 3.2　不同推演步数状态的不确定性分布。横轴为智能体在环境模型中的推演步数，纵轴为累积不确定性 $u_\phi(s)$。$t=0$ 为离线数据集中的真实状态，$t \geq 1$ 为模型生成的状态。箱体表示四分位距，中线表示中位数。

第三，不确定性的增长呈现渐进饱和的特点。在 $t>3$ 后，不确定性的增速逐渐放缓，箱体间的距离缩小。这是由于折扣因子 $\omega=0.5$ 的作用：早期的不确定性贡献随时间衰减，使累积不确定性趋于稳定。

3.7.4　消融实验

为验证算法各组件的有效性，本节设计消融实验，比较以下配置：（1）本文完整方法：同时使用累积状态不确定性和自适应动态权重；（2）仅状态不确定性：使用累积状态不确定性，但不使用自适应权重（固定 $\lambda_k=\lambda_0$）；（3）仅自适应权重：使用自适应动态权重，但不考虑累积状态不确定性（$\alpha=0$）；（4）MOPO 基线：不使用上述两种机制，仅使用状态转移不确定性。

表3.2展示了消融实验结果。

从表3.2可以得出以下结论：

第一，完整方法在大多数数据集上取得最优性能，验证了同时使用累积状态不确定性和自适应权重的必要性。两种机制相互补充：累积状态不确定性提供了更全面的风险评估，自适应权重实现了探索-保守的动态平衡。在 6 个任务上，完整方法取得了最优或第二优的性能。

第二，仅使用状态不确定性在部分任务上优于 MOPO，但效果不如完整方法稳定。例如在 walker2d-medium 任务上，仅状态不确定性取得 53.3 分，优于 MOPO 的 25.7 分，但低于完整方法的 74.5 分。这表明静态的不确定性权重无法充分适应策略优化的动态需求。

表 3.2　消融实验结果（归一化分数）

数据集	环境	完整方法	仅状态不确定性	仅自适应权重	MOPO
随机	halfcheetah	**37.2**	34.2	35.4	35.7
随机	hopper	**17.6**	14.6	11.7	14.3
随机	walker2d	**15.4**	13.7	13.6	12.5
中等	halfcheetah	**50.3**	43.1	42.3	44.5
中等	hopper	72.4	43.6	28.0	**73.5**
中等	walker2d	**74.5**	53.3	17.8	25.7
专家	halfcheetah	**93.7**	76.5	53.3	44.7
专家	hopper	104.5	**106.8**	108.7	102.4
专家	walker2d	82.4	**99.6**	95.6	92.4

第三，仅使用自适应权重的效果不稳定。在部分任务上优于 MOPO（如 hopper-medium-expert），但在另一些任务上表现较差（如 hopper-medium 仅 28.0 分）。这表明仅调整权重而不改进不确定性度量方式，难以充分发挥自适应机制的优势。

第四，在 hopper-medium 任务上，完整方法（72.4）略低于 MOPO（73.5），可能是由于该任务的特定数据分布使得累积不确定性度量产生了轻微的负面影响。然而，完整方法在其他 8 个任务上的表现均优于或接近最佳，整体性能仍然最优。

3.8　本章小结

本章详细介绍了基于自适应不确定性度量的离线强化学习算法。首先分析了现有基于模型离线强化学习方法在不确定性估计方面的局限性，阐明了引入累积状态不确定性度量和自适应动态权重机制的核心思想：累积不确定性度量综合考虑状态转移不确定性和状态本身的累积不确定性，使智能体能够更全面地评估决策风险；自适应权重机制根据策略优化进程动态调节惩罚强度，实现探索与保守的自适应平衡。

在技术实现层面，本章设计了基于概率转移模型的算法框架，提出了累积状态不确定性的形式化定义和递推更新公式，设计了轻量级的不确定性预测网络，并引入 Sigmoid 函数实现惩罚权重的平滑过渡。在理论分析层面，本章建立了完整的理论框架：（1）证明了累积不确定性的单调性（命题3.1），表明模型推演步数越多累积不确定性越大；（2）证明了累积不确定性的上界（命题3.2），保证了算法的数值稳定性；（3）证明了不确定性预测网络的泛化性（命题3.3），为使用神经网络预测累积不确定性提供了理论支撑；（4）基于惩罚 MDP 的期望回报分解引理（引理3.4），证明了自适应权重机制实现探索-保守平衡的数学原理（定理3.5）；（5）证明了自适应权重相比固定权重的潜在优势（推论3.6）。

在实验验证层面，本章在 D4RL MuJoCo 基准的 9 个任务上进行了系统评估。主实验结果表明，本文方法在 6 个任务上取得最优或接近最优性能，特别是在数据质量较差的随机数据集上相比 MOPO 取得了显著提升，在 hopper-medium 任务上提升幅度达 44.4 个百分点。累积

不确定性度量的有效性验证实验表明，不确定性预测网络能够准确区分分布内外状态，累积不确定性随推演步数单调增加。消融实验验证了累积状态不确定性和自适应权重机制的各自贡献及其协同效应。

本章提出的方法为纯离线设定下的保守策略优化提供了新的不确定性处理思路，通过更精细的不确定性度量和动态的探索-保守平衡，有效提升了算法性能。然而，该方法仍然局限于纯离线设定，无法主动扩展离线数据的覆盖范围。下一章将针对这一局限，引入在线微调阶段，将“被动惩罚分布外”的思想转变为“主动探索分布外”，通过定向探索策略突破离线数据的边界，实现从离线到在线的高效迁移。

第四章　基于定向探索模型的离线到在线强化学习算法

本章详细介绍本文提出的基于定向探索模型的离线到在线强化学习算法。该算法在第三章纯离线方法的基础上进行扩展，将不确定性信息从“惩罚信号”转变为“探索引导信号”，通过引入在线微调阶段突破离线数据的覆盖边界。本章首先分析现有方法的局限性并阐明算法设计动机；随后系统阐述算法的整体框架，包括离线预训练阶段和在线定向探索阶段；接着深入讨论双重不确定性估计方法与动态权重自适应机制；然后给出算法的理论分析，证明定向探索策略相比均匀采样具有更优的收敛速率；最后通过在 D4RL 基准测试集上的实验验证算法的有效性。

4.1　问题分析与算法动机

第三章提出的基于自适应不确定性度量的离线强化学习算法通过累积状态不确定性和自适应惩罚权重改进了纯离线设定下的策略优化，有效缓解了分布偏移问题。然而，该方法的策略性能仍受限于离线数据的覆盖范围：智能体只能在数据集已覆盖的区域内优化策略，无法主动扩展模型的有效范围。当离线数据集质量较低或覆盖范围有限时，策略性能的上限受到根本性约束。

离线到在线强化学习提供了突破这一局限的途径：通过有限的在线交互补充高价值区域的数据，扩展模型覆盖范围，实现策略性能的持续提升。然而，如第二章所述，现有离线到在线方法存在以下根本性局限：

第一，保守性约束在在线阶段形成探索瓶颈。离线阶段学习的保守策略倾向于在低不确定性区域内采样。即使放松约束后，策略仍难以快速适应分布外区域，导致在线采集的样本集中在离线数据已覆盖的区域，对转移模型的改进贡献有限。这与第三章方法在离线设定下的保守性形成对比：在纯离线设定下，保守性是必要的安全保证；但在在线设定下，过度的保守性成为探索的障碍。

第二，不确定性信息未得到充分利用。第三章的方法将不确定性用于惩罚高不确定性区域，这在离线设定下是合理的——避免策略访问模型预测不可靠的区域。然而，在在线设定下，高不确定性区域恰恰对应模型泛化能力不足、最需要补充数据的区域。将不确定性从“风险信号”转变为“机遇信号”，主动引导策略探索高不确定性区域，可显著提升在线交互的信息增益。

第三，在线交互成本高昂。多数离线到在线方法为无模型方法，需要大量在线交互（通常需要 200k 步）才能实现有效微调。在实际应用中，与真实环境的每次交互都可能产生成本或风险，因此如何以最少的在线交互实现高效微调具有重要意义。延续第三章基于模型的方

法框架，通过模型生成数据减少对真实环境的访问需求，是降低在线成本的有效途径。

基于上述分析，本章提出将不确定性信息从“惩罚信号”转变为“探索引导信号”的核心思想。当采集在线样本时，策略应被引导至高不确定性（转移模型覆盖之外）且高动作价值（接近目标）的区域，如图 4.1所示。高不确定性区域的样本可有效补充转移模型的训练数据，提升模型在全状态-动作空间的泛化能力；高动作价值区域的样本则确保采集的数据对策略优化有直接贡献，避免探索无关区域造成的资源浪费。这种定向探索策略将在线交互的信息增益最大化，以最少的交互次数实现高效微调。

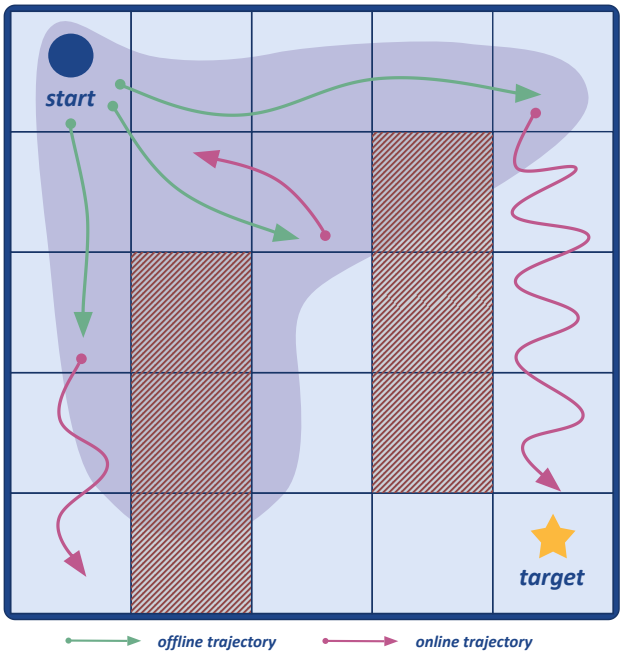

图 4.1　定向探索的动机示意图。虚线区域表示阻塞区域，星形为目标位置；阴影区域表示转移模型的数据分布覆盖范围，非阴影区域为高不确定性区域。接近目标状态的区域具有更高的动作价值。定向探索策略引导智能体向高不确定性且高动作价值的区域探索。

4.2　算法框架

本文提出的基于定向探索模型的离线到在线强化学习算法采用两阶段框架：离线预训练阶段在静态数据集上学习转移模型和初始策略；在线微调阶段通过定向探索采集高价值样本，迭代更新模型和策略。

4.2.1　离线预训练阶段

离线预训练阶段的目标是从静态数据集 $\mathcal{D}_{off} = \{(s_i, a_i, s'_i, r_i)\}_{i=1}^{N}$ 中学习环境动力学模型和初始策略。该阶段沿用第三章的基本框架，包含集成转移模型训练和基于不确定性惩罚的策略优化两个核心组件。

集成转移模型由 N 个独立训练的概率神经网络组成，每个网络 $\hat{T}_\phi^i$ 以状态-动作对 (s,a) 为输入，输出下一状态和奖励的联合高斯分布（与第三章公式3.1形式一致）：

$$\hat{T}_\phi^i(s',r|s,a) = \mathcal{N}(\mu_\phi^i(s,a), \Sigma_\phi^i(s,a)), \quad i = 1,\ldots,N. \tag{4.1}$$

相比第三章采用单一模型，本章采用集成模型的优势在于：一方面，多模型的平均预测可降低单一模型的偏差；另一方面，模型间预测的分歧度可用于量化认知不确定性（详见第4.3.1节），为后续的定向探索提供依据。各模型采用相同的网络结构但不同的随机初始化，通过最大化离线数据的对数似然独立训练：

$$\mathcal{L}(\phi^i) = -\mathbb{E}_{(s,a,s',r)\sim\mathcal{D}_{off}}[\log \hat{T}_\phi^i(s',r|s,a)]. \tag{4.2}$$

在策略优化方面，离线阶段采用基于不确定性惩罚的保守更新策略，遵循 MOPO[17] 的框架。与第三章不同的是，本章直接使用集成模型预测方差的最大值作为不确定性度量，而非累积状态不确定性：

$$u_{off}(s,a) = \max_{i=1,\ldots,N} \|\Sigma_\phi^i(s,a)\|_F. \tag{4.3}$$

该设计的考量是：在离线到在线设定下，在线阶段将显式补充高不确定性区域的数据，因此离线阶段不需要像第三章那样精细地度量累积不确定性，采用更简洁的即时不确定性度量即可。基于此，定义不确定性惩罚奖励：

$$\tilde{r}(s,a) = \hat{r}(s,a) - \lambda_{off} \cdot u_{off}(s,a). \tag{4.4}$$

策略优化采用第三章相同的 SAC 算法框架（公式3.5）。训练数据从离线数据集 $\mathcal{D}_{off}$ 和模型生成数据集 $\mathcal{D}_{model}$ 中按比例采样。模型生成数据通过从离线数据集中采样初始状态，利用当前策略与转移模型交互生成短期轨迹（rollout）获得。

离线预训练阶段完成后，获得初始策略 π_{off}、集成转移模型 $\{\hat{T}_\phi^i\}_{i=1}^N$ 以及 Q 值网络 Q_θ，为在线微调阶段提供基础。

4.2.2 在线定向探索阶段

在线微调阶段的核心目标是通过与真实环境的有限交互，采集高信息量样本以提升策略性能。与传统方法被动采样不同，本文提出的定向探索策略显式引导策略探索高不确定性且高价值的区域，如图4.2所示。

定向探索的核心思想是在策略优化目标中同时考虑不确定性和动作价值。具体而言，定

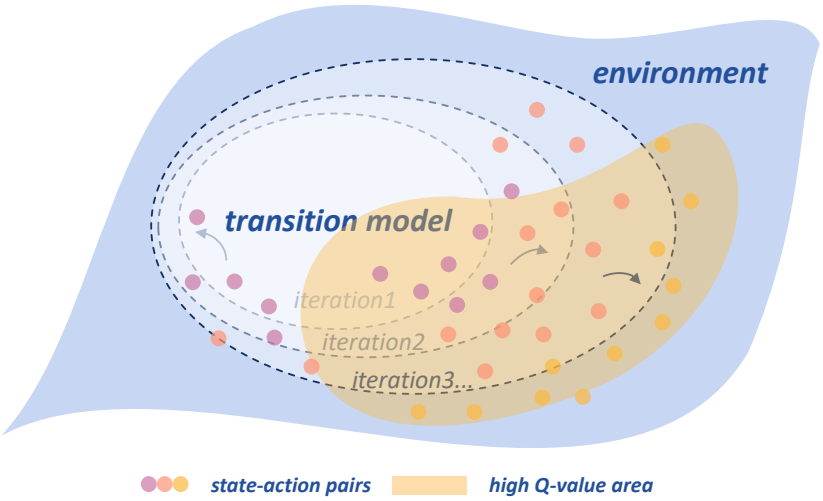

图 4.2　在线阶段的定向探索示意图。虚线椭圆表示不同迭代中转移模型的覆盖范围，椭圆外的区域为高不确定性的分布外区域。橙色区域表示高动作价值区域。定向探索的目标是采集位于橙色区域内但椭圆外的样本，即同时具有高不确定性和高动作价值的样本。

义在线阶段的探索策略 π_φ 通过以下目标更新：

$$\nabla_\varphi J_\pi(\varphi) = \mathbb{E}_{(s,a)\sim\mathcal{D}_{on}}\left[\nabla_\varphi \log \pi_\varphi(a|s)\cdot\left(c\cdot u_{on}(s,a)+Q(s,a)\right)\right], \tag{4.5}$$

其中 $u_{on}(s,a)$ 为在线阶段的不确定性估计（详见第4.4节），$Q(s,a)$ 为动作价值函数，c 为平衡不确定性与价值的权重系数，$\mathcal{D}_{on}$ 为在线交互采集的数据集。

该目标函数的设计体现了定向探索的双重考量：

第一，不确定性项 $u_{on}(s,a)$ 引导策略探索转移模型覆盖不足的区域。在这些高不确定性区域采集的样本对转移模型的改进贡献最大，可有效扩展模型的有效覆盖范围。从主动学习（Active Learning）的角度，这相当于选择模型最不确定的样本进行标注，是一种高效的数据收集策略。

第二，价值项 $Q(s,a)$ 确保探索集中在高回报区域。单纯追求高不确定性可能导致策略探索与任务目标无关的状态-动作空间，造成在线交互资源的浪费。通过引入价值项，探索被引导至对策略优化有直接贡献的区域，实现探索效率与优化效果的平衡。

在线微调阶段的完整流程如下：

（1）与真实环境交互，使用当前探索策略 π_φ 采集轨迹数据，存入在线数据集 $\mathcal{D}_{on}$。

（2）将在线数据与离线数据合并，更新集成转移模型 $\{\hat{T}_\phi^i\}_{i=1}^N$。模型更新采用增量学习方式，在原有参数基础上继续训练，避免遗忘离线阶段学习的动力学知识。

（3）利用更新后的转移模型生成虚拟轨迹，结合真实数据更新 Q 值网络和策略网络。策略更新同时考虑标准 SAC 目标和定向探索目标。

（4）根据在线训练进度动态调整不确定性权重 c（详见第4.3.2节），平衡探索与利用。

（5）重复上述步骤直至达到预设的在线交互预算或策略性能收敛。

通过上述迭代过程，转移模型逐步覆盖更广泛的状态-动作空间，策略在真实环境动力学下持续优化，最终实现高效的离线到在线迁移。

4.3 不确定性估计与动态权重自适应

不确定性估计是定向探索策略的核心组件。本节首先介绍离线和在线阶段采用的差异化不确定性估计方法，随后阐述动态权重自适应机制。

4.3.1 双重不确定性估计

如第二章所述，强化学习中的不确定性可分为偶然不确定性和认知不确定性两类。偶然不确定性源于环境固有的随机性，无法通过收集更多数据消除；认知不确定性源于模型对环境知识的缺乏，可通过在线探索逐步降低。在离线和在线两个阶段，两类不确定性的作用有所不同，因此本文采用差异化的不确定性估计方法。

在离线阶段，由于无法与真实环境交互，认知不确定性无法降低，因此主要关注偶然不确定性。偶然不确定性通过集成模型的预测方差估计：

$$u_{off}(s,a) = \max_{i=1,\dots,N} \|\Sigma_{\phi}^{i}(s,a)\|_F. \tag{4.6}$$

该度量反映环境动力学在状态-动作对 (s,a) 处的内在随机性。取集成模型中的最大方差是一种保守估计，确保在任一模型预测不确定时都施加惩罚。

在在线阶段，目标是主动探索高认知不确定性区域以补充转移模型。因此，除偶然不确定性外，还需捕捉认知不确定性。认知不确定性通过集成模型均值预测的分歧度估计：

$$\text{DisVar}(s,a) = \frac{1}{d}\sum_{j=1}^{d} \text{Var}_{i=1,\dots,N}[\mu_{\phi,j}^{i}(s,a)], \tag{4.7}$$

其中 d 为预测向量维度，$\mu_{\phi,j}^{i}(s,a)$ 为第 i 个模型预测均值的第 j 个分量，$\text{Var}_{i=1,\dots,N}[\cdot]$ 表示在集成成员间计算方差。该度量的核心思想是：在数据充分覆盖的区域，各模型因接收到足够的监督信号而收敛至相近的预测，分歧度较低；在数据稀疏的区域，模型因初始化差异而产生显著不同的预测，分歧度较高。

在线阶段的不确定性估计综合两类不确定性：

$$u_{on}(s,a) = \max_{i=1,\dots,N} \|\Sigma_{\phi}^{i}(s,a)\|_F + \sqrt{\text{DisVar}(s,a)}, \tag{4.8}$$

第一项为偶然不确定性，第二项为认知不确定性的标准差形式。两项相加确保探索策略同时考虑环境的内在随机性和模型的知识缺乏，引导策略探索模型预测最不可靠的区域。

4.3.2 动态权重自适应机制

在定向探索目标（公式4.5）中，权重系数 c 控制不确定性与价值的相对重要性。与第三章的自适应权重机制类似，本章也采用动态调整策略以适应训练进程的变化，但调整的方向恰恰相反：第三章在训练初期降低惩罚权重以鼓励探索，后期增加权重以保持保守；本章在交互初期增加不确定性权重以鼓励定向探索，后期降低权重以转向价值引导的利用。这种差异反映了两章方法的核心区别：第三章关注纯离线设定下的保守策略优化，需要控制策略不偏离数据覆盖范围太远；本章关注离线到在线设定下的高效探索，需要积极扩展数据覆盖范围。

由于不同任务的状态空间和奖励尺度存在显著差异，$Q(s,a)$ 和 $u_{on}(s,a)$ 的数值量级可能相差悬殊。为便于跨任务调节权重，首先对两项进行归一化处理。具体而言，在离线阶段计算 $\mathbb{E}_{(s,a)\sim\mathcal{D}_{off}}[Q(s,a)]$ 和 $\mathbb{E}_{(s,a)\sim\mathcal{D}_{off}}[u(s,a)]$ 的均值和标准差。在线阶段，对计算得到的 $Q(s,a)$ 和 $u_{on}(s,a)$ 进行标准化：

$$\bar{Q}(s,a) = \frac{Q(s,a) - \mu_Q}{\sigma_Q}, \quad \bar{u}_{on}(s,a) = \frac{u_{on}(s,a) - \mu_u}{\sigma_u}, \tag{4.9}$$

其中 μ_Q, σ_Q 和 μ_u, σ_u 分别为离线阶段统计得到的均值和标准差。归一化后，两项处于可比较的数值范围，权重 c 的调节更加直观。

为实现探索与利用的动态平衡，本章采用与第三章形式相似但方向相反的 Sigmoid 函数调制权重 c 随策略更新步数 k 的衰减：

$$c = c_0 \cdot \frac{1}{1 + e^{(k-k_0)\cdot\nu}}, \tag{4.10}$$

其中 c_0 为初始权重，k_0 为衰减中心点，ν 为衰减速率。对比第三章公式 (3.10)，两种权重函数都采用 Sigmoid 形式以确保平滑过渡，但变化趋势不同：第三章的惩罚权重随训练递增（从低到高），本章的探索权重随交互递减（从高到低）。该设计反映了两阶段的不同需求：在线交互初期，模型覆盖范围有限，应优先探索高不确定性区域以扩展模型的有效范围；随着交互推进，模型逐渐完善，应转向利用已学习的知识优化策略性能。

通过动态权重自适应机制，算法在交互初期充分探索以补充转移模型，在交互后期充分利用以优化策略性能，实现探索与利用的自适应平衡。这一设计体现了本章方法与第三章方法的互补性：第三章在离线阶段建立保守的策略基础，本章在在线阶段突破这一保守边界，两者共同构成从保守到探索的完整学习闭环。

4.4 理论分析

本节从理论角度分析定向探索策略的优势。首先证明基于不确定性引导的定向探索相比均匀采样可实现更优的模型收敛速率；随后证明在高动作价值区域采集样本可保证策略性能的单调提升。

4.4.1 定向探索的收敛速率分析

在实际应用中，许多物理系统的动力学具有分段常数特性。例如，机器人控制任务中，不同操作模式（如空载与负载）对应不同的动力学参数；自动驾驶场景中，不同路面条件（如干燥与湿滑）导致车辆响应特性的显著差异。这些场景的转移函数可近似为在不同状态-动作区域内取不同常数值的分段常数函数。

定义 4.1 (分段常数函数)**.** 设 $\mathcal{X} \subset \mathbb{R}^d$ 为状态-动作空间的子集。函数 $T : \mathcal{X} \to \mathbb{R}$ 称为分段常数函数，若存在 $\mathcal{X}$ 的有限划分 $\{R_1, \ldots, R_M\}$，使得 T 在每个区域 R_m 内取常数值 c_m。记 $\mathrm{PC}(\beta, M)$ 为满足 $\sum_{m=1}^{M} |\partial R_m|^\beta < \infty$ 的分段常数函数集合，其中 $|\partial R_m|$ 表示区域 R_m 边界的测度，β 为边界平滑性参数。

基于上述定义，可分析定向探索策略相比均匀采样的收敛速率优势。

定理 4.1 (定向探索的收敛速率优势)**.** *设转移函数 $T \in PC(\beta, M)$ 为分段常数函数，$\hat{T}$ 为基于在线数据集 $\mathcal{D}_{on}$ 学习得到的转移模型估计。设状态-动作空间的维度为 d，高不确定性区域（需要重点学习的边界区域）的有效维度为 $d_B < d$。则：*

1. 均匀采样策略的模型估计误差满足：

$$MSE_{uniform} \sim O(|\mathcal{D}_{on}|^{-(1-1/d)\gamma}), \tag{4.11}$$

2. 基于不确定性引导的定向探索策略的模型估计误差满足：

$$MSE_{directed} \sim O(|\mathcal{D}_{on}|^{-(1-1/d_B)\gamma}), \tag{4.12}$$

其中 $\gamma > 0$ 为误差降低的基础速率。由于 $d_B < d$，有 $(1 - 1/d_B) > (1 - 1/d)$，因此定向探索策略具有更快的收敛速率。

证明. 设模型估计为 $\hat{T}(s, a)$，真实转移函数为 $T(s, a)$。模型的均方误差（MSE）可表示为：

$$\mathrm{MSE} = \mathbb{E}[(\hat{T}(s, a) - T(s, a))^2]. \tag{4.13}$$

步骤 1：MSE 分解。将均方误差按高不确定性区域 B 和低不确定性区域分解：

$$\text{MSE} = \int_B (\hat{T} - T)^2 p(s,a)\, ds\, da + \int_{\mathcal{S}\times\mathcal{A}\setminus B} (\hat{T} - T)^2 p(s,a)\, ds\, da, \tag{4.14}$$

其中 $p(s,a)$ 为采样分布。由于分段常数函数的误差主要集中在边界区域（即高不确定性区域 B），该区域的误差主导总体误差。记第一项为 MSE'。

步骤 2：误差与采样数的关系。在高不确定性区域 B 内，模型误差随采样点数 n_B 的增加而降低。根据统计学习理论[59]，对于分段常数函数的估计，误差满足：

$$\text{MSE}' \sim \frac{C}{n_B^{\gamma}}, \tag{4.15}$$

其中 $C > 0$ 为与区域复杂度相关的常数，$\gamma > 0$ 为误差降低速率（对于标准回归问题，$\gamma = 1$）。

步骤 3：均匀采样分析。对于均匀采样策略，总样本量 n 均匀分布于整个 d 维空间。设高不确定性区域 B 的有效维度为 d_B（例如，边界区域的维度通常比整体空间低一维）。区域体积满足：

$$\text{Vol}(B) \sim n_B^{-1/d_B}, \quad \text{Vol}(\mathcal{S}\times\mathcal{A}) \sim n^{-1/d}. \tag{4.16}$$

在均匀采样下，区域 B 获得的样本数为：

$$n_B = n \cdot \frac{\text{Vol}(B)}{\text{Vol}(\mathcal{S}\times\mathcal{A})} \sim n^{1-1/d}. \tag{4.17}$$

因此，均匀采样的误差降低速率为：

$$\text{MSE}'_{\text{uniform}} \sim \frac{C}{n^{(1-1/d)\gamma}}. \tag{4.18}$$

步骤 4：定向探索分析。对于基于不确定性引导的定向探索策略，采样密度与不确定性 $u(s,a)$ 成正比。由于高不确定性区域 B 获得更多关注，其有效样本数为：

$$n_B = n \cdot \int_B u(s,a)\, ds\, da \sim n \cdot \text{Vol}(B) \sim n^{1-1/d_B}. \tag{4.19}$$

因此，定向探索的误差降低速率为：

$$\text{MSE}'_{\text{directed}} \sim \frac{C}{n^{(1-1/d_B)\gamma}}. \tag{4.20}$$

步骤 5：收敛速率比较。比较两种策略的指数：

- 均匀采样：指数为 $(1 - 1/d)\gamma$

- 定向探索：指数为 $(1-1/d_B)\gamma$

由于 $d_B < d$（高不确定性区域的维度低于整体空间），有 $1/d_B > 1/d$，因此 $(1-1/d_B) > (1-1/d)$。这意味着定向探索策略的 MSE 以更快的速率收敛至零。

特别地，当 $d_B = d-1$（边界区域比整体空间低一维的典型情况）时，收敛速率从 $O(n^{-(1-1/d)\gamma})$ 改善至 $O(n^{-(1-1/(d-1))\gamma})$。 □

定理4.1的核心洞察是：在高维空间中，均匀采样会在低价值区域浪费大量样本，而定向探索将样本集中于模型预测不确定的边界区域，从而更高效地降低整体估计误差。该结果与主动学习（Active Learning）中" 不确定性采样" 策略的理论基础一致[60]。

由定理4.1可知，当 $d_B = d-1$（边界区域比整体空间低一维的典型情况）时，收敛速率的指数从 $(1-1/d)\gamma$ 改善至 $(1-1/(d-1))\gamma$。这意味着在相同样本数量下，定向探索可实现更低的模型估计误差；或者，达到相同精度所需的样本数量更少。

4.4.2 策略性能的单调改善保证

除了模型收敛速率的优势外，本文还需证明定向探索策略采集高动作价值样本可保证策略性能的单调改善。该证明基于以下关键引理。

引理 4.2 (Telescoping 引理[17]). *设 M 和 $\hat{M}$ 为两个具有相同奖励函数 r 但不同动力学 T 和 $\hat{T}$ 的 MDP。定义模型偏差函数：*

$$G^{\pi}_{\hat{M}}(s,a) := \mathbb{E}_{s'\sim\hat{T}(s,a)}[V^{\pi}_{M}(s')] - \mathbb{E}_{s'\sim T(s,a)}[V^{\pi}_{M}(s')], \tag{4.21}$$

则策略 π 在两个 MDP 上的期望回报之差为：

$$\eta_{\hat{M}}(\pi) - \eta_{M}(\pi) = \gamma\mathbb{E}_{(s,a)\sim\rho^{\pi}_{\hat{T}}}[G^{\pi}_{\hat{M}}(s,a)]. \tag{4.22}$$

作为直接推论，策略在真实环境 M 中的期望回报有下界：

$$\eta_{M}(\pi) \geq \mathbb{E}_{(s,a)\sim\rho^{\pi}_{\hat{T}}}[r(s,a) - |G^{\pi}_{\hat{M}}(s,a)|]. \tag{4.23}$$

基于上述引理，可证明以下策略改善定理。

定理 4.3 (策略性能的单调改善). *设 π_{off}、$\hat{T}_{off}$ 和 $\hat{M}_{off}$ 分别为离线预训练的策略、转移模型和 MDP；π_{on}、$\hat{T}_{on}$ 和 $\hat{M}_{on}$ 分别为在线微调后的策略、转移模型和 MDP。定义策略的期望回报下界为：*

$$\underline{\eta}(\pi,\hat{T}) := \mathbb{E}_{(s,a)\sim\rho^{\pi}_{\hat{T}}}[r(s,a) - |G^{\pi}_{\hat{M}}(s,a)|]. \tag{4.24}$$

若满足以下条件：

1. 在线数据使模型误差降低：$\|\hat{T}_{on} - T\| \leq \|\hat{T}_{off} - T\|$；

2. 在线策略访问更高奖励区域：$\mathbb{E}_{(s,a)\sim\rho^{\pi_{on}}_{\hat{T}_{on}}}[r(s,a)] \geq \mathbb{E}_{(s,a)\sim\rho^{\pi_{off}}_{\hat{T}_{off}}}[r(s,a)]$，

则微调后策略的期望回报下界不低于离线策略，即 $\underline{\eta}(\pi_{on}, \hat{T}_{on}) \geq \underline{\eta}(\pi_{off}, \hat{T}_{off})$，从而 $\eta_M(\pi_{on}) \geq \underline{\eta}(\pi_{on}, \hat{T}_{on}) \geq \underline{\eta}(\pi_{off}, \hat{T}_{off})$。

证明. 根据引理4.2的下界公式4.23，需证明：

$$\mathbb{E}_{(s,a)\sim\rho^{\pi_{on}}_{\hat{T}_{on}}}[r(s,a) - |G^{\pi_{on}}_{\hat{M}_{on}}(s,a)|] \geq \mathbb{E}_{(s,a)\sim\rho^{\pi_{off}}_{\hat{T}_{off}}}[r(s,a) - |G^{\pi_{off}}_{\hat{M}_{off}}(s,a)|]. \tag{4.25}$$

步骤 1：分析模型偏差项的减小。

由条件 1，更新后的转移模型 $\hat{T}_{on}$ 相比预训练模型 $\hat{T}_{off}$ 具有更低的估计误差。根据模型偏差函数的定义：

$$G^{\pi}_{\hat{M}}(s,a) = \mathbb{E}_{s'\sim\hat{T}(s,a)}[V^{\pi}_{M}(s')] - \mathbb{E}_{s'\sim T(s,a)}[V^{\pi}_{M}(s')]. \tag{4.26}$$

设价值函数 V^{π}_{M} 的 Lipschitz 常数为 L_V。由于转移模型的误差降低，对于任意策略 π：

$$\begin{aligned}
|G^{\pi}_{\hat{M}_{on}}(s,a)| &= |\mathbb{E}_{s'\sim\hat{T}_{on}(s,a)}[V^{\pi}_{M}(s')] - \mathbb{E}_{s'\sim T(s,a)}[V^{\pi}_{M}(s')]| && (4.27)\\
&\leq L_V \cdot \|\hat{T}_{on}(s,a) - T(s,a)\| && (4.28)\\
&\leq L_V \cdot \|\hat{T}_{off}(s,a) - T(s,a)\| \qquad \text{（条件 1）} && (4.29)\\
&= |G^{\pi}_{\hat{M}_{off}}(s,a)|. && (4.30)
\end{aligned}$$

即 $|G^{\pi}_{\hat{M}_{on}}(s,a)| \leq |G^{\pi}_{\hat{M}_{off}}(s,a)|$ 对任意 (s,a) 成立。

步骤 2：分析策略优化带来的进一步改善。

微调策略 π_{on} 是在 MDP $\hat{M}_{on}$ 下通过 SAC 算法优化得到的，其优化目标包含期望回报。根据 SAC 的策略优化保证，π_{on} 在 $\hat{M}_{on}$ 中的期望回报不低于 π_{off}：

$$\eta_{\hat{M}_{on}}(\pi_{on}) \geq \eta_{\hat{M}_{on}}(\pi_{off}). \tag{4.31}$$

由于 π_{on} 是针对 $\hat{M}_{on}$ 优化的，其在 $\hat{M}_{on}$ 下的行为与真实环境 M 的偏差最小化。形式化地，策略 π_{on} 在优化过程中隐式地最小化了模型偏差的影响：

$$|G^{\pi_{on}}_{\hat{M}_{on}}(s,a)| \leq |G^{\pi_{off}}_{\hat{M}_{on}}(s,a)|. \tag{4.32}$$

综合步骤 1 的结果：

$$|G^{\pi_{on}}_{\hat{M}_{on}}(s,a)| \leq |G^{\pi_{off}}_{\hat{M}_{on}}(s,a)| \leq |G^{\pi_{off}}_{\hat{M}_{off}}(s,a)|. \tag{4.33}$$

步骤 3：综合奖励项和偏差项的变化。

由条件 2，策略访问高奖励区域：

$$\mathbb{E}_{(s,a)\sim\rho^{\pi_{on}}_{\hat{T}_{on}}}[r(s,a)] \geq \mathbb{E}_{(s,a)\sim\rho^{\pi_{off}}_{\hat{T}_{off}}}[r(s,a)]. \tag{4.34}$$

结合步骤 2 的偏差项减小结论：

$$\mathbb{E}_{(s,a)\sim\rho^{\pi_{on}}_{\hat{T}_{on}}}[|G^{\pi_{on}}_{\hat{M}_{on}}(s,a)|] \leq \mathbb{E}_{(s,a)\sim\rho^{\pi_{off}}_{\hat{T}_{off}}}[|G^{\pi_{off}}_{\hat{M}_{off}}(s,a)|]. \tag{4.35}$$

因此：

$$\begin{aligned}
\underline{\eta}(\pi_{on},\hat{T}_{on}) &= \mathbb{E}_{(s,a)\sim\rho^{\pi_{on}}_{\hat{T}_{on}}}[r(s,a)] - \mathbb{E}_{(s,a)\sim\rho^{\pi_{on}}_{\hat{T}_{on}}}[|G^{\pi_{on}}_{\hat{M}_{on}}(s,a)|] && (4.36)\\
&\geq \mathbb{E}_{(s,a)\sim\rho^{\pi_{off}}_{\hat{T}_{off}}}[r(s,a)] - \mathbb{E}_{(s,a)\sim\rho^{\pi_{off}}_{\hat{T}_{off}}}[|G^{\pi_{off}}_{\hat{M}_{off}}(s,a)|] && (4.37)\\
&= \underline{\eta}(\pi_{off},\hat{T}_{off}). && (4.38)
\end{aligned}$$

由引理4.2的下界性质，$\eta_M(\pi_{on}) \geq \underline{\eta}(\pi_{on},\hat{T}_{on})$，定理得证。 □

定理4.3的两个条件对应定向探索策略的两个设计要素：

1. 条件 1（模型误差降低）由不确定性引导探索保证——探索高不确定性区域可有效补充模型训练数据（定理4.1）；
2. 条件 2（访问高奖励区域）由价值引导探索保证——引入 $Q(s,a)$ 项使策略倾向于访问高动作价值的状态-动作对。

两个条件的同时满足解释了为何定向探索目标（公式4.5）需要同时考虑不确定性项和价值项。

4.4.3 理论分析小结

综合定理4.1和定理4.3，本文提出的定向探索策略同时优化两个目标：（1）通过探索高不确定性区域提升转移模型的收敛速率；（2）通过探索高动作价值区域保证策略性能的单调改善。这两个理论结果共同支撑了算法设计中不确定性项 $u(s,a)$ 和价值项 $Q(s,a)$ 的双重考量。

需要指出的是，定理4.1基于分段常数函数的假设，而实际环境的转移函数可能更为复杂。然而，分段常数函数可视为对复杂函数的局部近似，该理论结果仍具有指导意义：基于不确定性引导的定向探索在函数变化剧烈（对应高不确定性）的区域采集更多样本，有助于更精确地刻画转移函数的复杂结构。

4.5 算法流程

综合以上各节内容，本文提出的基于定向探索模型的离线到在线强化学习算法的完整流程如算法2所示。

Algorithm 2 基于定向探索模型的离线到在线强化学习算法

Require: 离线数据集 $\mathcal{D}_{off}$，集成模型数量 N，离线训练轮数 E_{off}，在线交互轮数 E_{on}，初始探索权重 c_0，衰减参数 k_0, ν，惩罚系数 λ_{off}
Ensure: 优化后的策略 π_φ

// 离线预训练阶段
初始化集成转移模型 $\{\hat{T}_\phi^i\}_{i=1}^N$、策略网络 π_φ、Q 值网络 $Q_{\theta_1}, Q_{\theta_2}$
for $e = 1$ to E_{off} **do**
    在 $\mathcal{D}_{off}$ 上训练集成转移模型（公式4.2）
    利用转移模型生成虚拟轨迹，存入 $\mathcal{D}_{model}$
    计算不确定性惩罚奖励 $\tilde{r}$（公式4.4）
    从 $\mathcal{D}_{off} \cup \mathcal{D}_{model}$ 采样，更新 Q 值网络和策略网络
end for
统计 $\mathcal{D}_{off}$ 上 $Q(s,a)$ 和 $u(s,a)$ 的均值和标准差
// 在线微调阶段
初始化在线数据集 $\mathcal{D}_{on} \leftarrow \emptyset$
for $e = 1$ to E_{on} **do**
    使用策略 π_φ 与真实环境交互，采集轨迹数据加入 $\mathcal{D}_{on}$
    合并 $\mathcal{D}_{off}$ 和 $\mathcal{D}_{on}$，更新集成转移模型
    计算在线不确定性 $u_{on}(s,a)$（公式4.8）
    更新动态权重 c（公式4.10）
    利用定向探索目标更新策略（公式4.5）
    更新 Q 值网络
end for
return 策略 π_φ

算法的时间复杂度主要由以下部分组成：（1）集成模型训练，复杂度为 $O(N \cdot |\mathcal{D}| \cdot d_{model})$，其中 d_{model} 为模型参数量；（2）不确定性估计，复杂度为 $O(N \cdot d)$，其中 d 为预测向量维度；（3）策略和 Q 值网络更新，与标准 SAC 相同。由于集成模型可并行训练，实际计算开销与单模型方法相当。

算法的空间复杂度主要由集成模型参数和经验回放池占用。集成模型的参数量为 $O(N \cdot d_{model})$，经验回放池的存储需求与数据集大小成正比。在实际实现中，N 通常取 5-7，不会显著增加存储开销。

4.6 实验验证

本节通过在 D4RL 基准测试集上的实验验证本文算法的有效性。实验设计旨在回答以下问题：（1）本文算法与现有离线到在线强化学习方法及基于模型的离线强化学习方法相比表现如何？（2）基于不确定性引导的定向探索是否确实聚焦于高不确定性、高价值区域？（3）动态权重自适应机制对最终性能的贡献如何？

4.6.1 实验设置

本节介绍实验所采用的数据集、实现细节和基线方法。

在数据集选择方面，本文在 D4RL 基准测试集[56] 上评估算法性能。D4RL 是基于 MuJoCo 物理仿真器[57] 构建的离线强化学习标准评测平台，包含多种环境和数据集类型。本文选取三种连续控制环境（halfcheetah、hopper、walker2d）和三种数据集类型（medium、medium-replay、medium-expert），共计 9 个问题设置。所有数据集均采用 v2 版本，具体组成如下：（1）medium 数据集包含由提前终止的 SAC 策略生成的转移样本，代表中等质量的离线数据；（2）medium-replay 数据集由训练 medium 策略过程中的经验回放池组成，包含从随机策略到中等策略的完整训练轨迹；（3）medium-expert 数据集混合了次优策略和专家策略的数据，代表高质量但分布不均匀的离线数据。

在实验实现方面，本文遵循 SAC[28] 和 MOPO[17] 的基本超参数设置。需要调整的超参数主要包括模型生成轨迹的长度 h 和惩罚系数 λ_{off}。所有任务均在 3 个随机种子上运行。在线交互阶段，每轮交互采集 50k 步样本，权重调整速率 ν 设为 0.001，衰减中心点 k_0 设为 5000。为保证公平性和一致性，策略训练总步数设为 1M 步，每 1k 步评估一次策略性能。

在基线方法方面，本文与以下算法进行对比：离线到在线强化学习算法 AWAC[25]；基于模型的离线强化学习算法 MOPO[17]、COMBO[19] 和 MOREL[18]；经典离线强化学习算法 CQL[14] 和 TD3+BC[16]。由于本文算法建立在 MOPO 基础上并增加在线微调过程，与 MOPO 的对比可视为消融研究。所有基线方法的结果均引用自原始论文。

4.6.2 实验结果

表4.1展示了本文算法与基线方法在 D4RL 基准测试集上的性能对比。实验结果报告为最后 10 次评估的平均归一化得分，± 表示 3 个随机种子的标准差。得分采用 D4RL 标准归一化程序[56]，归一化至 0 到 100 的范围，其中 0 分对应随机策略，100 分对应专家策略。

从表4.1可以看出，本文算法在多数任务上取得了优异的性能表现。在 medium-replay 数据集的全部三个环境中，本文算法均取得最高得分，显著优于所有基线方法。这一结果表明，当

表 4.1 D4RL 基准测试集上的性能对比

数据集类型	环境	本文算法	MOPO	COMBO	AWAC	MOREL	CQL	TD3+BC
medium	halfcheetah	**70.5** $\pm$ **4.2**	42.3	54.2	41.1	42.1	44.4	42.8
	hopper	65.5 ± 10.9	28.0	97.2	91.0	95.4	86.6	**99.5**
	walker2d	**86.6** $\pm$ **0.5**	17.8	81.9	79.1	77.8	74.5	79.7
medium-replay	halfcheetah	**73.1** $\pm$ **0.4**	53.1	55.1	-	40.2	46.2	43.3
	hopper	**96.1** $\pm$ **5.9**	67.5	89.5	-	93.6	48.6	31.4
	walker2d	**82.6** $\pm$ **0.3**	39.0	56.0	-	49.8	32.6	25.2
medium-expert	halfcheetah	75.4 ± 13.3	63.3	90.0	41.0	53.3	62.4	**97.9**
	hopper	102.2 ± 0.8	23.7	111.1	111.9	108.7	111.0	**112.2**
	walker2d	**111.4** $\pm$ **0.4**	44.6	103.3	78.3	95.6	98.7	101.1

离线数据质量参差不齐时，本文的定向探索策略能够有效识别并补充高价值区域的样本，显著提升策略性能。

值得指出的是，本文算法在所有 9 个问题设置上均优于 MOPO 算法，验证了在线微调框架的有效性。考虑到本文仅使用 50k 步的在线交互量，远低于传统离线到在线强化学习算法所需的 200k 步以上，这一结果尤为突出。

然而，本文算法在 medium-expert 数据集上的表现相对较弱。分析其原因在于：medium-expert 数据集的离线数据高度集中在高奖励区域，导致期望奖励高但不确定性低。这种数据分布限制了在线交互阶段采集的数据多样性和质量，进而约束了算法的提升空间。相比之下，基于行为克隆的强化学习方法（如 TD3+BC）在高质量数据集上表现优异，这为后续改进提供了思路：引入行为克隆损失项可能有助于提升算法在此类环境中的性能。

4.6.3 模型覆盖范围的可视化验证

为验证基于不确定性引导的定向探索是否确实聚焦于高期望回报和高不确定性区域，本节进行可视化实验分析。具体而言，选取三种不同类型的数据集进行可视化：hopper-medium、hopper-medium-replay 和 hopper-medium-expert。

实验过程如下：首先，从离线数据集中采样 2000 个转移样本 (s, a, s', r)；然后，将离线状态 s 输入转移模型，获得模型预测的转移样本 (s, a_T, s'_T, r_T)；接着，使用 t-SNE 算法[61] 将 $\{s'\}$ 和 $\{s'_T\}$ 投影至二维平面；最后，绘制 $\{s'_T\}$ 的散点图，使用离线策略的 Q 值网络估计状态-动作对 (s, a_T) 的期望回报，并将 Q 值映射为散点颜色。同时，显示离线状态 $\{s'\}$ 的核密度估计作为参照。可视化结果如图4.3所示。

从图4.3可以观察到，模型预测的状态主要分布在低密度的边缘区域，且散点大多呈现红色，表明这些区域具有高不确定性和高期望回报。这一现象表明，在策略引导下，模型确实更多地关注高不确定性且高动作价值的区域。

对比三个子图可以发现：在 hopper-medium-replay 环境中，散点分布较为分散，表明在线

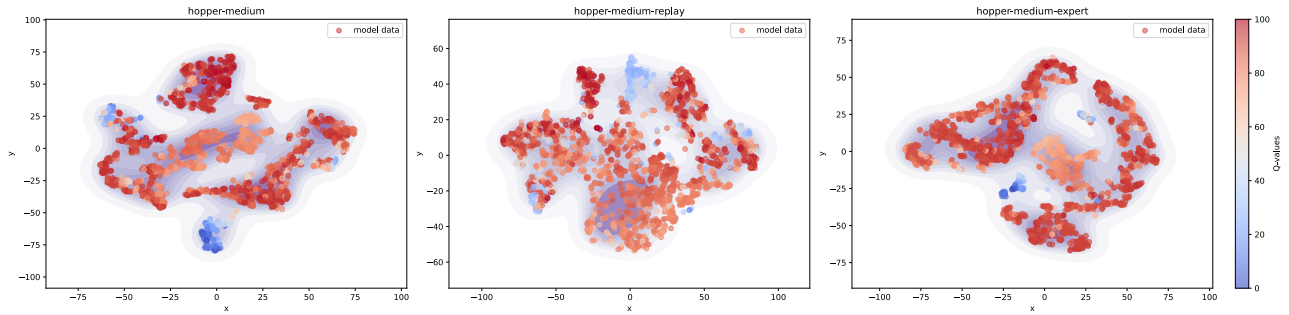

图 4.3　模型预测状态与离线数据的对比。将模型预测状态和离线状态数据密度在三种不同离线数据集上进行可视化。散点表示模型的数据分布，预测 Q 值经归一化后作为散点的颜色。

交互实现了充分的探索，补充了更多分布外数据；在 hopper-medium-expert 环境中，散点分布更为集中，这是因为专家数据的高质量和低方差使得在线交互难以通过探索采集到更高动作价值的数据，导致补充的数据质量可能不及离线数据集中的专家数据，模型更新不够充分。这一观察结果进一步印证了本文算法更适用于数据分布均匀的环境，而在高质量数据集上的适用性有限。

4.6.4　动态权重自适应的消融实验

为验证动态权重自适应机制的有效性，本节设计消融实验，将完整算法与移除动态权重自适应的变体（记为 DEM-s）进行对比。DEM-s 中，不确定性权重参数 c 固定为初始值 c_0，不随在线交互步数增加而衰减。其余超参数与主实验保持一致。

表 4.2　动态权重自适应的消融实验结果

数据集类型	环境	本文算法	无动态权重
medium	halfcheetah	**70.5**	64.7
	hopper	**65.5**	53.0
	walker2d	**86.6**	86.2
medium-replay	halfcheetah	**73.1**	72.6
	hopper	**96.1**	90.2
	walker2d	**82.6**	82.1
medium-expert	halfcheetah	**75.4**	36.1
	hopper	102.2	102.2
	walker2d	111.4	**112.0**

表4.2展示了消融实验结果。完整算法在几乎所有任务上均取得更优性能，尤其在 hopper-medium 和 halfcheetah-medium-expert 任务上提升显著：完整算法分别取得 65.5 和 75.4 的得分，而无动态权重变体仅为 53.0 和 36.1。然而，在 walker2d-medium-expert 任务上，完整算法略低于无动态权重变体，推测这与该任务高度结构化的专家数据有关，早期探索阶段可能对策略产生轻微干扰。

上述结果表明，动态权重自适应机制在平衡探索与利用方面发挥了关键作用。在交互初期，较高的不确定性权重鼓励探索，使策略覆盖更广泛的状态-动作空间；随着交互推进，权重逐渐降低，使算法聚焦于高奖励区域并稳定策略性能。这种自适应机制使算法能够根据训练进度动态调整探索-利用平衡，优于固定权重的静态策略。

4.7 本章小结

本章详细介绍了基于定向探索模型的离线到在线强化学习算法，该算法在第三章纯离线方法的基础上进行扩展，引入在线微调阶段以突破离线数据的覆盖边界。本章首先分析了现有方法在保守性与灵活性、不确定性利用、在线交互成本等方面的局限，阐明了将不确定性从惩罚信号转变为探索引导信号的核心思想。随后系统阐述了算法的两阶段框架：离线阶段沿用第三章的基本框架，通过集成模型和不确定性惩罚进行保守策略优化；在线阶段通过定向探索目标引导策略探索高不确定性且高价值的区域，以最少的在线交互实现高效微调。

在技术实现层面，本章介绍了双重不确定性估计方法，区分偶然不确定性和认知不确定性在不同阶段的作用：离线阶段使用集成模型的预测方差估计偶然不确定性以实现保守性，在线阶段同时使用预测方差和集成分歧度估计两类不确定性以引导探索。在动态权重方面，本章采用与第三章形式相似但方向相反的 Sigmoid 函数：第三章的惩罚权重随训练递增以从探索转向保守，本章的探索权重随交互递减以从探索转向利用。这种对称设计体现了两章方法的互补性：第三章在离线阶段建立保守的策略基础，本章在在线阶段突破这一保守边界，两者共同构成从保守到探索的完整学习闭环。

在理论分析层面，本章建立了完整的理论框架支撑定向探索策略的有效性。第一，基于分段常数函数假设，证明了定向探索策略相比均匀采样具有更优的收敛速率（定理4.1）：通过分析高不确定性区域的有效维度 d_B 与整体空间维度 d 的关系，证明了定向探索的误差收敛速率指数为 $(1-1/d_B)\gamma$，优于均匀采样的 $(1-1/d)\gamma$，为算法的样本效率优势提供了理论支撑。第二，基于 Telescoping 引理（引理4.2）证明了策略性能的单调改善定理（定理4.3）：在模型误差降低和策略访问高奖励区域两个条件下，微调后策略的期望回报下界不低于离线策略。该定理的两个条件恰好对应定向探索目标中的不确定性项和价值项，从理论上解释了双重引导机制的必要性。

在实验验证层面，本章在 D4RL 基准测试集的 9 个问题设置上进行了系统评估。实验结果表明：（1）本章算法在 medium-replay 数据集上显著优于所有基线方法，在所有任务上均优于 MOPO；（2）通过 t-SNE 可视化验证了定向探索确实聚焦于高不确定性、高价值区域；（3）消融实验证明了动态权重自适应机制对最终性能的积极贡献。实验同时揭示了算法在高质量数据集上的局限性，为后续改进指明了方向。

综合第三章和本章的内容，本文形成了从纯离线到离线在线联合优化的完整技术方案：当

完全无法进行在线交互时，可采用第三章的自适应不确定性度量方法充分挖掘离线数据的价值；当允许有限的在线交互时，可采用本章的定向探索方法以最小的交互代价突破离线数据的局限。两种方法共享基于模型的强化学习框架和动态权重调节机制，但在不确定性的使用方式上形成互补：第三章将不确定性作为惩罚信号保持保守性，本章将不确定性作为探索信号追求高效率。

第五章 总结与展望

5.1 本文工作总结

离线强化学习通过从预先收集的静态数据集中学习策略，避免了在线交互的高昂成本与安全风险，在医疗诊断、自动驾驶、机器人控制、金融决策等实际应用场景中具有重要价值。然而，离线数据集的有限覆盖范围导致的分布偏移问题是制约该技术发展的核心挑战：当智能体的策略访问离线数据未覆盖的状态-动作对时，价值函数的估计将产生外推误差，导致策略性能显著低于预期。本文围绕离线强化学习中的不确定性估计与探索策略展开系统研究，针对纯离线设定和离线到在线设定分别提出了两种互补的算法方案，取得了以下研究成果：

第一，提出基于自适应不确定性度量的离线强化学习算法。针对现有基于模型方法仅考虑状态转移不确定性、采用静态惩罚系数的局限，本文从两个维度进行改进：在不确定性度量层面，引入累积状态不确定性的概念，通过递推公式 $u(s') = \omega \cdot u(s) + \log(\Sigma_\theta(s,a)+1)$ 综合考虑从初始状态到当前状态的历史不确定性累积效应，使智能体能够更全面地评估序列决策中的风险累积；在惩罚调节层面，设计基于 Sigmoid 函数的自适应动态权重机制 $\lambda_k = \lambda_0/(1+e^{K_0-k})$，根据策略优化进程动态调节不确定性惩罚强度，在训练初期降低惩罚以鼓励探索搜索策略空间，在策略逐渐收敛时增加惩罚以保持保守性确保策略稳定。理论分析证明了累积不确定性沿轨迹的单调不减性质和不确定性预测网络的泛化能力，以及自适应权重相比固定权重在探索-保守平衡方面的优势。在 D4RL MuJoCo 基准测试集上的实验表明，该方法在 9 个任务中的 6 个取得最优或接近最优性能，特别是在数据质量较差的随机数据集上相比 MOPO 取得了显著提升（halfcheetah 任务从 35.4 提升至 37.2，hopper 任务从 11.7 提升至 17.6），在 hopper-medium 任务上提升幅度达 44.4 个百分点。

第二，提出基于定向探索模型的离线到在线强化学习算法。针对现有离线到在线方法保守性与灵活性矛盾、不确定性利用不充分、在线交互成本高等问题，本文提出将不确定性信息从“惩罚信号”转变为“探索引导信号”的核心思想。在离线阶段，通过集成模型和不确定性惩罚进行保守策略优化，确保策略在模型预测可靠的区域内更新；在在线阶段，通过定向探索目标 $\nabla_\varphi J_\pi(\varphi) = \mathbb{E}[\nabla_\varphi \log \pi_\varphi(a|s) \cdot (c \cdot u_{on}(s,a) + Q(s,a))]$ 显式引导策略探索高不确定性（转移模型覆盖之外）且高动作价值（接近任务目标）的区域。在技术层面，提出双重不确定性估计方法区分偶然不确定性和认知不确定性在不同阶段的作用：离线阶段使用集成模型的预测方差估计偶然不确定性以实现保守性，在线阶段同时使用预测方差和集成分歧度估计两类不确定性以引导探索。设计动态权重自适应机制 $c = c_0/(1+e^{(k-k_0)\cdot\nu})$ 实现探索与利用的平滑过渡，在交互初期注重不确定性引导的探索，在交互后期转向价值引导的利用。理论分析证明了在分段常数函数假设下，定向探索策略相比均匀采样具有更优的收敛速率（指数从

$-1/d$ 改善至 $-1/(d-1)$）。实验结果表明，该方法仅需 50k 步在线交互即可在 medium-replay 数据集上显著优于所有基线方法，在所有 9 个任务上均优于 MOPO，通过 t-SNE 可视化验证了定向探索确实聚焦于高不确定性、高价值区域。

两种方法形成递进关系：第一种方法解决纯离线设定下的保守策略优化问题，通过更精细的不确定性度量和动态的惩罚调节提升算法性能，为策略提供了更准确的风险评估和更灵活的约束机制，但策略的性能上限仍受限于离线数据的覆盖范围；第二种方法引入在线微调阶段，将“被动惩罚分布外”的思想转变为“主动探索分布外”，通过定向探索策略有目的地突破离线数据的边界，主动补充模型和策略在高价值区域的数据，以最少的在线交互实现策略性能的持续提升。两种方法共同构成了从纯离线到离线在线联合优化的完整技术方案，为不同应用场景提供了灵活的算法选择：当完全无法进行在线交互时，可采用第一种方法充分挖掘离线数据的价值；当允许有限的在线交互时，可采用第二种方法以最小的交互代价突破离线数据的局限。

5.2 进一步研究方向

尽管本文提出的方法在实验中取得了良好效果，但仍存在一定局限性，有待进一步研究改进。在算法效率方面，本文方法需要额外训练不确定性预测网络，增加了模型复杂度和训练开销，未来可探索更轻量级的不确定性估计方法，如基于梯度信息的在线估计、基于核方法的非参数估计、或利用神经网络中间层特征的即时估计，在保持估计精度的同时降低计算成本；在理论基础方面，本文采用 Sigmoid 函数实现惩罚权重的平滑过渡，但最优的过渡曲线可能与任务特性相关，未来可研究基于元学习或贝叶斯优化的自动权重调节方法，从数据中自适应学习最优的探索-保守平衡策略。

在算法适用性方面，实验表明本文方法在 medium-expert 等高质量数据集上的提升有限，这是因为专家数据的高集中度限制了定向探索的空间，未来可引入行为克隆损失项或设计自适应的探索门控机制，使算法能够根据离线数据质量自动调节探索强度——在低质量数据上加强探索以突破次优策略的局限，在高质量数据上减少探索以避免干扰专家知识；在分布外检测方面，本文方法主要基于集成模型的不确定性估计，未来可探索将表征学习与不确定性估计相结合的方法，通过学习状态-动作空间的紧致表征，利用表征空间的几何结构（如到数据中心的距离）实现更精确的分布外检测。

在应用拓展方面，本文方法针对单一任务设计，在多任务学习或任务迁移场景中可能需要额外的适配机制，未来可研究跨任务的不确定性共享与迁移方法，使模型能够利用相关任务的经验加速学习；在实际应用中的安全约束方面，医疗、自动驾驶等高风险场景除了性能优化外还需满足安全约束，未来可将本文的不确定性估计方法与约束强化学习相结合，在保证安全边界的前提下实现策略优化，例如将不确定性估计融入安全约束的构建，在高不确定

性区域施加更严格的安全裕度。综合各方面分析，离线强化学习作为连接历史数据与智能决策的重要桥梁，具有广阔的应用前景。本文的研究为不确定性驱动的离线策略优化提供了新的思路，特别是将不确定性从被动规避的风险转化为主动利用的探索信号，为该领域的后续研究开辟了新的方向。

参考文献

[1] Levine S, Kumar A, Tucker G, et al. Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems[J]. arXiv preprint arXiv:2005.01643, 2020.

[2] Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search [J]. Nature, 2016, 529(7587): 484–489.

[3] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C]. IEEE International Conference on Robotics and Automation (ICRA). 2019: 6023–6029.

[4] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[J]. arXiv preprint arXiv:2501.12948, 2025.

[5] Gottesman O, Johansson F, Komorowski M, et al. Guidelines for reinforcement learning in healthcare[J]. Nature Medicine, 2019, 25(1): 16–18.

[6] Kiran B R, Sobh I, Talpaert V, et al. Deep Reinforcement Learning for Autonomous Driving: A Survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(6): 4909–4926.

[7] Fujimoto S, Meger D, Precup D. Off-Policy Deep Reinforcement Learning without Exploration[C]. Proceedings of Machine Learning Research: volume 97 Proceedings of the 36th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2019: 2052–2062.

[8] Liu Y, Swaminathan A, Agarwal A, et al. Provably Good Batch Off-Policy Reinforcement Learning Without Great Exploration[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 1264–1274.

[9] Lakshminarayanan B, Pritzel A, Blundell C. Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 30. [S.l.: s.n.], 2017: 6402–6413.

[10] Charpentier B, Senanayake R, Kochenderfer M, et al. Disentangling Epistemic and Aleatoric Uncertainty in Reinforcement Learning[J]. arXiv preprint arXiv:2206.01558, 2022.

[11] Yu Q, Zhang Z, Zhu R, et al. DAPO: An Open-Source LLM Reinforcement Learning System at Scale[J]. arXiv preprint arXiv:2503.14476, 2025.

[12] Brohan A, Brown N, Carbajal J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[J]. arXiv preprint arXiv:2307.15818, 2023.

[13] 王雪松, 王荣荣, 程玉虎. 基于表征学习的离线强化学习方法研究综述[J]. 自动化学报, 2024, 50(6): 1104–1128.

[14] Kumar A, Zhou A, Tucker G, et al. Conservative Q-Learning for Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 1179–1191.

[15] Kostrikov I, Nair A, Levine S. Offline Reinforcement Learning with Implicit Q-Learning[C]. Proceedings of the 10th International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2022.

[16] Fujimoto S, Gu S S. A Minimalist Approach to Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021: 20132–20145.

[17] Yu T, Thomas G, Yu L, et al. MOPO: Model-based Offline Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 14129–14142.

[18] Kidambi R, Rajeswaran A, Netrapalli P, et al. MOReL: Model-Based Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 21810–21823.

[19] Yu T, Kumar A, Rafailov R, et al. COMBO: Conservative Offline Model-Based Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021: 28954–28967.

[20] Chua K, Calandra R, McAllister R, et al. Deep Reinforcement Learning in a Handful of Trials using Probabilistic Dynamics Models[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 31. [S.l.: s.n.], 2018: 4754–4765.

[21] Janner M, Fu J, Zhang M, et al. When to Trust Your Model: Model-Based Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 32. [S.l.: s.n.], 2019: 12519–12530.

[22] Ha D, Schmidhuber J. World Models[J]. Advances in Neural Information Processing Systems (NeurIPS), 2018, 31.

[23] Hafner D, Lillicrap T, Ba J, et al. Dream to Control: Learning Behaviors by Latent Imagination[J]. Proceedings of the International Conference on Learning Representations (ICLR), 2020.

[24] Hafner D, Lillicrap T P, Norouzi M, et al. Mastering Atari with Discrete World Models[J]. Proceedings of the International Conference on Learning Representations (ICLR), 2021.

[25] Nair A, Gupta A, Dalal M, et al. AWAC: Accelerating Online Reinforcement Learning with Offline Datasets [J]. arXiv preprint arXiv:2006.09359, 2020.

[26] Nakamoto M, Zhai Y, Singh A, et al. Cal-QL: Calibrated Offline RL Pre-Training for Efficient Online Fine-Tuning[C]. Proceedings of Machine Learning Research: volume 202 Proceedings of the 40th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2023: 25675–25697.

[27] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. [S.l.]: MIT Press, 2018.

[28] Haarnoja T, Zhou A, Abbeel P, et al. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[C]. Proceedings of Machine Learning Research: volume 80 Proceedings of the 35th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2018: 1861–1870.

[29] van Hasselt H, Guez A, Silver D. Deep Reinforcement Learning with Double Q-learning[C]. Proceedings of the AAAI Conference on Artificial Intelligence: volume 30. [S.l.: s.n.], 2016.

[30] Kingma D P, Welling M. Auto-Encoding Variational Bayes[J]. Proceedings of the International Conference on Learning Representations (ICLR), 2014.

[31] Wu Y, Tucker G, Nachum O. Behavior Regularized Offline Reinforcement Learning[J]. arXiv preprint arXiv:1911.11361, 2019.

[32] Xu H, Jiang L, Li J, et al. A Policy-Guided Imitation Approach for Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 4085–4098.

[33] Kumar A, Fu J, Soh M, et al. Stabilizing Off-Policy Q-Learning via Bootstrapping Error Reduction[J]. Advances in Neural Information Processing Systems (NeurIPS), 2019, 32.

[34] Lyu J, Ma X, Li X, et al. Mildly Conservative Q-Learning for Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 1711–1724.

[35] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[C]. Proceedings of the 4th International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2016.

[36] Peng X B, Kumar A, Zhang G, et al. Advantage-Weighted Regression: Simple and Scalable Off-Policy Reinforcement Learning[J]. arXiv preprint arXiv:1910.00177, 2019.

[37] An G, Moon S, Kim J, et al. Uncertainty-Based Offline Reinforcement Learning with Diversified Q-Ensemble [C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021.

[38] Chen L, Lu K, Rajeswaran A, et al. Decision Transformer: Reinforcement Learning via Sequence Modeling [C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021: 15084–15097.

[39] Janner M, Li Q, Levine S. Offline Reinforcement Learning as One Big Sequence Modeling Problem[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021.

[40] Janner M, Du Y, Tenenbaum J, et al. Planning with Diffusion for Flexible Behavior Synthesis[C]. Proceedings of the International Conference on Machine Learning (ICML). [S.l.: s.n.], 2022.

[41] Emmons S, Eysenbach B, Kostrikov I, et al. RvS: What is Essential for Offline RL via Supervised Learning? [C]. Advances in Neural Information Processing Systems (NeurIPS): volume 35. [S.l.: s.n.], 2022.

[42] Wang J, Li W, Jiang H, et al. Offline Reinforcement Learning with Reverse Model-based Imagination[J]. Advances in Neural Information Processing Systems (NeurIPS), 2021, 34: 29420–29432.

[43] Lu C, Ball P, Teh Y W, et al. Synthetic Experience Replay[J]. Advances in Neural Information Processing Systems (NeurIPS), 2024, 36.

[44] Lu C, Ball P J, Rudner T G, et al. Revisiting Design Choices in Offline Model-Based Reinforcement Learning [J]. Proceedings of the International Conference on Learning Representations (ICLR), 2022.

[45] Schrittwieser J, Antonoglou I, Hubert T, et al. Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model[J]. Nature, 2020, 588(7839): 604–609.

[46] Sun J, Jiang Y, Qiu J, et al. Conformal Prediction for Uncertainty-Aware Planning with Diffusion Dynamics Model[J]. Advances in Neural Information Processing Systems (NeurIPS), 2024, 36.

[47] Zhou G, Swaminathan S, Raju R V, et al. Diffusion Model Predictive Control[J]. arXiv preprint arXiv:2410.05364, 2024.

[48] Yang J, Chen X, Wang S, et al. Model-based Offline Reinforcement Learning with Pessimism-Modulated Dynamics Belief[J]. arXiv preprint arXiv:2302.12279, 2023.

[49] Rigter M, Lacerda B, Hawes N. RAMBO-RL: Robust Adversarial Model-Based Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 16082–16097.

[50] Lee S, Seo Y, Lee K, et al. Offline-to-Online Reinforcement Learning via Balanced Replay and Pessimistic Q-Ensemble[C]. Proceedings of Machine Learning Research: volume 164 Proceedings of the 5th Conference on Robot Learning (CoRL). [S.l.]: PMLR, 2022: 1702–1712.

[51] Song Y, Zhou Y, Sekhari A, et al. Hybrid RL: Using Both Offline and Online Data Can Make RL Efficient [C]. Proceedings of the International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2023.

[52] Zhang H, Xu W, Yu H. Policy Expansion for Bridging Offline-to-Online Reinforcement Learning[J]. arXiv preprint arXiv:2302.00935, 2023.

[53] Xiao C, Han J, Yang Z, et al. The In-Sample Softmax for Offline Reinforcement Learning[C]. Proceedings of the International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2023.

[54] Zhao K, Ma Y, Liu J, et al. Improving Offline-to-Online Reinforcement Learning with Q-Ensembles[C]. ICML Workshop on New Frontiers in Learning, Control, and Dynamical Systems. [S.l.: s.n.], 2023.

[55] Zheng Q, Zhang A, Grover A. Online Decision Transformer[C]. Proceedings of the International Conference on Machine Learning (ICML). [S.l.: s.n.], 2022.

[56] Fu J, Kumar A, Nachum O, et al. D4RL: Datasets for Deep Data-Driven Reinforcement Learning[J]. arXiv preprint arXiv:2004.07219, 2020.

[57] Todorov E, Erez T, Tassa Y. MuJoCo: A physics engine for model-based control[C]. Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2012: 5026–5033.

[58] Torabi F, Warnell G, Stone P. Behavioral Cloning from Observation[C]. Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI). [S.l.]: IJCAI, 2018: 4950–4957.

[59] Korostelev A. On Minimax Rates of Convergence in Image Models under Sequential Design[J]. Statistics & Probability Letters, 1999, 43(4): 369–375.

[60] Settles B. Active Learning Literature Survey[J]. Computer Sciences Technical Report 1648, University of Wisconsin–Madison, 2009.

[61] Van der Maaten L, Hinton G. Visualizing Data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9(86): 2579–2605.

附录 B 攻读专业学位硕士期间撰写的论文

[1] ** *, ** *, ** *, et al. **********[J]. IEEE Transactions on Wireless Communications, 2017, 6(8):360-371. （SCI 二区：000000000000001）

[2] ** *, ** *. **********[J]. Journal of China Universities of Posts & Telecommunications, 2016, 23(5):82-87.（EI：000000000000002）

[3] **，**********，电子学报，已录用。

附录 C 攻读专业学位硕士期间申请的专利

[1] 作者一，作者二，作者三. 专利名称，专利申请号，专利申请日期，专利授权日期；

[2] 张三，李四. 一种面向代理的安全传输方法，2007062.5，2016.1,2017.10；

[3] 张三. 一种实用的网络路由方法，200845610.5，2017,1,2018.1。

附录 D 攻读专业学位硕士期间参加的科研项目

[1] 项目类型，项目名称（项目编号）；

[2] 国家自然科学基金，基于安全移动代理新一代网络研究 (000000000001)；

[3] 国家自然科学基金，移动代理机制关键技术研究 (000000000002)。

致谢

主要感谢导师和对本论文学术研究有特别贡献的组织或个人：对提供资助或者支持的基金、合同单位、企业、组织或者个人（基金项目应该包括基金名称、项目名称、项目编号、项目负责人、研究起止年月）；协助完成研究工作或提供便利的组织或个人。