单位代码：10293　密　级：_____

南京邮电大学

专业学位硕士论文

论文题目：_____

学　　号　_____

姓　　名　_____

导　　师　_____

专业学位类别　_____

类　　型　_____

专业（领域）　****

论文提交日期　_____

摘要

《摘要正文》********** 中文摘要（两页），英文摘要，二者应基本对应。它是论文内容的高度概括，应说明研究目的、研究方法、成果和结论，要突出本论文的创造性成果或新的见解、用语简洁、准确。论文摘要的关键词 3 至 8 个。关键词应为公知公用的词和学术术语，不可采用自造字词和略写、符号等，词组不宜过长。

英文摘要采用第三人称单数语气介绍该学位论文内容，目的是便于其他文摘摘录，因此在写作英文文摘时不宜用第一人称的语气陈述。叙述的基本时态为一般现在时，确实需要强调过去的事情或者已经完成的行为才使用过去时、完成时等其他时态

关键词： **，**，**，**

Abstract

Abstract.....

Key Words: **,**,**,**

目　录

摘要 I
Abstract II
插图索引 V
表格索引 VI
专用术语注释表 VII
第一章　绪论 1
1.1　研究背景与意义 1
1.2　国内外研究现状 2
1.3　研究内容与主要工作 2
1.4　文章结构安排 2
第二章　理论基础与相关工作 3
2.1　理论基础 3
2.1.1　马尔可夫决策过程 3
2.1.2　基于模型的离线强化学习框架 4
2.1.3　集成模型与不确定性估计 4
2.2　离线强化学习相关工作 4
2.2.1　无模型离线强化学习 5
2.2.2　基于模型的离线强化学习 5
2.3　离线到在线强化学习相关工作 6
2.3.1　保守性调节方法 6
2.3.2　数据融合方法 6
2.3.3　现有方法的共同局限 7
2.4　本章小结 7
第三章　第三章标题 8
3.1　章内标题 3.1 8
3.1.1　章内标题 3.1.1 8
3.1.2　章内标题 3.1.2 8
3.2　章内标题 3.2 8
3.2.1　章内标题 3.2.1 8
3.2.2　章内标题 3.2.2 8
3.3　章内标题 3.3 8
3.3.1　章内标题 3.3.1 8
3.3.2　章内标题 3.3.2 8
3.4　本章小结 9
第四章　第四章标题 10
4.1　章内标题 4.1 10
4.1.1　章内标题 4.1.1 10
4.1.2　章内标题 4.1.2 10
4.2　章内标题 4.2 10
4.2.1　章内标题 4.2.1 10
4.2.2　章内标题 4.2.2 10

4.3 章内标题 4.3 10
4.3.1 章内标题 4.3.1 10
4.3.2 章内标题 4.3.2 10
4.4 本章小结 11
第五章 第五章标题 12
5.1 章内标题 5.1 12
5.1.1 章内标题 5.1.1 12
5.1.2 章内标题 5.1.2 12
5.2 章内标题 5.2 12
5.2.1 章内标题 5.2.1 12
5.2.2 章内标题 5.2.2 12
5.3 章内标题 5.3 12
5.3.1 章内标题 5.3.1 12
5.3.2 章内标题 5.3.2 12
5.4 本章小结 13
第六章 总结与展望 14
6.1 本文工作总结 14
6.2 进一步研究方向 14
参考文献 15
附录 **A** 程序清单 18
附录 **B** 攻读专业学位硕士期间撰写的论文 19
附录 **C** 攻读专业学位硕士期间申请的专利 20
附录 **D** 攻读专业学位硕士期间参加的科研项目 21

插图索引

表格索引

专用术语注释表

符号说明：

符号	表示含义
B_D	多普勒扩展

缩略词说明：

缩写	英文全称	中文译名
5G	5th Generation	第五代移动通信

第一章 绪论

1.1 研究背景与意义

强化学习（Reinforcement Learning, RL）是一种实现机器自主决策的人工智能范式，智能体通过与环境的持续交互学习最优策略，以最大化长期累积回报[1]。自深度强化学习在围棋[2]等领域取得突破以来，学术界与工业界持续将其应用拓展至更复杂的真实场景。近年来，强化学习在机器人控制[3]领域积累了丰富经验，并随着 DeepSeek-R1[4]在推理任务中的成功应用，开始广泛用于大语言模型的对齐与微调。

在线强化学习框架中，智能体直接与环境交互，通过试错优化行为策略。该方法具备良好的适应性，能够根据环境反馈及时调整策略，但需要大量交互样本。在医疗诊断[5]、自动驾驶[6]等数据采集成本高昂或存在安全约束的场景中，频繁的在线试错既不经济也存在风险，限制了在线强化学习的实际部署。

离线强化学习提供了一种替代方案：从预先收集的静态数据集中学习策略，避免在线交互的成本与风险。该范式依赖行为策略采集的历史数据，训练开销较小。然而，行为策略通常是次优的，且存在分布偏移问题[7]——训练数据分布与目标策略访问的状态-动作分布存在差异，导致价值函数对分布外动作的估计不准确。由于离线学习无法获得环境反馈修正估计误差，累积误差会引发对分布外动作价值的过高估计，产生外推误差[8]。如何从有限且可能存在偏差的数据中学习泛化能力良好的策略，是离线强化学习的核心挑战。

离线到在线强化学习结合了两种范式的优势：先在离线数据上预训练策略，再通过有限的在线交互进行微调，既利用了历史数据降低样本需求，又通过在线反馈提升策略性能。

当前离线到在线方法多采用无模型框架，侧重于离线与在线数据的融合策略，如平衡重放、优先级采样等。无模型方法的样本效率受限，难以充分挖掘大规模离线数据集的价值。本文研究基于不确定性探索模型的离线到在线强化学习算法，将优化重点置于环境动力学模型：利用离线策略与环境交互获取的在线数据优化状态转移模型，构建更准确且覆盖分布外区域的环境模型，进而完成策略更新。该方法以模型生成数据替代频繁的环境交互，在线开销较小，数据利用效率较高。

引入不确定性量化机制后，该方法在离线阶段可识别数据集中的高不确定性区域，对这些区域采取保守的策略更新；在线阶段则优先探索不确定性较高的状态-动作对，以较小的交互代价获取策略未覆盖区域的新数据。这种不确定性引导的探索机制提升了模型对环境变化的适应能力。

该算法适用于需要充分利用历史数据、同时在线探索受限的场景，如自动驾驶、金融决策、医疗优化等。基于模型的框架通过数据生成减少对在线交互的依赖，不确定性引导的探

索策略提升了在线微调的样本效率，在控制在线成本的同时实现策略性能的持续提升。

1.2 国内外研究现状

强化学习在决策优化领域的应用日趋成熟，学术界与工业界均取得了阶段性进展。在大语言模型领域，DeepSeek 发布的 R1 系列模型[4] 通过纯强化学习范式激发模型的复杂推理能力，验证了强化学习在语言模型对齐中的有效性；ByteDance 等团队提出的 DAPO 算法[9] 开源了大规模语言模型强化学习训练系统，在 Qwen2.5-32B 基座模型上实现了可复现的推理能力训练。在具身智能领域，Google DeepMind 研发的 RT-2 模型[10] 将视觉-语言预训练知识迁移至机器人控制，提升了机器人在真实环境中的语义理解与操作泛化能力。在离线强化学习理论研究方面，王雪松等[11] 系统梳理了基于表征学习的离线强化学习方法，分析了特征解耦对策略迁移能力的增强作用。

上述进展表明强化学习在大模型对齐、表征学习、复杂场景适配等方向取得了实质性成果，但也对离线到在线强化学习技术提出了更高要求。当前该领域仍面临三方面技术挑战：

分布偏移与知识遗忘问题。离线阶段基于固定数据集训练的策略，在在线环境中因数据分布差异易产生性能衰减；在线微调过程中又可能丢失离线阶段习得的知识。现有方案通过动态策略调整、重要性加权等机制尝试平衡两者，但需针对具体任务分析数据分布特性并设计回放机制，开发成本较高，且难以在适应新环境与保留已有知识之间取得平衡。

探索与利用的平衡加剧。探索-利用权衡是强化学习的固有难题，离线到在线的两阶段模式进一步放大了这一矛盾：离线阶段需保持策略保守性以规避数据偏差风险，在线阶段又需探索未知区域以适配环境变化。两阶段对探索强度的需求相反，使得探索策略的设计更加困难。RT-2 模型虽提升了泛化能力，但未形成适配两阶段特性的动态探索机制。

数据效率与在线开销的失衡。离线到在线的两阶段设置中，离线数据集的知识常未被充分利用，策略在微调阶段易丢失预训练知识；在线交互虽能获取环境反馈，但频繁访问环境会削弱离线学习低成本的优势。如何在提升数据利用率的同时控制在线开销，是该领域亟待解决的问题。

上述挑战推动了基于不确定性探索等技术方案的研究，也是本文的研究出发点。

1.3 研究内容与主要工作

1.4 文章结构安排

第二章 理论基础与相关工作

本章首先介绍强化学习的理论基础，建立本文所需的数学框架；随后对离线强化学习、离线到在线强化学习领域的相关工作进行系统综述，分析现有方法的发展脉络、核心优势与局限，阐明本文研究动机。

2.1 理论基础

2.1.1 马尔可夫决策过程

强化学习问题通常建模为马尔可夫决策过程（Markov Decision Process, MDP）[12]。MDP 由六元组 $M = (\mathcal{S}, \mathcal{A}, T, r, \mu_0, \gamma)$ 定义，其中 $\mathcal{S}$ 表示状态空间，$\mathcal{A}$ 表示动作空间，$r(s,a)$ 为奖励函数，$T(s'|s,a)$ 为状态转移函数，μ_0 为初始状态分布，$\gamma \in (0,1)$ 为折扣因子。

状态价值函数 $V_M^\pi(s)$ 表示在 MDP M 中，从状态 s 出发遵循策略 π 所能获得的期望折扣回报：

$$V_M^\pi(s) = \mathbb{E}_{\pi,M}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)\right] \tag{2.1}$$

期望折扣回报 η_M^π 可通过初始状态分布 μ_0 下状态价值函数的期望得到：

$$\eta_M^\pi = \mathbb{E}_{s\sim\mu_0}[V_M^\pi(s)] \tag{2.2}$$

MDP 的目标是找到最大化 η_M^π 的最优策略。

动作价值函数 $Q_M^\pi(s,a)$ 表示在状态 s 执行动作 a 后，遵循策略 π 所能获得的期望折扣回报。设 $\rho_M^\pi(s,a)$ 为策略 π 下的（非归一化）折扣状态-动作访问分布：

$$\rho_M^\pi(s,a) = \pi(a|s)\sum_{t=0}^{\infty} \gamma^t P(s_t = s|\pi, M) \tag{2.3}$$

其中 $P(s_t = s|\pi, M)$ 表示在 MDP M 中遵循策略 π 于时刻 t 到达状态 s 的概率。期望折扣回报可表示为：

$$\eta_M^\pi = \mathbb{E}_{\rho_M^\pi}[r(s,a)] \tag{2.4}$$

归一化状态-动作访问分布定义为 $\tilde{\rho}_M^\pi(s,a) = (1-\gamma)\cdot\rho_M^\pi(s,a)$。

2.1.2 基于模型的离线强化学习框架

在离线强化学习中,智能体仅能访问由行为策略 π_D 采集的静态数据集 $\mathcal{D}_{off} = \{(s_i, a_i, s'_i, r_i)\}_{i=1}^N$，而无法与环境交互。为优化策略，基于模型的离线强化学习首先通过监督学习构建转移模型 $\hat{T}_\theta(s', r|s, a)$，该模型根据当前状态 s 和动作 a 预测下一状态 s' 和奖励 r。

转移模型通常表示为高斯分布 $\hat{T}_\theta(s', r|s, a) = \mathcal{N}(\mu_\theta(s, a), \Sigma_\theta(s, a))$，其中 $\mu_\theta(s, a)$ 为分布均值，$\Sigma_\theta(s, a)$ 为方差。策略可通过与该监督学习得到的转移模型交互进行优化。基于模型的方法在数据采集困难时具有更高的样本效率，但真实环境与监督学习得到的转移模型之间的差异会累积外推误差，导致分布偏移问题。因此，减少分布外数据的过估计对于基于模型的离线强化学习至关重要。

2.1.3 集成模型与不确定性估计

集成方法通过训练多个独立模型，利用模型间预测的分歧度估计不确定性[13]。设训练 N 个模型 $\{f_1, \ldots, f_N\}$，预测不确定性可通过集成预测的方差估计。

强化学习中的不确定性可分为两类：**认知不确定性（Epistemic Uncertainty）**源于知识的缺乏，可通过收集更多数据降低；**偶然不确定性（Aleatoric Uncertainty）**源于环境固有的随机性，无法通过更多数据消除。对于离线到在线强化学习，认知不确定性尤为重要：高认知不确定性区域对应离线数据覆盖不足的区域，是在线探索应优先关注的目标。

在基于模型的强化学习中,集成动力学模型的每个成员输出高斯分布,其预测方差 $\Sigma_\phi^i(s, a)$ 反映偶然不确定性。为进一步捕捉认知不确定性，可利用集成模型均值预测的分歧度：

$$\mathrm{DisVar}(s, a) = \frac{1}{d} \sum_{j=1}^{d} \mathrm{Var}_{i=1,\ldots,N}[\mu_{\phi,j}^i(s, a)] \tag{2.5}$$

其中 d 为预测向量维度，Var_i 表示集成模型间的方差。本文将在算法设计中结合两类不确定性，实现更有效的在线探索。

2.2 离线强化学习相关工作

离线强化学习（Offline Reinforcement Learning）旨在仅利用预先收集的静态数据集学习策略，而不与环境进行交互[1]。该范式在机器人控制[3]、自动驾驶[6]、医疗决策[5] 等探索成本高昂或存在安全风险的领域具有重要应用价值。离线强化学习面临的核心挑战是**分布偏移（Distribution Shift）**问题[7]：当学习策略与行为策略差异较大时，策略可能访问离线数据集未覆盖的状态-动作对，导致价值函数的外推误差（Extrapolation Error）[8]。根据是否学习环境模型，离线强化学习方法可分为无模型方法和基于模型方法两大类。

2.2.1 无模型离线强化学习

无模型离线强化学习直接利用离线数据优化策略，其核心思想是在价值函数或策略中引入保守性约束，避免对分布外动作的过估计[14–18]。

策略约束方法是该领域的早期探索方向。BCQ[7] 首次系统分析了离线强化学习中的外推误差问题，提出通过生成模型约束策略仅在行为策略支撑集内选择动作。BRAC[14] 进一步系统研究了策略正则化方法，通过 KL 散度或 MMD 度量约束学习策略与行为策略的距离。TD3+BC[19] 则采用更简洁的行为克隆正则项，以极简方式实现策略约束。策略约束方法的**优势**在于直观有效地避免分布外动作，**局限**在于策略改进空间受行为策略质量限制，难以超越数据集中最优轨迹的性能。

价值正则化方法从价值函数角度抑制过估计。CQL[20] 引入正则项学习保守的 Q 值下界，通过推低分布外动作的 Q 值、推高数据集内动作的 Q 值实现保守估计。MCQ[17] 在 CQL 基础上引入更温和的保守约束，避免过度惩罚。IQL[18] 采用期望回归学习价值函数，通过非对称损失函数隐式逼近最优 Q 值，完全避免对分布外动作的显式查询。价值正则化方法的**优势**在于无需显式建模行为策略，理论保证更为完善；**局限**在于保守性可能过强，导致策略性能低于数据集中最优轨迹。

无模型方法的共同**局限**在于无法生成新的数据样本，样本效率较低，且保守性约束可能限制策略的潜在性能。

2.2.2 基于模型的离线强化学习

基于模型的离线强化学习首先从离线数据学习环境转移模型，再通过与模型交互优化策略[21–24]。该类方法的**优势**在于可利用模型生成额外数据，提升样本效率。然而，模型在分布外区域的预测可能产生外推误差[8]，且误差会随 rollout 步数累积，导致性能退化。因此，基于模型的方法需在探索分布外数据与保持保守性之间取得平衡。

不确定性惩罚方法是该领域的主流范式。MOPO[22] 提出通过集成模型估计不确定性，对模型预测的奖励施加不确定性惩罚，约束策略在低不确定性区域内优化。该方法的**优势**在于提供了理论保证的性能下界；**局限**在于惩罚系数需要针对不同任务调整，且过强的惩罚可能限制策略性能。

悲观 MDP 方法从另一角度实现保守性。MOReL[25] 构建悲观 MDP：当模型不确定性超过阈值时，将状态转移至吸收状态并给予低奖励，从而约束策略在高置信区域内优化。RAMBO[26] 通过对抗训练学习悲观模型，无需显式设定不确定性阈值。该类方法的**优势**在于提供更强的安全保证；**局限**在于悲观性可能过强，导致策略过于保守。

保守价值估计方法将无模型方法的保守性与模型数据结合。COMBO[27] 在模型生成数据

上采用 CQL 的保守估计，在真实数据上进行标准学习，兼顾数据效率与保守性。该方法的**优势**在于结合了两类方法的优点；**局限**在于仍受 CQL 保守性的限制。

近年来，研究者开始引入**扩散模型**提升转移模型的表达能力[28,29]，能够更好地捕捉多模态转移分布。

尽管上述方法在一定程度上缓解了外推误差，但核心局限在于：**不确定性信息仅用于惩罚高不确定性区域，而非主动引导策略补充这些区域的数据**。这导致模型在分布外区域的泛化能力始终受限，难以充分评估和补充分布外数据。

2.3 离线到在线强化学习相关工作

离线到在线强化学习（Offline-to-Online RL）旨在结合离线学习与在线学习的优势：先在离线数据集上预训练策略，再通过有限的在线交互进行微调，提升策略性能。该范式的核心挑战在于**灾难性遗忘（Catastrophic Forgetting）**：预训练策略在在线微调初期可能出现性能骤降，原因是策略约束的放松导致对分布外状态的访问增加，而价值函数对这些状态的估计不可靠。

2.3.1 保守性调节方法

当前主流方法通过在离线阶段采用保守算法、在线阶段逐步放松约束来平滑过渡[30]。AWAC[31]通过优势加权回归隐式约束策略接近数据集中的高质量动作，自然适配离线到在线转换。PEX[32]维护离线策略与在线策略的混合，根据在线性能动态调整混合权重，在安全性与灵活性之间取得平衡。Cal-QL[33] 发现离线预训练的 Q 值可能过于保守或乐观，提出通过校准 Q 值确保在线微调时策略有合理的改进方向。

该类方法的**优势**在于实现简单、训练稳定；**局限**在于离线阶段的保守性在在线阶段仍会阻碍策略灵活性，限制策略适应新数据的能力。

2.3.2 数据融合方法

另一类方法关注如何有效融合离线数据与在线数据。平衡重放（Balanced Replay）[34] 结合悲观 Q 集成与平衡采样策略，以固定比例从离线数据集与在线回放池中采样，避免在线数据稀少时的分布漂移。Q-Ensemble 方法[30] 利用多个 Q 网络的最小值抑制过估计，在在线阶段逐步放松保守约束。

该类方法的**优势**在于充分利用离线数据，缓解在线初期的数据稀疏问题；**局限**在于仍依赖被动采样，未能主动引导策略探索高价值区域。

2.3.3 现有方法的共同局限

综合分析现有离线到在线强化学习方法，存在以下共同局限：

(1) **保守性与灵活性的矛盾**：离线阶段的保守性约束在在线阶段仍会阻碍策略灵活性，使策略难以有效适应新数据。

(2) **在线交互成本高**：多数方法为无模型方法，需要频繁访问在线环境（通常需要 200k 步交互），成本较高。

(3) **不确定性利用不充分**：现有方法主要将不确定性用于惩罚高不确定性区域以保持保守性，而未能利用不确定性信息主动引导在线探索。

相比之下，近年基于模型的强化学习研究表明，模型的可靠性可以得到相对保证[22,26–28,35]。这启发我们探索一种基于模型的离线到在线强化学习算法：**在离线阶段利用不确定性保持保守性，在在线阶段利用不确定性引导探索**。当采集在线样本时，策略应被引导至高不确定性（转移模型覆盖之外）且高动作价值（接近目标）的区域，而非被动地在低不确定性区域内采样。

2.4 本章小结

本章首先介绍了强化学习的理论基础，包括 MDP 框架、基于模型的离线强化学习框架以及集成模型的不确定性估计方法。在相关工作部分，系统综述了离线强化学习与离线到在线强化学习的发展历程：

(1) **无模型离线强化学习**通过策略约束或价值正则化抑制分布外过估计，优势在于理论保证完善、实现简洁，局限在于样本效率低、保守性可能限制性能。

(2) **基于模型离线强化学习**通过学习转移模型提升样本效率，优势在于可生成额外数据，局限在于不确定性信息仅用于惩罚而非引导探索。

(3) **离线到在线强化学习**通过保守性调节或数据融合平滑过渡，优势在于结合两阶段优势，局限在于保守性与灵活性矛盾、在线交互成本高、不确定性利用不充分。

基于上述分析，本文提出基于定向探索模型的离线到在线强化学习算法（DEM）。DEM 继承了基于模型方法的样本效率优势，同时创新性地将不确定性信息用于**引导在线探索**而非仅用于惩罚：显式引导策略探索高不确定性且高价值的区域，有效补充转移模型，以最少的在线交互实现高效微调。

第三章 第三章标题

《正文》**********

3.1 章内标题 3.1

3.1.1 章内标题 3.1.1

《正文》**********

3.1.2 章内标题 3.1.2

《正文》**********

3.2 章内标题 3.2

《正文》**********

3.2.1 章内标题 3.2.1

《正文》**********

3.2.2 章内标题 3.2.2

《正文》**********

3.3 章内标题 3.3

《正文》**********

3.3.1 章内标题 3.3.1

《正文》**********

3.3.2 章内标题 3.3.2

《正文》**********

3.4 本章小结

《正文》**********

第四章 第四章标题

《正文》**********

4.1 章内标题 4.1

4.1.1 章内标题 4.1.1

《正文》**********

4.1.2 章内标题 4.1.2

《正文》**********

4.2 章内标题 4.2

《正文》**********

4.2.1 章内标题 4.2.1

《正文》**********

4.2.2 章内标题 4.2.2

《正文》**********

4.3 章内标题 4.3

《正文》**********

4.3.1 章内标题 4.3.1

《正文》**********

4.3.2 章内标题 4.3.2

《正文》**********

4.4 本章小结

《正文》**********

第五章 第五章标题

《正文》**********

5.1 章内标题 5.1

5.1.1 章内标题 5.1.1

《正文》**********

5.1.2 章内标题 5.1.2

《正文》**********

5.2 章内标题 5.2

《正文》**********

5.2.1 章内标题 5.2.1

《正文》**********

5.2.2 章内标题 5.2.2

《正文》**********

5.3 章内标题 5.3

《正文》**********

5.3.1 章内标题 5.3.1

《正文》**********

5.3.2 章内标题 5.3.2

《正文》**********

5.4 本章小结

《正文》**********

第六章 总结与展望

6.1 本文工作总结

《正文》**********

6.2 进一步研究方向

《正文》**********

参考文献

[1] Levine S, Kumar A, Tucker G, et al. Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems[J]. arXiv preprint arXiv:2005.01643, 2020.

[2] Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search [J]. Nature, 2016, 529(7587): 484–489.

[3] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C]. IEEE International Conference on Robotics and Automation (ICRA). 2019: 6023–6029.

[4] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[J]. arXiv preprint arXiv:2501.12948, 2025.

[5] Gottesman O, Johansson F, Komorowski M, et al. Guidelines for reinforcement learning in healthcare[J]. Nature Medicine, 2019, 25(1): 16–18.

[6] Kiran B R, Sobh I, Talpaert V, et al. Deep Reinforcement Learning for Autonomous Driving: A Survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(6): 4909–4926.

[7] Fujimoto S, Meger D, Precup D. Off-Policy Deep Reinforcement Learning without Exploration[C]. Proceedings of Machine Learning Research: volume 97 Proceedings of the 36th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2019: 2052–2062.

[8] Liu Y, Swaminathan A, Agarwal A, et al. Provably Good Batch Off-Policy Reinforcement Learning Without Great Exploration[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 1264–1274.

[9] Yu Q, Zhang Z, Zhu R, et al. DAPO: An Open-Source LLM Reinforcement Learning System at Scale[J]. arXiv preprint arXiv:2503.14476, 2025.

[10] Brohan A, Brown N, Carbajal J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[J]. arXiv preprint arXiv:2307.15818, 2023.

[11] 王雪松, 王荣荣, 程玉虎. 基于表征学习的离线强化学习方法研究综述[J]. 自动化学报, 2024, 50(6): 1104–1128.

[12] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. [S.l.]: MIT Press, 2018.

[13] Lakshminarayanan B, Pritzel A, Blundell C. Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 30. [S.l.: s.n.], 2017: 6402–6413.

[14] Wu Y, Tucker G, Nachum O. Behavior Regularized Offline Reinforcement Learning[J]. arXiv preprint arXiv:1911.11361, 2019.

[15] Xu H, Jiang L, Li J, et al. A Policy-Guided Imitation Approach for Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 4085–4098.

[16] Kumar A, Fu J, Soh M, et al. Stabilizing Off-Policy Q-Learning via Bootstrapping Error Reduction[J]. Ad-

vances in Neural Information Processing Systems (NeurIPS), 2019, 32.

[17] Lyu J, Ma X, Li X, et al. Mildly Conservative Q-Learning for Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 1711–1724.

[18] Kostrikov I, Nair A, Levine S. Offline Reinforcement Learning with Implicit Q-Learning[C]. Proceedings of the 10th International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2022.

[19] Fujimoto S, Gu S S. A Minimalist Approach to Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021: 20132–20145.

[20] Kumar A, Zhou A, Tucker G, et al. Conservative Q-Learning for Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 1179–1191.

[21] Janner M, Fu J, Zhang M, et al. When to Trust Your Model: Model-Based Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 32. [S.l.: s.n.], 2019: 12519–12530.

[22] Yu T, Thomas G, Yu L, et al. MOPO: Model-based Offline Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 14129–14142.

[23] Wang J, Li W, Jiang H, et al. Offline Reinforcement Learning with Reverse Model-based Imagination[J]. Advances in Neural Information Processing Systems (NeurIPS), 2021, 34: 29420–29432.

[24] Lu C, Ball P, Teh Y W, et al. Synthetic Experience Replay[J]. Advances in Neural Information Processing Systems (NeurIPS), 2024, 36.

[25] Kidambi R, Rajeswaran A, Netrapalli P, et al. MOReL: Model-Based Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 21810–21823.

[26] Rigter M, Lacerda B, Hawes N. RAMBO-RL: Robust Adversarial Model-Based Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 16082–16097.

[27] Yu T, Kumar A, Rafailov R, et al. COMBO: Conservative Offline Model-Based Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021: 28954–28967.

[28] Sun J, Jiang Y, Qiu J, et al. Conformal Prediction for Uncertainty-Aware Planning with Diffusion Dynamics Model[J]. Advances in Neural Information Processing Systems (NeurIPS), 2024, 36.

[29] Zhou G, Swaminathan S, Raju R V, et al. Diffusion Model Predictive Control[J]. arXiv preprint arXiv:2410.05364, 2024.

[30] Zhao K, Ma Y, Liu J, et al. Improving Offline-to-Online Reinforcement Learning with Q-Ensembles[C]. ICML Workshop on New Frontiers in Learning, Control, and Dynamical Systems. [S.l.: s.n.], 2023.

[31] Nair A, Gupta A, Dalal M, et al. AWAC: Accelerating Online Reinforcement Learning with Offline Datasets [J]. arXiv preprint arXiv:2006.09359, 2020.

[32] Zhang H, Xu W, Yu H. Policy Expansion for Bridging Offline-to-Online Reinforcement Learning[J]. arXiv preprint arXiv:2302.00935, 2023.

[33] Nakamoto M, Zhai Y, Singh A, et al. Cal-QL: Calibrated Offline RL Pre-Training for Efficient Online Fine-Tuning[C]. Proceedings of Machine Learning Research: volume 202 Proceedings of the 40th International

Conference on Machine Learning (ICML). [S.l.]: PMLR, 2023: 25675–25697.

[34] Lee S, Seo Y, Lee K, et al. Offline-to-Online Reinforcement Learning via Balanced Replay and Pessimistic Q-Ensemble[C]. Proceedings of Machine Learning Research: volume 164 Proceedings of the 5th Conference on Robot Learning (CoRL). [S.l.]: PMLR, 2022: 1702–1712.

[35] Yang J, Chen X, Wang S, et al. Model-based Offline Reinforcement Learning with Pessimism-Modulated Dynamics Belief[J]. arXiv preprint arXiv:2302.12279, 2023.

附录 A 程序清单

第三章 QAM 系统 CMA 算法程序（QAM programme 文件夹）

mainQAM_MSE_CMAvsCADAMA：QAM 系统，画 MSE 曲线主函数

mainQAM_SER_CMAvsCADAMA：QAM 系统，画 SER 曲线主函数

mainDQAM_SER_PhaseRotate：差分 QAM 系统，相位旋转下，画 SER 曲线主函数

mainDQAM_SER_Doppler：差分 QAM 系统，多普勒频移下，画 SER 曲线主函数

mainDQAM_SER_SNR：差分 QAM 系统，不同 SNR 下，画 SER 曲线主函数

第四章 QPSK 系统 CMA 算法程序（PSK programme 文件夹）

mainDPSK_SER_PhaseRotate：差分 PSK 系统，相位旋转下，画 SER 曲线主函数

mainDPSK_SER_Doppler：差分 PSK 系统，多普勒频移下，画 SER 曲线主函数

mainDPSK_SER_SNR：差分 PSK 系统，不同 SNR 下，画 SER 曲线主函数

FunQPSK：QPSK 编码子函数

FunDeQPSK_b：QPSK 解码子函数 (输出为比特)

第五章 CMA 频域均衡系统程序（FDE programme 文件夹）

main_CMAFDE：CMA 频域均衡主函数

FunCAZACSeGen：产生 CAZAC 序列子函数

Fun8PSK：8PSK 调制子函数

FunDe8PSK_s：8PSK 解调输出符号子函数

FunQPSK1：QPSK 调制幅度为 1 子函数

FunDeQPSK1_s：QPSK 解调输出符号幅度为 1 子函数

FunSDCMA22f：频域均衡 (2 2)SDCMA 算法子函数

附录 B 攻读专业学位硕士期间撰写的论文

[1] ** *, ** *, ** *, et al. **********[J]. IEEE Transactions on Wireless Communications, 2017, 6(8):360-371. （SCI 二区：000000000000001）

[2] ** *, ** *. **********[J]. Journal of China Universities of Posts & Telecommunications, 2016, 23(5):82-87.（EI：000000000000002）

[3] **，**********，电子学报，已录用。

附录 C 攻读专业学位硕士期间申请的专利

[1] 作者一，作者二，作者三. 专利名称，专利申请号，专利申请日期，专利授权日期；

[2] 张三，李四. 一种面向代理的安全传输方法，2007062.5，2016.1,2017.10；

[3] 张三. 一种实用的网络路由方法，200845610.5，2017,1,2018.1。

附录 D 攻读专业学位硕士期间参加的科研项目

[1] 项目类型，项目名称（项目编号）；

[2] 国家自然科学基金，基于安全移动代理新一代网络研究 (000000000001)；

[3] 国家自然科学基金，移动代理机制关键技术研究 (000000000002)。