单位代码： 10293 密 级： _____

南京邮电大学

专 业 学 位 硕 士 论 文

论文题目：基于不确定性探索模型的离线到在线强化学习算法

学 号 1223045728

姓 名 刘哲闰

导 师 张伯雷

专业学位类别 人工智能

类 型 全日制

专业（领域） 计算机技术

论文提交日期 2026 年 6 月

Offline-to-Online Reinforcement Learning with Directed Exploration Models

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of

Master of ENGINEERING

By

Zherun Liu

Supervisor: Prof. Bolei Zhang

June 2026

南京邮电大学学位论文原创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得南京邮电大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文及涉及相关资料若有不实，愿意承担一切相关的法律责任。

研究生学号：_____ 研究生签名：_____ 日期：_____

南京邮电大学学位论文使用授权声明

本人承诺所呈交的学位论文不涉及任何国家秘密，本人及导师为本论文的涉密责任并列第一责任人。

本人授权南京邮电大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档；允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索；可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文。本文电子文档的内容和纸质论文的内容相一致。论文的公布（包括刊登）授权南京邮电大学研究生院办理。

非国家秘密类涉密学位论文在解密后适用本授权书。

研究生签名：_____ 导师签名：_____ 日期：_____

摘要

《摘要正文》********** 中文摘要（两页），英文摘要，二者应基本对应。它是论文内容的高度概括，应说明研究目的、研究方法、成果和结论，要突出本论文的创造性成果或新的见解、用语简洁、准确。论文摘要的关键词 3 至 8 个。关键词应为公知公用的词和学术术语，不可采用自造字词和略写、符号等，词组不宜过长。

英文摘要采用第三人称单数语气介绍该学位论文内容，目的是便于其他文摘摘录，因此在写作英文文摘时不宜用第一人称的语气陈述。叙述的基本时态为一般现在时，确实需要强调过去的事情或者已经完成的行为才使用过去时、完成时等其他时态

关键词： **，**，**，**

Abstract

Abstract.....

Key Words: **,**,**,**

目 录

摘要 I
Abstract II
插图索引 V
表格索引 VI
专用术语注释表 VII
第一章 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.3 研究内容与主要工作 2
1.4 文章结构安排 2
第二章 理论基础与相关工作 3
2.1 理论基础 3
2.1.1 马尔可夫决策过程 3
2.1.2 基于模型的离线强化学习框架 4
2.1.3 集成模型与不确定性估计 5
2.2 相关工作 6
2.2.1 无模型离线强化学习 6
2.2.2 基于模型的离线强化学习 7
2.2.3 离线到在线强化学习 8
2.3 本章小结 8
第三章 基于对比表征学习的保守离线策略优化算法 10
3.1 问题分析与算法动机 10
3.2 对比表征学习框架 11
3.2.1 状态-动作联合表征网络 11
3.2.2 轨迹感知的对比学习目标 12
3.2.3 表征空间的分布建模 12
3.3 基于表征距离的自适应保守策略优化 13
3.3.1 自适应惩罚权重设计 13
3.3.2 保守 Q 学习算法 14
3.4 理论分析 15
3.5 算法流程 16
3.6 实验验证 17
3.6.1 实验设置 17
3.6.2 实验结果 17
3.6.3 表征空间分析 17
3.6.4 消融实验 18
3.7 本章小结 18
第四章 基于定向探索模型的离线到在线强化学习算法 20
4.1 问题分析与算法动机 20
4.2 算法框架 21
4.2.1 离线预训练阶段 21
4.2.2 在线定向探索阶段 22

4.3 不确定性估计与动态权重自适应 23
4.3.1 双重不确定性估计 23
4.3.2 动态权重自适应机制 24
4.4 理论分析 25
4.5 算法流程 26
4.6 实验验证 26
4.6.1 实验设置 27
4.6.2 实验结果 28
4.6.3 模型覆盖范围的可视化验证 29
4.6.4 动态权重自适应的消融实验 29
4.7 本章小结 30
第五章 总结与展望 31
5.1 本文工作总结 31
5.2 进一步研究方向 31
参考文献 32
附录 A 程序清单 35
附录 B 攻读专业学位硕士期间撰写的论文 36
附录 C 攻读专业学位硕士期间申请的专利 37
附录 D 攻读专业学位硕士期间参加的科研项目 38

插图索引

图 4.1 基于定向探索模型的离线到在线强化学习算法框架。离线阶段利用不确定性惩罚保守更新策略；在线阶段利用不确定性引导定向探索，采集的样本用于更新转移模型和策略。 21
图 4.2 模型预测状态与离线数据的对比。将模型预测状态和离线状态数据密度在三种不同离线数据集上进行可视化。散点表示模型的数据分布，预测 Q 值经归一化后作为散点的颜色。 29

表格索引

表 4.1 D4RL 基准测试集上的性能对比 28
表 4.2 动态权重自适应的消融实验结果 30

专用术语注释表

符号说明：

符号	表示含义
B_D	多普勒扩展

缩略词说明：

缩写	英文全称	中文译名
5G	5th Generation	第五代移动通信

第一章 绪论

1.1 研究背景与意义

强化学习（Reinforcement Learning, RL）是一种实现机器自主决策的人工智能范式，智能体通过与环境的持续交互学习最优策略，以最大化长期累积回报[1]。自深度强化学习在围棋[2]等领域取得突破以来，学术界与工业界持续将其应用拓展至更复杂的真实场景。近年来，强化学习在机器人控制[3]领域积累了丰富经验，并随着 DeepSeek-R1[4]在推理任务中的成功应用，开始广泛用于大语言模型的对齐与微调。

在线强化学习框架中，智能体直接与环境交互，通过试错优化行为策略。该方法具备良好的适应性，能够根据环境反馈及时调整策略，但需要大量交互样本。在医疗诊断[5]、自动驾驶[6]等数据采集成本高昂或存在安全约束的场景中，频繁的在线试错既不经济也存在风险，限制了在线强化学习的实际部署。

离线强化学习提供了一种替代方案：从预先收集的静态数据集中学习策略，避免在线交互的成本与风险。该范式依赖行为策略采集的历史数据，训练开销较小。然而，行为策略通常是次优的，且存在分布偏移问题[7]——训练数据分布与目标策略访问的状态-动作分布存在差异，导致价值函数对分布外动作的估计不准确。由于离线学习无法获得环境反馈修正估计误差，累积误差会引发对分布外动作价值的过高估计，产生外推误差[8]。如何从有限且可能存在偏差的数据中学习泛化能力良好的策略，是离线强化学习的核心挑战。

离线到在线强化学习结合了两种范式的优势：先在离线数据上预训练策略，再通过有限的在线交互进行微调，既利用了历史数据降低样本需求，又通过在线反馈提升策略性能。

当前离线到在线方法多采用无模型框架，侧重于离线与在线数据的融合策略，如平衡重放、优先级采样等。无模型方法的样本效率受限，难以充分挖掘大规模离线数据集的价值。本文研究基于不确定性探索模型的离线到在线强化学习算法，将优化重点置于环境动力学模型：利用离线策略与环境交互获取的在线数据优化状态转移模型，构建更准确且覆盖分布外区域的环境模型，进而完成策略更新。该方法以模型生成数据替代频繁的环境交互，在线开销较小，数据利用效率较高。

引入不确定性量化机制后，该方法在离线阶段可识别数据集中的高不确定性区域，对这些区域采取保守的策略更新；在线阶段则优先探索不确定性较高的状态-动作对，以较小的交互代价获取策略未覆盖区域的新数据。这种不确定性引导的探索机制提升了模型对环境变化的适应能力。

该算法适用于需要充分利用历史数据、同时在线探索受限的场景，如自动驾驶、金融决策、医疗优化等。基于模型的框架通过数据生成减少对在线交互的依赖，不确定性引导的探

索策略提升了在线微调的样本效率，在控制在线成本的同时实现策略性能的持续提升。

1.2 国内外研究现状

强化学习在决策优化领域的应用日趋成熟，学术界与工业界均取得了阶段性进展。在大语言模型领域，DeepSeek 发布的 R1 系列模型[4] 通过纯强化学习范式激发模型的复杂推理能力，验证了强化学习在语言模型对齐中的有效性；ByteDance 等团队提出的 DAPO 算法[9] 开源了大规模语言模型强化学习训练系统，在 Qwen2.5-32B 基座模型上实现了可复现的推理能力训练。在具身智能领域，Google DeepMind 研发的 RT-2 模型[10] 将视觉-语言预训练知识迁移至机器人控制，提升了机器人在真实环境中的语义理解与操作泛化能力。在离线强化学习理论研究方面，王雪松等[11] 系统梳理了基于表征学习的离线强化学习方法，分析了特征解耦对策略迁移能力的增强作用。

上述进展表明强化学习在大模型对齐、表征学习、复杂场景适配等方向取得了实质性成果，但也对离线到在线强化学习技术提出了更高要求。当前该领域仍面临若干技术挑战：离线阶段基于固定数据集训练的策略在在线环境中因数据分布差异易产生性能衰减，而在线微调过程中又可能丢失离线阶段习得的知识，现有方案通过动态策略调整、重要性加权等机制尝试平衡两者，但需针对具体任务分析数据分布特性并设计回放机制，开发成本较高。此外，探索-利用权衡是强化学习的固有难题，离线到在线的两阶段模式进一步放大了这一矛盾——离线阶段需保持策略保守性以规避数据偏差风险，在线阶段又需探索未知区域以适配环境变化，两阶段对探索强度的需求相反，RT-2 模型虽提升了泛化能力，但未形成适配两阶段特性的动态探索机制。在数据利用效率方面，离线数据集的知识常未被充分利用，策略在微调阶段易丢失预训练知识；在线交互虽能获取环境反馈，但频繁访问环境会削弱离线学习低成本的优势，如何在提升数据利用率的同时控制在线开销，是该领域亟待解决的问题。

上述挑战推动了基于不确定性探索等技术方案的研究，也是本文的研究出发点。

1.3 研究内容与主要工作

1.4 文章结构安排

第二章 理论基础与相关工作

本章首先介绍强化学习的理论基础，建立本文所需的数学框架；随后对离线强化学习、离线到在线强化学习领域的相关工作进行系统综述，分析现有方法的发展脉络、核心优势与局限，阐明本文研究动机。

2.1 理论基础

2.1.1 马尔可夫决策过程

强化学习问题通常建模为马尔可夫决策过程（Markov Decision Process, MDP）[12]。MDP 由六元组 $M = (\mathcal{S}, \mathcal{A}, T, r, \mu_0, \gamma)$ 定义，其中 $\mathcal{S}$ 表示状态空间，包含智能体可能处于的所有状态；$\mathcal{A}$ 表示动作空间，包含智能体可执行的所有动作；$r : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$ 为奖励函数，量化状态-动作对的即时收益；$T(s'|s, a)$ 为状态转移概率函数，定义在状态 s 执行动作 a 后转移至状态 s' 的条件概率；μ_0 为初始状态分布；$\gamma \in (0, 1)$ 为折扣因子，用于调节即时奖励与未来奖励的相对权重。

在 MDP 框架中，智能体的行为由策略 $\pi(a|s)$ 刻画，表示在状态 s 下选择动作 a 的条件概率分布。强化学习的核心任务是寻找最优策略，为此需要定义价值函数以量化策略的长期累积收益。

状态价值函数 $V_M^\pi(s)$ 定义为在 MDP M 中，从状态 s 出发并遵循策略 π 所能获得的期望折扣回报：

$$V_M^\pi(s) = \mathbb{E}_{\pi,M}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s\right] \tag{2.1}$$

其中 s_t 和 a_t 分别表示时刻 t 的状态和动作，期望在策略 π 和环境动力学 M 下计算。状态价值函数衡量的是智能体处于特定状态时的长期预期收益。

动作价值函数 $Q_M^\pi(s, a)$ 定义为在状态 s 执行动作 a 后，继续遵循策略 π 所能获得的期望折扣回报：

$$Q_M^\pi(s, a) = \mathbb{E}_{\pi,M}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a\right] \tag{2.2}$$

动作价值函数衡量的是在特定状态下执行特定动作的长期预期收益。

状态价值函数与动作价值函数之间存在如下关系：

$$V_M^\pi(s) = \mathbb{E}_{a\sim\pi(\cdot|s)}[Q_M^\pi(s, a)] = \sum_{a\in\mathcal{A}} \pi(a|s) Q_M^\pi(s, a) \tag{2.3}$$

即状态价值等于该状态下所有动作价值在策略分布下的期望。反之，动作价值函数可通过贝尔曼期望方程表示为：

$$Q_M^\pi(s,a) = r(s,a) + \gamma \mathbb{E}_{s' \sim T(\cdot|s,a)}[V_M^\pi(s')] \tag{2.4}$$

即当前奖励与后继状态价值折扣期望之和。

为分析策略在状态-动作空间上的访问行为，引入折扣状态-动作访问分布 $\rho_M^\pi(s,a)$，定义为策略 π 在 MDP M 中访问状态-动作对 (s,a) 的非归一化折扣频率：

$$\rho_M^\pi(s,a) = \pi(a|s) \sum_{t=0}^{\infty} \gamma^t P(s_t = s|\pi, M) \tag{2.5}$$

其中 $P(s_t = s|\pi, M)$ 表示从初始分布 μ_0 出发，遵循策略 π 于时刻 t 到达状态 s 的概率。该分布刻画了策略的状态-动作空间覆盖特性：$\rho_M^\pi(s,a)$ 值较大的区域对应策略频繁访问的区域，反之则对应策略较少探索的区域。

基于上述定义，策略的期望折扣回报 η_M^π 作为评估策略整体性能的核心指标，可通过以下三种等价形式表示：

$$\eta_M^\pi = \mathbb{E}_{s_0 \sim \mu_0}[V_M^\pi(s_0)] = \mathbb{E}_{s_0 \sim \mu_0, a_0 \sim \pi(\cdot|s_0)}[Q_M^\pi(s_0,a_0)] = \mathbb{E}_{(s,a) \sim \rho_M^\pi}[r(s,a)] \tag{2.6}$$

第一种形式从初始状态价值的角度表述期望回报；第二种形式从初始状态-动作价值的角度表述，便于与基于 Q 函数的算法衔接；第三种形式从访问分布的角度表述，将期望回报理解为策略访问的所有状态-动作对上奖励的加权平均。MDP 的优化目标是求解最大化期望折扣回报的最优策略 $\pi^* = \arg\max_\pi \eta_M^\pi$。

归一化状态-动作访问分布定义为 $\tilde{\rho}_M^\pi(s,a) = (1-\gamma) \cdot \rho_M^\pi(s,a)$，满足 $\sum_{s,a} \tilde{\rho}_M^\pi(s,a) = 1$，构成状态-动作空间上的概率分布。在离线强化学习中，训练数据的分布 ρ_D 与目标策略的访问分布 ρ_M^π 之间的差异构成分布偏移问题的根源：当目标策略访问的状态-动作对在训练数据中覆盖不足时，价值函数的估计将产生显著偏差。

2.1.2 基于模型的离线强化学习框架

在离线强化学习场景中，智能体仅能访问由行为策略 π_D 预先采集的静态数据集 $\mathcal{D}_{off} = \{(s_i, a_i, s_i', r_i)\}_{i=1}^N$，无法与真实环境进行在线交互。基于模型的离线强化学习方法通过监督学习从离线数据中构建环境转移模型 $\hat{T}_\theta(s', r|s,a)$，该模型以当前状态 s 和动作 a 为输入，预测下一状态 s' 及即时奖励 r 的联合分布。

转移模型通常采用参数化高斯分布进行建模：

$$\hat{T}_\theta(s', r|s, a) = \mathcal{N}(\mu_\theta(s, a), \Sigma_\theta(s, a)) \tag{2.7}$$

其中 $\mu_\theta(s, a)$ 为条件均值函数，$\Sigma_\theta(s, a)$ 为条件协方差矩阵，均由参数为 θ 的神经网络拟合。模型参数通过最大化离线数据的对数似然进行优化：

$$\mathcal{L}(\theta) = -\mathbb{E}_{(s,a,s',r)\sim\mathcal{D}_{off}}[\log \hat{T}_\theta(s', r|s, a)] \tag{2.8}$$

完成模型学习后，策略可通过与学习得到的转移模型交互生成虚拟轨迹进行优化，无需访问真实环境。这一特性使基于模型的方法具有更高的样本效率，尤其适用于数据采集成本高昂的实际应用场景。

然而，学习得到的转移模型与真实环境之间不可避免地存在模型误差。当策略访问离线数据覆盖不足的状态-动作区域时，模型预测的可靠性下降，外推误差将随模型推演（rollout）步数累积放大，最终导致策略性能退化。因此，如何量化并控制模型不确定性、抑制分布外区域的过估计，是基于模型离线强化学习的核心挑战。

2.1.3 集成模型与不确定性估计

集成方法（Ensemble Methods）通过训练多个独立初始化的模型，利用模型间预测的分歧度量化不确定性[13]。设集成包含 N 个模型 $\{f_\phi^1, \ldots, f_\phi^N\}$，每个模型在相同数据集上独立训练但采用不同的随机初始化，则预测不确定性可通过集成预测的统计特性进行估计。

强化学习中的不确定性可从来源角度分为两类[14]。认知不确定性（Epistemic Uncertainty）源于模型对环境知识的缺乏，反映训练数据覆盖不足导致的模型不确定性，可通过收集更多数据逐步降低。偶然不确定性（Aleatoric Uncertainty）源于环境固有的随机性，反映状态转移过程本身的内在噪声，无法通过增加数据量消除。

对于离线到在线强化学习，认知不确定性具有特殊重要性：高认知不确定性区域对应离线数据覆盖不足的状态-动作空间，恰恰是在线探索应优先关注的目标区域。通过识别并引导策略探索这些高不确定性区域，可有效补充转移模型的训练数据，提升模型在全状态-动作空间的泛化能力。

在基于模型的强化学习中,集成动力学模型的每个成员 $\hat{T}_\phi^i$ 输出高斯分布 $\mathcal{N}(\mu_\phi^i(s, a), \Sigma_\phi^i(s, a))$。其中，单个模型的预测方差 $\Sigma_\phi^i(s, a)$ 反映偶然不确定性，刻画环境动力学的内在随机性。为

捕捉认知不确定性，可利用集成模型均值预测的分歧度定义如下度量：

$$\mathrm{DisVar}(s,a) = \frac{1}{d}\sum_{j=1}^{d} \mathrm{Var}_{i=1,\ldots,N}[\mu^{i}_{\phi,j}(s,a)] \tag{2.9}$$

其中 d 为预测向量的维度，$\mu^{i}_{\phi,j}(s,a)$ 表示第 i 个模型预测均值的第 j 个分量，$\mathrm{Var}_{i=1,\ldots,N}[\cdot]$ 表示在 N 个集成成员间计算方差。该度量的核心思想是：在数据充分覆盖的区域，各模型收敛至相近的预测，分歧度较低；在数据稀疏的区域，模型因初始化差异而产生显著不同的预测，分歧度较高。本文将在算法设计中融合两类不确定性信息，实现更高效的在线探索策略。

2.2 相关工作

离线强化学习（Offline Reinforcement Learning）旨在仅利用预先收集的静态数据集学习策略，而不与环境进行交互[1]。该范式在机器人控制[3]、自动驾驶[6]、医疗决策[5] 等探索成本高昂或存在安全风险的领域具有重要应用价值。离线强化学习面临的核心挑战是分布偏移（Distribution Shift）问题[7]：当学习策略与行为策略差异较大时，策略可能访问离线数据集未覆盖的状态-动作对，导致价值函数产生外推误差（Extrapolation Error）[8]。根据是否学习环境模型，离线强化学习方法可分为无模型方法和基于模型方法两大类。

2.2.1 无模型离线强化学习

无模型离线强化学习直接利用离线数据优化策略，其核心思想是在价值函数或策略中引入保守性约束，避免对分布外动作的过估计[15–19]。该领域的发展大致经历了从策略约束到价值正则化的演进过程。

早期研究聚焦于策略约束方法。BCQ[7] 首次系统分析了离线强化学习中的外推误差问题，提出通过条件变分自编码器（CVAE）建模行为策略，并利用扰动网络在行为策略支撑集内选择动作，从而避免对未见动作的查询。BRAC[15] 进一步系统研究了策略正则化方法，通过在策略优化目标中添加 KL 散度或 MMD 度量作为正则项，显式约束学习策略与行为策略的距离。TD3+BC[20] 则发现简洁的行为克隆正则项 $\lambda \cdot \|\pi(s) - a\|^2$ 即可实现有效的策略约束，在保持性能的同时大幅简化算法设计。策略约束方法直观有效地避免了分布外动作，但策略改进空间受行为策略质量限制，难以超越数据集中最优轨迹的性能。

后续研究转向从价值函数角度抑制过估计。CQL[21] 提出在标准 Bellman 误差基础上引入正则项 $\alpha \cdot (\mathbb{E}_{a\sim\pi}[Q(s,a)] - \mathbb{E}_{a\sim\mathcal{D}}[Q(s,a)])$，通过推低策略分布下动作的 Q 值、推高数据集内动作的 Q 值，学习 Q 值的保守下界。MCQ[18] 针对 CQL 可能过度惩罚的问题，引入更温和的保守约束，仅对 Q 值高于数据集内最大 Q 值的动作施加惩罚。IQL[19] 采用期望回归（Expectile

Regression）学习价值函数，通过非对称损失函数 $L_\tau(u) = |\tau - \mathbf{1}(u < 0)| \cdot u^2$ 隐式逼近最优 Q 值，完全避免对分布外动作的显式查询，在多个基准任务上取得了优异性能。价值正则化方法无需显式建模行为策略，理论保证更为完善，但保守性可能过强，导致策略性能低于数据集中最优轨迹。

无模型方法的共同局限在于无法生成新的数据样本，样本效率较低，且保守性约束可能限制策略的潜在性能。

2.2.2 基于模型的离线强化学习

基于模型的离线强化学习首先从离线数据学习环境转移模型，再通过与模型交互生成虚拟样本优化策略[22–25]。该类方法可利用模型生成额外数据提升样本效率，但模型在分布外区域的预测可能产生外推误差[8]，且误差会随模型推演（rollout）步数累积，导致性能退化。因此，如何在利用模型数据与保持保守性之间取得平衡，是基于模型离线强化学习的核心问题。

不确定性惩罚方法是该领域的主流范式。MOPO[23] 提出通过集成模型估计状态转移的不确定性，并将不确定性量化值作为惩罚项从奖励中扣除：$\tilde{r}(s,a) = r(s,a) - \lambda \cdot u(s,a)$，其中 $u(s,a)$ 为集成模型预测的标准差。该方法约束策略在低不确定性区域内优化，并提供了理论保证的策略性能下界。然而，惩罚系数 λ 需要针对不同任务调整，且过强的惩罚可能过度限制策略探索。

悲观 MDP 方法从构建保守环境模型的角度实现保守性。MOReL[26] 构建悲观 MDP：当集成模型的预测分歧度超过阈值 ϵ 时，将状态转移至吸收态并给予固定负奖励 r_{halt}，从而将策略优化限制在高置信区域内。RAMBO[27] 则通过对抗训练学习悲观模型，在模型集成中选择使策略性能最差的转移，无需显式设定不确定性阈值。该类方法提供更强的安全保证，但悲观性可能过强导致策略过于保守。

保守价值估计方法将无模型方法的保守性与模型数据结合。COMBO[28] 在模型生成数据上采用 CQL 的保守 Q 学习，在真实数据上进行标准 Bellman 更新，兼顾数据效率与保守性。MORI[24] 提出反向模型推演（Reverse Imagination），从数据集状态反向生成轨迹，避免模型误差随正向推演累积。近年来，研究者开始引入扩散模型提升转移模型的表达能力[29,30]，能够更好地捕捉多模态转移分布。

尽管上述方法在一定程度上缓解了外推误差，但其核心局限在于不确定性信息仅用于惩罚高不确定性区域，而非主动引导策略补充这些区域的数据。这导致模型在分布外区域的泛化能力始终受限，难以突破离线数据的覆盖边界。

2.2.3 离线到在线强化学习

离线到在线强化学习（Offline-to-Online RL）旨在结合离线学习与在线学习的优势：先在离线数据集上预训练策略，再通过有限的在线交互进行微调，提升策略性能。该范式的核心挑战在于灾难性遗忘（Catastrophic Forgetting）问题：预训练策略在在线微调初期可能出现性能骤降，原因是策略约束的放松导致对分布外状态的访问增加，而价值函数对这些状态的估计不可靠[31]。

当前主流方法可分为保守性调节和数据融合两类。保守性调节方法通过在离线阶段采用保守算法、在线阶段逐步放松约束来实现平滑过渡。AWAC[32] 通过优势加权回归优化策略，以指数优势函数 $\exp(A(s,a)/\lambda)$ 对数据集中的动作进行加权，隐式约束策略接近高质量动作，该方法自然适配离线到在线转换，无需修改算法即可在两阶段间切换。PEX[33] 维护离线策略 π_{off} 与在线策略 π_{on} 的混合 $\pi = \alpha\pi_{off} + (1-\alpha)\pi_{on}$，根据在线性能动态调整混合权重 α，在安全性与灵活性之间取得平衡。Cal-QL[34] 发现离线预训练的 Q 值可能过于保守或过于乐观，提出通过校准 Q 值下界确保在线微调时策略有合理的改进方向。数据融合方法则关注如何有效利用离线数据与在线数据的互补性。平衡重放[31] 结合悲观 Q 集成与平衡采样策略，以固定比例从离线数据集与在线回放池中采样，同时采用多个 Q 网络的最小值 $\min_i Q_i(s,a)$ 抑制过估计，在在线阶段逐步减少 Q 网络数量以放松保守约束。E2O[35] 进一步研究了 Q 集成在离线到在线转换中的作用，发现适当的集成规模和放松策略对于平滑过渡至关重要。

综合分析现有离线到在线强化学习方法，存在以下共同局限：（1）保守性与灵活性的矛盾：离线阶段的保守性约束在在线阶段仍会阻碍策略灵活性，使策略难以有效适应新数据；（2）在线交互成本高：多数方法为无模型方法，需要频繁访问在线环境（通常需要 200k 步交互），成本较高；（3）不确定性利用不充分：现有方法主要将不确定性用于惩罚高不确定性区域以保持保守性，而未能利用不确定性信息主动引导在线探索。相比之下，近年基于模型的强化学习研究表明，集成动力学模型的可靠性可以得到相对保证[23,27–29,36]。这启发我们探索一种基于模型的离线到在线强化学习算法：在离线阶段利用不确定性保持保守性，在在线阶段利用不确定性引导探索。具体而言，当采集在线样本时，策略应被引导至高不确定性（转移模型覆盖之外）且高动作价值（接近目标）的区域，主动补充转移模型的训练数据，而非被动地在低不确定性区域内采样。

2.3 本章小结

本章首先介绍了强化学习的理论基础，包括 MDP 框架、基于模型的离线强化学习框架以及集成模型的不确定性估计方法。在相关工作部分，系统综述了离线强化学习与离线到在线强化学习的发展历程：无模型离线强化学习通过策略约束或价值正则化抑制分布外过估计，

优势在于理论保证完善、实现简洁，局限在于样本效率低、保守性可能限制性能；基于模型离线强化学习通过学习转移模型提升样本效率，优势在于可生成额外数据，局限在于不确定性信息仅用于惩罚而非引导探索；离线到在线强化学习通过保守性调节或数据融合平滑过渡，优势在于结合两阶段优势，局限在于保守性与灵活性矛盾、在线交互成本高、不确定性利用不充分。

基于上述分析，本文提出基于定向探索模型的离线到在线强化学习算法。这种方法继承了基于模型方法的样本效率优势，同时创新性地将不确定性信息用于引导在线探索而非仅用于惩罚：显式引导策略探索高不确定性且高价值的区域，有效补充转移模型，以最少的在线交互实现高效微调。

第三章 基于对比表征学习的保守离线策略优化算法

本章详细介绍本文提出的基于对比表征学习的保守离线策略优化算法。首先分析现有离线强化学习方法在分布外检测与保守性调节方面的局限性；随后阐述利用对比学习构建状态-动作表征空间的方法，实现对分布外样本的显式识别；接着设计基于表征距离的自适应保守惩罚机制，使算法在分布内区域保留优化空间的同时对分布外区域施加强约束；最后通过在 D4RL 基准测试集上的实验验证算法的有效性。

3.1 问题分析与算法动机

如第二章所述，离线强化学习面临的核心挑战是分布偏移问题：当学习策略与行为策略差异较大时，策略可能访问离线数据集未覆盖的状态-动作对，导致价值函数产生外推误差。现有方法通过引入保守性约束抑制分布外过估计，但存在以下根本性局限：

第一，分布外检测机制不够精确。现有无模型方法（如 CQL）通过惩罚策略分布与数据分布的差异隐式识别分布外动作，但这种全局性惩罚无法区分不同状态-动作对的分布外程度。基于模型的方法（如 MOPO）利用集成模型的预测分歧度估计不确定性，但需要训练多个独立模型，计算开销较大，且分歧度与真实的分布外程度并非严格对应。

第二，保守性约束缺乏自适应性。CQL 采用固定的正则化系数 α 对所有状态施加相同强度的保守约束，这在分布内区域可能过于保守，限制了策略的改进空间；而在分布外区域又可能约束不足，无法有效抑制过估计。理想的保守性机制应根据样本的分布外程度自适应调节惩罚强度。

第三，缺乏对状态-动作空间结构的显式建模。现有方法主要关注价值函数或动力学模型的学习，而忽视了状态-动作空间本身的结构特性。离线数据集定义了一个隐式的支撑集，如何显式刻画这一支撑集的边界，是实现精确分布外检测的关键。

基于上述分析，本文提出利用对比学习构建状态-动作表征空间的核心思想。对比学习通过拉近正样本对、推远负样本对，可学习到紧致且结构化的表征空间。在该空间中，离线数据集中的样本聚集在表征中心附近，而分布外样本则远离中心。基于表征距离可实现对分布外程度的显式量化，进而设计自适应的保守惩罚机制：对分布内样本施加较弱惩罚，保留策略优化空间；对分布外样本施加较强惩罚，有效抑制过估计。

3.2 对比表征学习框架

本节介绍利用对比学习构建状态-动作表征空间的方法。首先阐述状态-动作联合编码器的网络结构，随后介绍轨迹感知的对比学习目标，最后描述表征空间的分布建模方法。

3.2.1 状态-动作联合表征网络

为在统一的表征空间中刻画状态-动作对的分布特性，本文设计状态-动作联合编码器 $f_\psi : \mathcal{S} \times \mathcal{A} \to \mathbb{R}^{d_z}$，将原始状态-动作对映射至低维表征空间。编码器采用模块化设计，包含状态编码器、动作编码器和融合网络三个组件。

状态编码器 $f_s : \mathbb{R}^{d_s} \to \mathbb{R}^{d_h}$ 将原始状态向量映射至隐藏表征：

$$h_s = f_s(s) = \text{MLP}_s(s; \psi_s) \tag{3.1}$$

其中 MLP_s 为多层感知机，包含两个隐藏层，每层 256 个神经元，使用 ReLU 激活函数。d_h 为隐藏表征维度，通常取 256。

动作编码器 $f_a : \mathbb{R}^{d_a} \to \mathbb{R}^{d_h}$ 将动作向量映射至相同维度的隐藏表征：

$$h_a = f_a(a) = \text{MLP}_a(a; \psi_a) \tag{3.2}$$

融合网络将状态表征和动作表征合并，生成状态-动作联合表征：

$$h = h_s + h_a \tag{3.3}$$

本文采用加法融合而非拼接融合，以保持表征维度适中并促进状态与动作信息的交互。

在联合表征之上，添加投影头 $g : \mathbb{R}^{d_h} \to \mathbb{R}^{d_z}$ 将表征投影至对比学习空间：

$$z = g(h) = \text{MLP}_g(h; \psi_g) \tag{3.4}$$

投影头采用两层 MLP 结构，输出维度 d_z 通常取 128。最终的状态-动作表征为：

$$z(s, a) = g(f_s(s) + f_a(a)) \tag{3.5}$$

采用投影头的设计遵循对比学习的最佳实践[37]：投影头可过滤与对比任务无关的信息，使编码器学习更通用的表征。在后续的策略优化阶段，使用投影前的表征 h 而非投影后的 z，以保留更多任务相关信息。

3.2.2 轨迹感知的对比学习目标

对比学习的核心是定义合适的正样本对和负样本对。在离线强化学习场景中，本文提出轨迹感知的对比学习目标，利用轨迹的时序结构定义样本关系。

正样本对定义为同一轨迹内时间相邻的状态-动作对。设轨迹 $\tau = \{(s_0, a_0), (s_1, a_1), \ldots, (s_T, a_T)\}$，则 (s_t, a_t) 与 (s_{t+1}, a_{t+1}) 构成正样本对。这一定义基于以下直觉：时间相邻的状态-动作对由环境动力学关联，在表征空间中应保持接近。

负样本对定义为来自不同轨迹的状态-动作对。设 $(s_i, a_i) \in \tau_1$ 和 $(s_j, a_j) \in \tau_2$，其中 $\tau_1 \neq \tau_2$，则二者构成负样本对。不同轨迹的样本可能对应不同的行为模式或环境区域，在表征空间中应保持距离。

基于上述定义，采用 InfoNCE 损失[38] 作为对比学习目标：

$$\mathcal{L}_{CL} = -\mathbb{E}_{\tau\sim\mathcal{D}}\left[\sum_{t=0}^{T-1}\log\frac{\exp(\mathrm{sim}(z_t, z_{t+1})/\tau_{temp})}{\exp(\mathrm{sim}(z_t, z_{t+1})/\tau_{temp}) + \sum_{k\in\mathcal{N}_t}\exp(\mathrm{sim}(z_t, z_k)/\tau_{temp})}\right] \tag{3.6}$$

其中 $z_t = z(s_t, a_t)$ 为时刻 t 的状态-动作表征，$\mathrm{sim}(u, v) = u^\top v/(\|u\|\|v\|)$ 为余弦相似度，τ_{temp} 为温度参数，$\mathcal{N}_t$ 为时刻 t 的负样本集合。

温度参数 τ_{temp} 控制对比损失的平滑程度：较小的温度使损失对困难负样本更敏感，有助于学习更具区分性的表征；较大的温度则使优化更稳定。本文取 $\tau_{temp} = 0.1$，在区分性与稳定性之间取得平衡。

负样本集合 $\mathcal{N}_t$ 的构造采用批内负采样策略：在每个训练批次中，除正样本外的所有样本均作为负样本。设批次大小为 B，每条轨迹长度为 L，则每个锚点样本对应约 $B \times L - 2$ 个负样本（排除自身和正样本）。

轨迹感知对比学习的优势在于：（1）利用时序结构定义正样本，无需数据增强或人工标注；（2）使表征空间不仅反映静态分布，还隐式编码动力学关联；（3）与后续章节的动力学模型学习形成互补视角。

3.2.3 表征空间的分布建模

完成对比学习预训练后，需对表征空间中离线数据的分布进行建模，为后续的分布外检测提供基准。本文采用高斯分布对表征空间进行参数化建模。

首先，计算离线数据集在表征空间中的均值向量：

$$\mu_{\mathcal{D}} = \frac{1}{|\mathcal{D}|}\sum_{(s,a)\in\mathcal{D}} z(s, a) \tag{3.7}$$

其中 $|\mathcal{D}|$ 为离线数据集的样本数量。均值向量 $\mu_{\mathcal{D}}$ 表示离线数据在表征空间中的中心位置。

其次，计算协方差矩阵以刻画分布的形状：

$$\Sigma_{\mathcal{D}} = \frac{1}{|\mathcal{D}|} \sum_{(s,a)\in\mathcal{D}} (z(s,a) - \mu_{\mathcal{D}})(z(s,a) - \mu_{\mathcal{D}})^{\top} \tag{3.8}$$

基于上述统计量，定义状态-动作对 (s,a) 相对于离线数据分布的距离度量。本文考虑两种距离度量：

欧氏距离直接度量表征向量与分布中心的 L_2 距离：

$$d_{L2}(s,a) = \|z(s,a) - \mu_{\mathcal{D}}\|_2 \tag{3.9}$$

马氏距离在欧氏距离基础上考虑分布的协方差结构，对各维度进行归一化：

$$d_{Maha}(s,a) = \sqrt{(z(s,a) - \mu_{\mathcal{D}})^{\top} \Sigma_{\mathcal{D}}^{-1} (z(s,a) - \mu_{\mathcal{D}})} \tag{3.10}$$

马氏距离的优势在于：当表征空间各维度的方差差异较大时，马氏距离可避免高方差维度主导距离计算，提供更合理的分布外度量。

为确定分布内与分布外的边界，基于离线数据集的距离分布设定阈值：

$$d_{threshold} = \text{Percentile}_p\{d(s,a) : (s,a) \in \mathcal{D}\} \tag{3.11}$$

其中 Percentile_p 表示 p 分位数。本文取 $p = 95$，即离线数据集中 95% 样本的距离小于阈值。超过阈值的样本被视为分布外样本，需施加较强的保守惩罚。

3.3 基于表征距离的自适应保守策略优化

本节介绍如何利用表征距离实现自适应的保守策略优化。首先阐述自适应惩罚权重的设计，随后介绍保守 Q 学习算法的完整框架。

3.3.1 自适应惩罚权重设计

传统保守性方法采用固定的惩罚系数，无法适应不同样本的分布外程度。本文提出基于表征距离的自适应惩罚权重，使惩罚强度随分布外程度平滑变化。

定义自适应惩罚权重函数：

$$\lambda(s,a) = \lambda_0 \cdot \sigma\left(\beta \cdot (d(s,a) - d_{threshold})\right) \tag{3.12}$$

其中 λ_0 为基础惩罚系数，β 为调节过渡陡峭程度的参数，$\sigma(\cdot)$ 为 Sigmoid 函数，$d(s,a)$ 为表征距离，$d_{threshold}$ 为分布边界阈值。

该设计具有以下性质：

第一，当 $d(s,a) \ll d_{threshold}$ 时，$(d(s,a) - d_{threshold})$ 为较大负数，$\sigma(\cdot) \approx 0$，因此 $\lambda(s,a) \approx 0$。这意味着对分布内样本几乎不施加惩罚，保留策略的完整优化空间。

第二，当 $d(s,a) \gg d_{threshold}$ 时，$(d(s,a) - d_{threshold})$ 为较大正数，$\sigma(\cdot) \approx 1$，因此 $\lambda(s,a) \approx \lambda_0$。这意味着对分布外样本施加完整惩罚，有效抑制过估计。

第三，当 $d(s,a) \approx d_{threshold}$ 时，$\lambda(s,a) \approx \lambda_0/2$，惩罚强度处于中间水平。Sigmoid 函数确保惩罚权重在分布边界附近平滑过渡，避免策略优化过程中的梯度不连续。

参数 β 控制过渡区域的宽度：较大的 β 使过渡更陡峭，惩罚权重在阈值附近快速变化；较小的 β 使过渡更平滑，惩罚权重渐变。本文通过实验选取 $\beta = 5$，在区分性与平滑性之间取得平衡。

3.3.2 保守 Q 学习算法

基于自适应惩罚权重，本文提出保守 Q 学习算法。核心思想是在 Q 值估计中引入基于表征距离的惩罚项，使 Q 值对分布外动作保持保守。

定义保守 Q 值估计：

$$\tilde{Q}(s,a) = Q_\theta(s,a) - \lambda(s,a) \cdot d(s,a) \tag{3.13}$$

其中 $Q_\theta(s,a)$ 为神经网络参数化的原始 Q 值估计，$\lambda(s,a)$ 为自适应惩罚权重，$d(s,a)$ 为表征距离。保守 Q 值通过减去惩罚项，降低对分布外动作的价值估计。

Q 网络的训练目标为最小化时序差分误差：

$$\mathcal{L}_Q(\theta) = \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}}\left[(Q_\theta(s,a) - y)^2\right] \tag{3.14}$$

其中目标值 y 基于保守 Q 值计算：

$$y = r + \gamma \mathbb{E}_{a'\sim\pi_\varphi(\cdot|s')}\left[\min_{j=1,2} \tilde{Q}_{\bar{\theta}_j}(s',a') - \alpha \log \pi_\varphi(a'|s')\right] \tag{3.15}$$

其中 $\tilde{Q}_{\bar{\theta}}$ 为目标网络的保守 Q 值估计，α 为熵正则化系数。采用双 Q 网络[39] 取最小值以

进一步抑制过估计。

策略网络的训练目标为最大化保守 Q 值与策略熵的加权和：

$$J(\varphi) = \mathbb{E}_{s\sim\mathcal{D},a\sim\pi_\varphi(\cdot|s)}\left[\tilde{Q}(s,a) - \alpha \log \pi_\varphi(a|s)\right] \tag{3.16}$$

策略在保守 Q 值的引导下，倾向于选择分布内的高价值动作，自然规避分布外区域。

与 CQL[21] 相比，本文方法的保守性更加精细：CQL 通过正则项 $\mathbb{E}_\pi[Q] - \mathbb{E}_\mathcal{D}[Q]$ 全局性地压低策略分布下的 Q 值，而本文方法仅对分布外样本施加惩罚，分布内样本保留完整的优化空间。这使得策略在高质量离线数据上能够充分学习，同时对低质量或未覆盖区域保持保守。

3.4 理论分析

本节从理论角度分析基于表征距离的自适应保守惩罚相比固定惩罚的优势。核心结论是：自适应惩罚可获得更紧的策略性能下界。

首先引入策略性能下界的概念。设 $\eta(\pi)$ 为策略 π 的真实期望回报，$\hat{\eta}(\pi)$ 为基于学习得到的 Q 函数估计的期望回报。理想的保守算法应确保 $\hat{\eta}(\pi) \le \eta(\pi)$，即估计的性能不超过真实性能，从而避免选择实际表现不佳的策略。

定理 3.1 (自适应惩罚的性能下界)**.** *设 π 为任意策略，$\tilde{Q}$ 为基于自适应惩罚的保守 Q 值估计。若惩罚权重 $\lambda(s,a)$ 满足：*

$$\lambda(s,a) \ge \frac{|Q^*(s,a) - Q_\theta(s,a)|}{d(s,a) + \epsilon} \tag{3.17}$$

其中 Q^* 为最优 Q 函数，$\epsilon > 0$ 为正则化常数，则有：

$$\hat{\eta}(\pi) = \mathbb{E}_{s\sim\rho^\pi,a\sim\pi}[\tilde{Q}(s,a)] \le \eta(\pi) \tag{3.18}$$

该定理表明：只要惩罚权重足够大以覆盖 Q 值估计误差，保守 Q 值即可提供真实性能的下界。自适应惩罚的优势在于：对于分布内样本，$d(s,a)$ 较小，Q 值估计误差 $|Q^* - Q_\theta|$ 通常也较小（因为有充足的训练数据），因此所需的惩罚权重较小；对于分布外样本，$d(s,a)$ 较大，惩罚权重相应增大，恰好匹配更大的估计误差。

相比之下，固定惩罚需要取 $\lambda = \max_{s,a} |Q^* - Q_\theta|/(d_{min} + \epsilon)$ 以确保对所有样本成立，这在分布内区域造成过度惩罚，导致性能下界过于保守。

推论 3.2 (相比固定惩罚的改进)**.** *设 $\hat{\eta}_{adapt}$ 和 $\hat{\eta}_{fixed}$ 分别为自适应惩罚和固定惩罚的估计性能。在相同保守性保证下：*

$$\hat{\eta}_{adapt}(\pi) \ge \hat{\eta}_{fixed}(\pi) \tag{3.19}$$

等号成立当且仅当所有样本的分布外程度相同。

该推论表明：自适应惩罚在提供相同保守性保证的前提下，获得更紧的性能下界，从而有潜力学习到更优的策略。

3.5 算法流程

综合以上各节内容，本文提出的基于对比表征学习的保守离线策略优化算法（Contrastive Representation Learning for Conservative offline policy optimization, CRLC）的完整流程如算法1所示。

Algorithm 1 基于对比表征学习的保守离线策略优化算法（CRLC）

Require: 离线数据集 $\mathcal{D}$，对比学习温度 τ_{temp}，基础惩罚系数 λ_0，过渡参数 β，分位数阈值 p
Ensure: 优化后的策略 π_φ

```
// 阶段 1：对比表征学习
初始化编码器 f_s, f_a 和投影头 g
for e = 1 to E_pretrain do
    从 D 采样批次轨迹片段
    构造正样本对（相邻时间步）和负样本对（跨轨迹）
    计算对比损失 L_CL（公式3.6）并更新编码器参数
end for
// 阶段 2：表征空间分布建模
计算表征中心 μ_D（公式3.7）
计算协方差矩阵 Σ_D（公式3.8）
计算距离阈值 d_threshold（公式3.11，取 p 分位数）
冻结编码器参数
// 阶段 3：自适应保守策略优化
初始化策略网络 π_φ、Q 网络 Q_θ1, Q_θ2 及目标网络
for k = 1 to K do
    从 D 采样批次 (s, a, r, s')
    计算表征距离 d(s, a)（公式3.9或3.10）
    计算自适应惩罚权重 λ(s, a)（公式3.12）
    计算保守 Q 值 Q̃(s, a)（公式3.13）
    更新 Q 网络（公式3.14）
    更新策略网络（公式3.16）
    软更新目标网络
end for
return 策略 π_φ
```

算法分为三个阶段：对比表征学习阶段约占总训练时间的 20%，表征空间分布建模为一次性计算，自适应保守策略优化阶段占主要训练时间。

算法的时间复杂度主要由以下部分组成：（1）对比学习预训练，复杂度为 $O(E_{pretrain} \cdot B \cdot L \cdot d_z)$，其中 B 为批次大小，L 为轨迹长度；（2）表征距离计算，复杂度为 $O(d_z)$ 或 $O(d_z^2)$

（马氏距离需矩阵乘法）；（3）策略和 Q 值网络更新，与标准 SAC 相同。由于编码器结构轻量，计算开销显著低于基于集成模型的方法。

3.6 实验验证

本节通过实验验证本文算法的有效性。实验设计旨在回答以下问题：（1）本文算法与现有离线强化学习方法相比表现如何？（2）对比表征学习是否有效构建了区分分布内外样本的表征空间？（3）表征距离能否准确反映样本的分布外程度？（4）自适应惩罚机制相比固定惩罚的优势如何？

3.6.1 实验设置

本节介绍实验所采用的数据集、实现细节和基线方法。

在数据集选择方面，本文选取两类实验环境：

（1）D4RL Antmaze 导航任务[40]。该任务要求智能体在迷宫环境中从起点导航至目标点，采用稀疏奖励设计（仅在到达目标时获得奖励）。选取三种迷宫规模（umaze、medium、large）和两种数据集类型（play、diverse），共计 6 个问题设置。相比 MuJoCo 连续控制任务，Antmaze 的状态空间具有更明确的空间结构，便于分析表征学习的效果；稀疏奖励设计使得分布外检测更具挑战性，能够更好地验证本文方法的有效性。

（2）2D Point 导航合成实验。为直观验证对比表征学习的核心假设，设计简化的 2D 导航环境：智能体在二维平面上从随机起点导航至目标区域，状态为二维坐标，动作为二维速度向量。该环境的优势在于状态空间可直接可视化，便于分析表征空间与原始状态空间的对应关系。

在基线方法方面，本文与以下算法进行对比：无模型离线强化学习算法 CQL[21]、IQL[19] 和 TD3+BC[20]；基于模型的离线强化学习算法 MOPO[23]。

3.6.2 实验结果

3.6.3 表征空间分析

本节设计一系列分析实验，验证对比表征学习构建的表征空间能够有效区分分布内外样本。

3.6.3.1 表征距离与 Q 值估计误差的相关性分析

为验证表征距离能够反映样本的分布外程度，分析表征距离 $d(s,a)$ 与 Q 值估计误差 $|Q_\theta(s,a)-Q^{MC}(s,a)|$ 的相关性。其中 $Q^{MC}(s,a)$ 为蒙特卡洛回报估计，作为真实 Q 值的近似。若相关性显著为正，则表明表征距离大的样本确实对应更大的估计误差，验证了自适应惩罚的合理性。

3.6.3.2 分布外检测的 ROC 曲线分析

将表征距离作为分布外检测的判别指标，绘制 ROC 曲线以量化检测精度。具体而言，将训练数据标记为分布内样本，将策略生成的分布外动作标记为分布外样本，计算不同阈值下的真阳性率和假阳性率。该分析可定量评估表征距离作为 OOD 指标的有效性。

3.6.3.3 2D 导航环境的表征可视化

在 2D Point 导航合成环境中，直接可视化表征空间与原始状态空间的对应关系。由于原始状态为二维坐标，可将表征向量也投影至二维平面，观察对比学习是否保持了状态空间的拓扑结构，以及表征距离是否与距离数据集分布中心的空间距离一致。

3.6.4 消融实验

为验证各算法组件的贡献，本节设计消融实验：

（1）对比学习目标消融：比较轨迹感知对比学习、随机对比学习、无对比预训练三种设置。

（2）距离度量消融：比较欧氏距离、马氏距离、余弦距离三种距离度量的效果。

（3）自适应惩罚消融：比较自适应惩罚权重与固定惩罚权重的性能差异。

（4）计算效率对比：比较本文单编码器方法与基于集成模型方法（如 MOPO）的训练时间和推理时间。

3.7 本章小结

本章详细介绍了基于对比表征学习的保守离线策略优化算法。首先分析了现有离线强化学习方法在分布外检测与保守性调节方面的局限性，阐明了利用对比学习构建表征空间、基于表征距离实现自适应惩罚的核心思想。

在技术实现层面，本章设计了状态-动作联合编码器网络结构，提出了轨迹感知的对比学习目标，利用时序结构定义正负样本关系；建立了基于高斯分布的表征空间建模方法，通过

分位数阈值划分分布内外区域；设计了基于 Sigmoid 函数的自适应惩罚权重，实现惩罚强度随分布外程度的平滑变化。

在理论分析层面，本章证明了自适应惩罚相比固定惩罚可获得更紧的策略性能下界，为算法的优越性提供了理论支撑。

本章提出的方法为纯离线设定下的保守策略优化提供了新思路。然而，该方法的局限在于表征空间的覆盖范围受限于离线数据，无法主动扩展到未知区域。下一章将针对这一局限，引入在线微调阶段，将“被动惩罚分布外”转变为“主动探索分布外”，通过定向探索策略突破离线数据的边界。

第四章　基于定向探索模型的离线到在线强化学习算法

本章详细介绍本文提出的基于定向探索模型的离线到在线强化学习算法。首先分析现有方法的局限性并阐明算法设计动机；随后系统阐述算法的整体框架，包括离线预训练阶段和在线定向探索阶段；接着深入讨论不确定性估计方法与动态权重自适应机制；然后给出算法的理论分析，证明定向探索策略相比均匀采样具有更优的收敛速率；最后通过在 D4RL 基准测试集上的实验验证算法的有效性，并与现有方法进行系统对比。

4.1　问题分析与算法动机

如第二章所述，离线到在线强化学习面临的核心挑战在于如何平衡离线阶段的保守性与在线阶段的探索性。现有方法通常在离线阶段采用保守算法抑制分布外过估计，在在线阶段逐步放松约束以适应新数据。然而，这类方法存在以下根本性局限：

第一，保守性约束在在线阶段形成探索瓶颈。离线阶段学习的保守策略倾向于在低不确定性区域内采样，即使放松约束后，策略仍难以快速适应分布外区域。这导致在线采集的样本集中在离线数据已覆盖的区域，对转移模型的改进贡献有限。

第二，不确定性信息未得到充分利用。现有基于模型的方法主要将不确定性用于惩罚高不确定性区域的奖励，以避免策略访问模型预测不可靠的状态-动作对。这种被动利用方式忽视了不确定性信息的另一层含义：高不确定性区域恰恰对应模型泛化能力不足的区域，是在线探索应优先补充的目标。

第三，在线交互成本高昂。多数离线到在线方法为无模型方法，需要大量在线交互（通常需要 200k 步）才能实现有效微调。在实际应用中，与真实环境的每次交互都可能产生成本或风险，因此如何以最少的在线交互实现高效微调具有重要意义。

基于上述分析，本文提出将不确定性信息从”惩罚信号”转变为”探索引导信号”的核心思想。当采集在线样本时，策略应被引导至高不确定性（转移模型覆盖之外）且高动作价值（接近目标）的区域。高不确定性区域的样本可有效补充转移模型的训练数据，提升模型在全状态-动作空间的泛化能力；高动作价值区域的样本则确保采集的数据对策略优化有直接贡献，避免探索无关区域造成的资源浪费。这种定向探索策略将在线交互的信息增益最大化，以最少的交互次数实现高效微调。

4.2　算法框架

本文提出的基于定向探索模型的离线到在线强化学习算法采用两阶段框架：离线预训练阶段在静态数据集上学习转移模型和初始策略；在线微调阶段通过定向探索采集高价值样本，迭代更新模型和策略。算法的整体流程如图4.1所示。

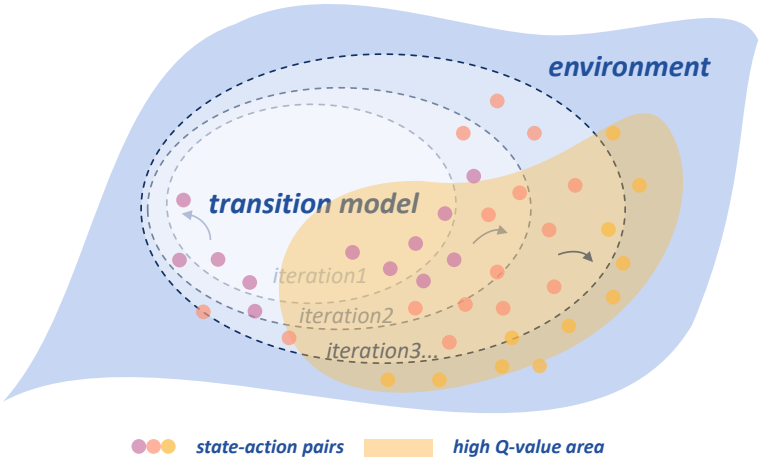

图 4.1　基于定向探索模型的离线到在线强化学习算法框架。离线阶段利用不确定性惩罚保守更新策略；在线阶段利用不确定性引导定向探索，采集的样本用于更新转移模型和策略。

4.2.1　离线预训练阶段

离线预训练阶段的目标是从静态数据集 $\mathcal{D}_{off} = \{(s_i, a_i, s'_i, r_i)\}_{i=1}^{N}$ 中学习环境动力学模型和初始策略。该阶段包含两个核心组件：集成转移模型的训练和基于不确定性惩罚的策略优化。

集成转移模型由 N 个独立训练的神经网络组成，每个网络 $\hat{T}_\phi^i$ 以状态-动作对 (s, a) 为输入，输出下一状态和奖励的联合高斯分布：

$$\hat{T}_\phi^i(s', r|s, a) = \mathcal{N}(\mu_\phi^i(s, a), \Sigma_\phi^i(s, a)), \quad i = 1, \ldots, N \tag{4.1}$$

其中 $\mu_\phi^i(s, a) \in \mathbb{R}^{d_s+1}$ 为预测均值向量，$\Sigma_\phi^i(s, a) \in \mathbb{R}^{(d_s+1)\times(d_s+1)}$ 为预测协方差矩阵，d_s 为状态空间维度。各模型采用相同的网络结构但不同的随机初始化，通过最大化离线数据的对数似然独立训练：

$$\mathcal{L}(\phi^i) = -\mathbb{E}_{(s,a,s',r)\sim\mathcal{D}_{off}}[\log \hat{T}_\phi^i(s', r|s, a)] \tag{4.2}$$

集成模型的优势在于：一方面，多模型的平均预测可降低单一模型的偏差；另一方面，模型间预测的分歧度可用于量化认知不确定性，为后续的探索引导提供依据。

在策略优化方面，离线阶段采用基于不确定性惩罚的保守更新策略，遵循 MOPO[23] 的框

架。具体而言，定义离线阶段的不确定性估计为集成模型预测方差的最大值：

$$u_{off}(s,a) = \max_{i=1,\dots,N} \|\Sigma_\phi^i(s,a)\|_F \tag{4.3}$$

其中 $\|\cdot\|_F$ 表示 Frobenius 范数。该度量捕捉了集成模型中最不确定的预测，反映状态-动作对 (s,a) 处环境动力学的偶然不确定性。基于此，定义不确定性惩罚奖励：

$$\tilde{r}(s,a) = \hat{r}(s,a) - \lambda_{off} \cdot u_{off}(s,a) \tag{4.4}$$

其中 $\hat{r}(s,a)$ 为转移模型预测的奖励均值，λ_{off} 为惩罚系数。通过惩罚高不确定性区域的奖励，策略被约束在模型预测可靠的区域内优化，避免外推误差导致的性能退化。

策略优化采用 Soft Actor-Critic（SAC）[41] 算法。SAC 维护策略网络 π_φ 和两个 Q 值网络 $Q_{\theta_1}, Q_{\theta_2}$，通过最大化带熵正则的期望回报优化策略：

$$J(\varphi) = \mathbb{E}_{s\sim\mathcal{D},a\sim\pi_\varphi}[Q_\theta(s,a) - \alpha \log \pi_\varphi(a|s)] \tag{4.5}$$

其中 α 为温度参数，控制探索与利用的平衡。Q 值网络通过最小化时序差分误差更新：

$$\mathcal{L}(\theta) = \mathbb{E}_{(s,a,\tilde{r},s')\sim\mathcal{D}}\left[\left(Q_\theta(s,a) - \tilde{r} - \gamma\mathbb{E}_{a'\sim\pi_\varphi}[\min_{j=1,2} Q_{\bar{\theta}_j}(s',a') - \alpha\log\pi_\varphi(a'|s')]\right)^2\right] \tag{4.6}$$

其中 $\bar{\theta}$ 为目标网络参数。训练数据从离线数据集 $\mathcal{D}_{off}$ 和模型生成数据集 $\mathcal{D}_{model}$ 中按比例采样。模型生成数据通过从离线数据集中采样初始状态，利用当前策略与转移模型交互生成短期轨迹（rollout）获得。

离线预训练阶段完成后，获得初始策略 π_{off}、集成转移模型 $\{\hat{T}_\phi^i\}_{i=1}^N$ 以及 Q 值网络 Q_θ，为在线微调阶段提供基础。

4.2.2 在线定向探索阶段

在线微调阶段的核心目标是通过与真实环境的有限交互，采集高信息量样本以提升策略性能。与传统方法被动采样不同，本文提出的定向探索策略显式引导策略探索高不确定性且高价值的区域。

定向探索的核心思想是在策略优化目标中同时考虑不确定性和动作价值。具体而言，定义在线阶段的探索策略 π_φ 通过以下目标更新：

$$\nabla_\varphi J_\pi(\varphi) = \mathbb{E}_{(s,a)\sim\mathcal{D}_{on}}\left[\nabla_\varphi \log\pi_\varphi(a|s)\cdot(c\cdot u_{on}(s,a) + Q(s,a))\right] \tag{4.7}$$

其中 $u_{on}(s,a)$ 为在线阶段的不确定性估计（详见第4.4节），$Q(s,a)$ 为动作价值函数，c 为平衡不确定性与价值的权重系数，$\mathcal{D}_{on}$ 为在线交互采集的数据集。

该目标函数的设计体现了定向探索的双重考量：

第一，不确定性项 $u_{on}(s,a)$ 引导策略探索转移模型覆盖不足的区域。在这些高不确定性区域采集的样本对转移模型的改进贡献最大，可有效扩展模型的有效覆盖范围。从主动学习（Active Learning）的角度，这相当于选择模型最不确定的样本进行标注，是一种高效的数据收集策略。

第二，价值项 $Q(s,a)$ 确保探索集中在高回报区域。单纯追求高不确定性可能导致策略探索与任务目标无关的状态-动作空间，造成在线交互资源的浪费。通过引入价值项，探索被引导至对策略优化有直接贡献的区域，实现探索效率与优化效果的平衡。

在线微调阶段的完整流程如下：

（1）与真实环境交互，使用当前探索策略 π_φ 采集轨迹数据，存入在线数据集 $\mathcal{D}_{on}$。

（2）将在线数据与离线数据合并，更新集成转移模型 $\{\hat{T}_\phi^i\}_{i=1}^N$。模型更新采用增量学习方式，在原有参数基础上继续训练，避免遗忘离线阶段学习的动力学知识。

（3）利用更新后的转移模型生成虚拟轨迹，结合真实数据更新 Q 值网络和策略网络。策略更新同时考虑标准 SAC 目标和定向探索目标。

（4）根据在线训练进度动态调整不确定性权重 c（详见第4.3.2节），平衡探索与利用。

（5）重复上述步骤直至达到预设的在线交互预算或策略性能收敛。

通过上述迭代过程，转移模型逐步覆盖更广泛的状态-动作空间，策略在真实环境动力学下持续优化，最终实现高效的离线到在线迁移。

4.3 不确定性估计与动态权重自适应

不确定性估计是定向探索策略的核心组件。本节首先介绍离线和在线阶段采用的差异化不确定性估计方法，随后阐述动态权重自适应机制。

4.3.1 双重不确定性估计

如第二章所述，强化学习中的不确定性可分为偶然不确定性和认知不确定性两类。偶然不确定性源于环境固有的随机性，无法通过收集更多数据消除；认知不确定性源于模型对环境知识的缺乏，可通过在线探索逐步降低。在离线和在线两个阶段，两类不确定性的作用有所不同，因此本文采用差异化的不确定性估计方法。

在离线阶段，由于无法与真实环境交互，认知不确定性无法降低，因此主要关注偶然不

确定性。偶然不确定性通过集成模型的预测方差估计：

$$u_{off}(s,a) = \max_{i=1,\dots,N} \|\Sigma_\phi^i(s,a)\|_F \tag{4.8}$$

该度量反映环境动力学在状态-动作对 (s,a) 处的内在随机性。取集成模型中的最大方差是一种保守估计，确保在任一模型预测不确定时都施加惩罚。

在在线阶段，目标是主动探索高认知不确定性区域以补充转移模型。因此，除偶然不确定性外，还需捕捉认知不确定性。认知不确定性通过集成模型均值预测的分歧度估计：

$$\text{DisVar}(s,a) = \frac{1}{d}\sum_{j=1}^{d} \text{Var}_{i=1,\dots,N}[\mu_{\phi,j}^i(s,a)] \tag{4.9}$$

其中 d 为预测向量维度，$\mu_{\phi,j}^i(s,a)$ 为第 i 个模型预测均值的第 j 个分量，$\text{Var}_{i=1,\dots,N}[\cdot]$ 表示在集成成员间计算方差。该度量的核心思想是：在数据充分覆盖的区域，各模型因接收到足够的监督信号而收敛至相近的预测，分歧度较低；在数据稀疏的区域，模型因初始化差异而产生显著不同的预测，分歧度较高。

在线阶段的不确定性估计综合两类不确定性：

$$u_{on}(s,a) = \max_{i=1,\dots,N} \|\Sigma_\phi^i(s,a)\|_F + \sqrt{\text{DisVar}(s,a)} \tag{4.10}$$

第一项为偶然不确定性，第二项为认知不确定性的标准差形式。两项相加确保探索策略同时考虑环境的内在随机性和模型的知识缺乏，引导策略探索模型预测最不可靠的区域。

4.3.2 动态权重自适应机制

在定向探索目标（公式4.7）中，权重系数 c 控制不确定性与价值的相对重要性。由于不同任务的状态空间和奖励尺度存在显著差异，$Q(s,a)$ 和 $u_{on}(s,a)$ 的数值量级可能相差悬殊。为便于跨任务调节权重，首先对两项进行归一化处理。

具体而言，在离线阶段计算 $\mathbb{E}_{(s,a)\sim\mathcal{D}_{off}}[Q(s,a)]$ 和 $\mathbb{E}_{(s,a)\sim\mathcal{D}_{off}}[u(s,a)]$ 的均值和标准差。在线阶段，对计算得到的 $Q(s,a)$ 和 $u_{on}(s,a)$ 进行标准化：

$$\bar{Q}(s,a) = \frac{Q(s,a)-\mu_Q}{\sigma_Q}, \quad \bar{u}_{on}(s,a) = \frac{u_{on}(s,a)-\mu_u}{\sigma_u} \tag{4.11}$$

其中 μ_Q, σ_Q 和 μ_u, σ_u 分别为离线阶段统计得到的均值和标准差。归一化后，两项处于可比较的数值范围，权重 c 的调节更加直观。

此外，在在线微调过程中，不确定性与价值的相对重要性应随训练进度动态调整。在训练初期，模型覆盖范围有限，应优先探索高不确定性区域以扩展模型的有效范围；在训练后期，模型已较为完善，应转向利用已学习的知识优化策略，即更多关注高价值区域。

为实现上述动态平衡，本文采用 Sigmoid 函数调制权重 c 随策略更新步数 k 的衰减：

$$c = c_0 \cdot \frac{1}{1 + e^{(k-k_0)\cdot\nu}} \tag{4.12}$$

其中 c_0 为初始权重，k_0 为衰减中心点，ν 为衰减速率。该函数具有以下特性：当 $k < k_0$ 时，c 接近 c_0，策略重视不确定性引导的探索；当 $k > k_0$ 时，c 逐渐衰减至接近 0，策略转向价值引导的利用；衰减过程平滑连续，避免策略行为的突变。

通过动态权重自适应机制，算法在训练初期充分探索以补充转移模型，在训练后期充分利用以优化策略性能，实现探索与利用的自适应平衡。

4.4 理论分析

本节从理论角度分析定向探索策略相比均匀采样的优势。核心结论是：在转移函数满足分段常数假设的条件下，基于不确定性引导的定向探索可实现更优的模型收敛速率。

在实际应用中，许多物理系统的动力学具有分段常数特性。例如，机器人控制任务中，不同操作模式（如空载与负载）对应不同的动力学参数；自动驾驶场景中，不同路面条件（如干燥与湿滑）导致车辆响应特性的显著差异。这些场景的转移函数可近似为在不同状态-动作区域内取不同常数值的分段常数函数。

定义 4.1 (分段常数函数)**.** 设 $\mathcal{X} \subset \mathbb{R}^d$ 为状态-动作空间的子集。函数 $T : \mathcal{X} \to \mathbb{R}$ 称为分段常数函数，若存在 $\mathcal{X}$ 的有限划分 $\{R_1, \ldots, R_M\}$，使得 T 在每个区域 R_m 内取常数值 c_m。记 $\mathrm{PC}(\beta, M)$ 为满足 $\sum_{m=1}^{M} |\partial R_m|^\beta < \infty$ 的分段常数函数集合，其中 $|\partial R_m|$ 表示区域 R_m 边界的测度，β 为边界平滑性参数。

基于上述定义，可建立定向探索策略的收敛速率下界。

定理 4.1 (定向探索的收敛速率)**.** *设转移函数 $T \in PC(\beta, M)$ 为分段常数函数，$\hat{T}$ 为基于在线数据集 $\mathcal{D}_{on}$ 学习得到的转移模型估计。若采样策略基于不确定性引导，即优先采样模型预测方差最大的状态-动作对，则模型估计误差的下界为：*

$$\inf_{\hat{T}} \sup_{T \in PC(\beta, M)} \mathbb{E}[\|\hat{T} - T\|^2] \geq c \cdot |\mathcal{D}_{on}|^{-\frac{1}{d-1}} \tag{4.13}$$

其中 $c > 0$ 为与区域复杂度相关的常数，d 为状态-动作空间的内在维度，$|\mathcal{D}_{on}|$ 为在线数据集的样本数量。

证明. 该定理的证明基于主动学习理论中的经典结果[42]。核心思想是：对于分段常数函数，估计误差主要来源于函数不连续点（区域边界）附近的不确定性。基于不确定性引导的采样策略优先在这些边界区域采集样本，从而更高效地定位不连续点，降低估计误差。详细证明参见文献[42] 中定理 2 的推导。 □

作为对比，均匀采样策略的收敛速率下界为[43]：

$$\inf_{\hat{T}} \sup_{T \in \mathrm{PC}(\beta, M)} \mathbb{E}[\|\hat{T} - T\|^2] \geq c' \cdot |\mathcal{D}_{on}|^{-\frac{1}{d}} \tag{4.14}$$

比较公式4.13和公式4.14，定向探索策略的收敛速率指数为 $-\frac{1}{d-1}$，优于均匀采样的 $-\frac{1}{d}$。这意味着在相同样本数量下，定向探索可实现更低的模型估计误差；或者，达到相同精度所需的样本数量更少。该理论结果为本文算法的样本效率优势提供了理论支撑。

需要指出的是，上述理论分析基于分段常数函数的假设，而实际环境的转移函数可能更为复杂。然而，分段常数函数可视为对复杂函数的局部近似，该理论结果仍具有指导意义：基于不确定性引导的定向探索在函数变化剧烈（对应高不确定性）的区域采集更多样本，有助于更精确地刻画转移函数的复杂结构。

4.5 算法流程

综合以上各节内容，本文提出的基于定向探索模型的离线到在线强化学习算法的完整流程如算法2所示。

算法的时间复杂度主要由以下部分组成：（1）集成模型训练，复杂度为 $O(N \cdot |\mathcal{D}| \cdot d_{model})$，其中 d_{model} 为模型参数量；（2）不确定性估计，复杂度为 $O(N \cdot d)$，其中 d 为预测向量维度；（3）策略和 Q 值网络更新，与标准 SAC 相同。由于集成模型可并行训练，实际计算开销与单模型方法相当。

算法的空间复杂度主要由集成模型参数和经验回放池占用。集成模型的参数量为 $O(N \cdot d_{model})$，经验回放池的存储需求与数据集大小成正比。在实际实现中，N 通常取 5-7，不会显著增加存储开销。

4.6 实验验证

本节通过在 D4RL 基准测试集上的实验验证本文算法的有效性。实验设计旨在回答以下问题：（1）本文算法与现有离线到在线强化学习方法及基于模型的离线强化学习方法相比表现如何？（2）基于不确定性引导的定向探索是否确实聚焦于高不确定性、高价值区域？（3）动态权重自适应机制对最终性能的贡献如何？

Algorithm 2 基于定向探索模型的离线到在线强化学习算法

Require: 离线数据集 $\mathcal{D}_{off}$，集成模型数量 N，离线训练轮数 E_{off}，在线交互轮数 E_{on}，初始探索权重 c_0，衰减参数 k_0, ν，惩罚系数 λ_{off}

Ensure: 优化后的策略 π_φ

// 离线预训练阶段
初始化集成转移模型 $\{\hat{T}_\phi^i\}_{i=1}^N$、策略网络 π_φ、Q 值网络 $Q_{\theta_1}, Q_{\theta_2}$
for $e = 1$ to E_{off} **do**
    在 $\mathcal{D}_{off}$ 上训练集成转移模型（公式4.2）
    利用转移模型生成虚拟轨迹，存入 $\mathcal{D}_{model}$
    计算不确定性惩罚奖励 $\tilde{r}$（公式4.4）
    从 $\mathcal{D}_{off} \cup \mathcal{D}_{model}$ 采样，更新 Q 值网络和策略网络
end for
统计 $\mathcal{D}_{off}$ 上 $Q(s,a)$ 和 $u(s,a)$ 的均值和标准差
// 在线微调阶段
初始化在线数据集 $\mathcal{D}_{on} \leftarrow \emptyset$
for $e = 1$ to E_{on} **do**
    使用策略 π_φ 与真实环境交互，采集轨迹数据加入 $\mathcal{D}_{on}$
    合并 $\mathcal{D}_{off}$ 和 $\mathcal{D}_{on}$，更新集成转移模型
    计算在线不确定性 $u_{on}(s,a)$（公式4.10）
    更新动态权重 c（公式4.12）
    利用定向探索目标更新策略（公式4.7）
    更新 Q 值网络
end for
return 策略 π_φ

4.6.1 实验设置

本节介绍实验所采用的数据集、实现细节和基线方法。

在数据集选择方面，本文在 D4RL 基准测试集[40] 上评估算法性能。D4RL 是基于 MuJoCo 物理仿真器[44] 构建的离线强化学习标准评测平台，包含多种环境和数据集类型。本文选取三种连续控制环境（halfcheetah、hopper、walker2d）和三种数据集类型（medium、medium-replay、medium-expert），共计 9 个问题设置。所有数据集均采用 v2 版本，具体组成如下：（1）medium 数据集包含由提前终止的 SAC 策略生成的转移样本，代表中等质量的离线数据；（2）medium-replay 数据集由训练 medium 策略过程中的经验回放池组成，包含从随机策略到中等策略的完整训练轨迹；（3）medium-expert 数据集混合了次优策略和专家策略的数据，代表高质量但分布不均匀的离线数据。

在实验实现方面，本文遵循 SAC[41] 和 MOPO[23] 的基本超参数设置。需要调整的超参数主要包括模型生成轨迹的长度 h 和惩罚系数 λ_{off}。所有任务均在 3 个随机种子上运行。在线交互阶段，每轮交互采集 50k 步样本，权重调整速率 ν 设为 0.001，衰减中心点 k_0 设为 5000。为保证公平性和一致性，策略训练总步数设为 1M 步，每 1k 步评估一次策略性能。

在基线方法方面，本文与以下算法进行对比：离线到在线强化学习算法 AWAC[32]；基于模

型的离线强化学习算法 MOPO[23]、COMBO[28] 和 MOREL[26]；经典离线强化学习算法 CQL[21] 和 TD3+BC[20]。由于本文算法建立在 MOPO 基础上并增加在线微调过程，与 MOPO 的对比可视为消融研究。所有基线方法的结果均引用自原始论文。

4.6.2 实验结果

表4.1展示了本文算法与基线方法在 D4RL 基准测试集上的性能对比。实验结果报告为最后 10 次评估的平均归一化得分，± 表示 3 个随机种子的标准差。得分采用 D4RL 标准归一化程序[40]，归一化至 0 到 100 的范围，其中 0 分对应随机策略，100 分对应专家策略。

表 4.1 D4RL 基准测试集上的性能对比

数据集类型	环境	本文算法	MOPO	COMBO	AWAC	MOREL	CQL	TD3+BC
medium	halfcheetah	**70.5 ± 4.2**	42.3	54.2	41.1	42.1	44.4	42.8
	hopper	65.5 ± 10.9	28.0	97.2	91.0	95.4	86.6	**99.5**
	walker2d	**86.6 ± 0.5**	17.8	81.9	79.1	77.8	74.5	79.7
medium-replay	halfcheetah	**73.1 ± 0.4**	53.1	55.1	-	40.2	46.2	43.3
	hopper	**96.1 ± 5.9**	67.5	89.5	-	93.6	48.6	31.4
	walker2d	**82.6 ± 0.3**	39.0	56.0	-	49.8	32.6	25.2
medium-expert	halfcheetah	75.4 ± 13.3	63.3	90.0	41.0	53.3	62.4	**97.9**
	hopper	102.2 ± 0.8	23.7	111.1	111.9	108.7	111.0	**112.2**
	walker2d	**111.4 ± 0.4**	44.6	103.3	78.3	95.6	98.7	101.1

从表4.1可以看出，本文算法在多数任务上取得了优异的性能表现。在 medium-replay 数据集的全部三个环境中，本文算法均取得最高得分，显著优于所有基线方法。这一结果表明，当离线数据质量参差不齐时，本文的定向探索策略能够有效识别并补充高价值区域的样本，显著提升策略性能。

值得注意的是，本文算法在所有 9 个问题设置上均优于 MOPO 算法，验证了在线微调框架的有效性。考虑到本文仅使用 50k 步的在线交互量，远低于传统离线到在线强化学习算法所需的 200k 步以上，这一结果尤为突出。

然而，本文算法在 medium-expert 数据集上的表现相对较弱。分析其原因在于：medium-expert 数据集的离线数据高度集中在高奖励区域，导致期望奖励高但不确定性低。这种数据分布限制了在线交互阶段采集的数据多样性和质量，进而约束了算法的提升空间。相比之下，基于行为克隆的强化学习方法（如 TD3+BC）在高质量数据集上表现优异，这为后续改进提供了思路：引入行为克隆损失项可能有助于提升算法在此类环境中的性能。

4.6.3　模型覆盖范围的可视化验证

为验证基于不确定性引导的定向探索是否确实聚焦于高期望回报和高不确定性区域，本节进行可视化实验分析。具体而言，选取三种不同类型的数据集进行可视化：hopper-medium、hopper-medium-replay 和 hopper-medium-expert。

实验过程如下：首先，从离线数据集中采样 2000 个转移样本 (s, a, s', r)；然后，将离线状态 s 输入转移模型，获得模型预测的转移样本 (s, a_T, s'_T, r_T)；接着，使用 t-SNE 算法[45] 将 $\{s'\}$ 和 $\{s'_T\}$ 投影至二维平面；最后，绘制 $\{s'_T\}$ 的散点图，使用离线策略的 Q 值网络估计状态-动作对 (s, a_T) 的期望回报，并将 Q 值映射为散点颜色。同时，显示离线状态 $\{s'\}$ 的核密度估计作为参照。可视化结果如图4.2所示。

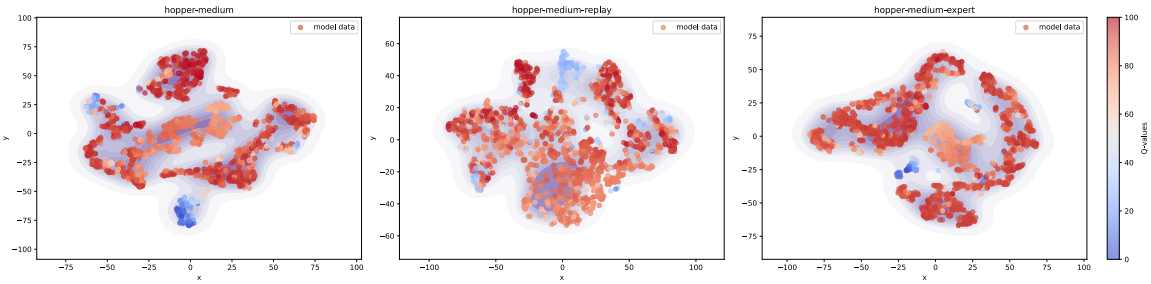

图 4.2　模型预测状态与离线数据的对比。将模型预测状态和离线状态数据密度在三种不同离线数据集上进行可视化。散点表示模型的数据分布，预测 Q 值经归一化后作为散点的颜色。

从图4.2可以观察到，模型预测的状态主要分布在低密度的边缘区域，且散点大多呈现红色，表明这些区域具有高不确定性和高期望回报。这一现象表明，在策略引导下，模型确实更多地关注高不确定性且高动作价值的区域。

对比三个子图可以发现：在 hopper-medium-replay 环境中，散点分布较为分散，表明在线交互实现了充分的探索，补充了更多分布外数据；在 hopper-medium-expert 环境中，散点分布更为集中，这是因为专家数据的高质量和低方差使得在线交互难以通过探索采集到更高动作价值的数据，导致补充的数据质量可能不及离线数据集中的专家数据，模型更新不够充分。这一观察结果进一步印证了本文算法更适用于数据分布均匀的环境，而在高质量数据集上的适用性有限。

4.6.4　动态权重自适应的消融实验

为验证动态权重自适应机制的有效性，本节设计消融实验，将完整算法与移除动态权重自适应的变体（记为 DEM-s）进行对比。DEM-s 中，不确定性权重参数 c 固定为初始值 c_0，不随在线交互步数增加而衰减。其余超参数与主实验保持一致。

表4.2展示了消融实验结果。完整算法在几乎所有任务上均取得更优性能，尤其在 hopper-medium 和 halfcheetah-medium-expert 任务上提升显著：完整算法分别取得 65.5 和 75.4 的得

表 4.2　动态权重自适应的消融实验结果

数据集类型	环境	本文算法	无动态权重
medium	halfcheetah	**70.5**	64.7
	hopper	**65.5**	53.0
	walker2d	**86.6**	86.2
medium-replay	halfcheetah	**73.1**	72.6
	hopper	**96.1**	90.2
	walker2d	**82.6**	82.1
medium-expert	halfcheetah	**75.4**	36.1
	hopper	102.2	102.2
	walker2d	111.4	**112.0**

分，而无动态权重变体仅为 53.0 和 36.1。然而，在 walker2d-medium-expert 任务上，完整算法略低于无动态权重变体，推测这与该任务高度结构化的专家数据有关，早期探索阶段可能对策略产生轻微干扰。

上述结果表明，动态权重自适应机制在平衡探索与利用方面发挥了关键作用。在交互初期，较高的不确定性权重鼓励探索，使策略覆盖更广泛的状态-动作空间；随着交互推进，权重逐渐降低，使算法聚焦于高奖励区域并稳定策略性能。这种自适应机制使算法能够根据训练进度动态调整探索-利用平衡，优于固定权重的静态策略。

4.7　本章小结

本章详细介绍了基于定向探索模型的离线到在线强化学习算法。首先分析了现有方法在保守性与灵活性、不确定性利用、在线交互成本等方面的局限，阐明了将不确定性从惩罚信号转变为探索引导信号的核心思想。随后系统阐述了算法的两阶段框架：离线阶段通过集成模型和不确定性惩罚进行保守策略优化；在线阶段通过定向探索目标引导策略探索高不确定性且高价值的区域，以最少的在线交互实现高效微调。

在技术实现层面，本章介绍了双重不确定性估计方法，区分偶然不确定性和认知不确定性在不同阶段的作用；提出了动态权重自适应机制，通过 Sigmoid 函数实现探索与利用的平滑过渡。在理论分析层面，证明了在分段常数函数假设下，定向探索策略相比均匀采样具有更优的收敛速率，为算法的样本效率优势提供了理论支撑。

在实验验证层面，本章在 D4RL 基准测试集的 9 个问题设置上进行了系统评估。实验结果表明：（1）本文算法在 medium-replay 数据集上显著优于所有基线方法，在所有任务上均优于 MOPO；（2）通过 t-SNE 可视化验证了定向探索确实聚焦于高不确定性、高价值区域；（3）消融实验证明了动态权重自适应机制对最终性能的积极贡献。实验同时揭示了算法在 high-quality 数据集上的局限性，为后续改进指明了方向。

第五章 总结与展望

5.1 本文工作总结

《正文》**********

5.2 进一步研究方向

《正文》**********

参考文献

[1] Levine S, Kumar A, Tucker G, et al. Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems[J]. arXiv preprint arXiv:2005.01643, 2020.

[2] Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search [J]. Nature, 2016, 529(7587): 484–489.

[3] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C]. IEEE International Conference on Robotics and Automation (ICRA). 2019: 6023–6029.

[4] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[J]. arXiv preprint arXiv:2501.12948, 2025.

[5] Gottesman O, Johansson F, Komorowski M, et al. Guidelines for reinforcement learning in healthcare[J]. Nature Medicine, 2019, 25(1): 16–18.

[6] Kiran B R, Sobh I, Talpaert V, et al. Deep Reinforcement Learning for Autonomous Driving: A Survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(6): 4909–4926.

[7] Fujimoto S, Meger D, Precup D. Off-Policy Deep Reinforcement Learning without Exploration[C]. Proceedings of Machine Learning Research: volume 97 Proceedings of the 36th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2019: 2052–2062.

[8] Liu Y, Swaminathan A, Agarwal A, et al. Provably Good Batch Off-Policy Reinforcement Learning Without Great Exploration[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 1264–1274.

[9] Yu Q, Zhang Z, Zhu R, et al. DAPO: An Open-Source LLM Reinforcement Learning System at Scale[J]. arXiv preprint arXiv:2503.14476, 2025.

[10] Brohan A, Brown N, Carbajal J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[J]. arXiv preprint arXiv:2307.15818, 2023.

[11] 王雪松, 王荣荣, 程玉虎. 基于表征学习的离线强化学习方法研究综述[J]. 自动化学报, 2024, 50(6): 1104–1128.

[12] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. [S.l.]: MIT Press, 2018.

[13] Lakshminarayanan B, Pritzel A, Blundell C. Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 30. [S.l.: s.n.], 2017: 6402–6413.

[14] Charpentier B, Senanayake R, Kochenderfer M, et al. Disentangling Epistemic and Aleatoric Uncertainty in Reinforcement Learning[J]. arXiv preprint arXiv:2206.01558, 2022.

[15] Wu Y, Tucker G, Nachum O. Behavior Regularized Offline Reinforcement Learning[J]. arXiv preprint arXiv:1911.11361, 2019.

[16] Xu H, Jiang L, Li J, et al. A Policy-Guided Imitation Approach for Offline Reinforcement Learning[J]. Ad-

vances in Neural Information Processing Systems (NeurIPS), 2022, 35: 4085–4098.

[17] Kumar A, Fu J, Soh M, et al. Stabilizing Off-Policy Q-Learning via Bootstrapping Error Reduction[J]. Advances in Neural Information Processing Systems (NeurIPS), 2019, 32.

[18] Lyu J, Ma X, Li X, et al. Mildly Conservative Q-Learning for Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 1711–1724.

[19] Kostrikov I, Nair A, Levine S. Offline Reinforcement Learning with Implicit Q-Learning[C]. Proceedings of the 10th International Conference on Learning Representations (ICLR). [S.l.: s.n.], 2022.

[20] Fujimoto S, Gu S S. A Minimalist Approach to Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021: 20132–20145.

[21] Kumar A, Zhou A, Tucker G, et al. Conservative Q-Learning for Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 1179–1191.

[22] Janner M, Fu J, Zhang M, et al. When to Trust Your Model: Model-Based Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 32. [S.l.: s.n.], 2019: 12519–12530.

[23] Yu T, Thomas G, Yu L, et al. MOPO: Model-based Offline Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 14129–14142.

[24] Wang J, Li W, Jiang H, et al. Offline Reinforcement Learning with Reverse Model-based Imagination[J]. Advances in Neural Information Processing Systems (NeurIPS), 2021, 34: 29420–29432.

[25] Lu C, Ball P, Teh Y W, et al. Synthetic Experience Replay[J]. Advances in Neural Information Processing Systems (NeurIPS), 2024, 36.

[26] Kidambi R, Rajeswaran A, Netrapalli P, et al. MOReL: Model-Based Offline Reinforcement Learning[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 33. [S.l.: s.n.], 2020: 21810–21823.

[27] Rigter M, Lacerda B, Hawes N. RAMBO-RL: Robust Adversarial Model-Based Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 16082–16097.

[28] Yu T, Kumar A, Rafailov R, et al. COMBO: Conservative Offline Model-Based Policy Optimization[C]. Advances in Neural Information Processing Systems (NeurIPS): volume 34. [S.l.: s.n.], 2021: 28954–28967.

[29] Sun J, Jiang Y, Qiu J, et al. Conformal Prediction for Uncertainty-Aware Planning with Diffusion Dynamics Model[J]. Advances in Neural Information Processing Systems (NeurIPS), 2024, 36.

[30] Zhou G, Swaminathan S, Raju R V, et al. Diffusion Model Predictive Control[J]. arXiv preprint arXiv:2410.05364, 2024.

[31] Lee S, Seo Y, Lee K, et al. Offline-to-Online Reinforcement Learning via Balanced Replay and Pessimistic Q-Ensemble[C]. Proceedings of Machine Learning Research: volume 164 Proceedings of the 5th Conference on Robot Learning (CoRL). [S.l.]: PMLR, 2022: 1702–1712.

[32] Nair A, Gupta A, Dalal M, et al. AWAC: Accelerating Online Reinforcement Learning with Offline Datasets [J]. arXiv preprint arXiv:2006.09359, 2020.

[33] Zhang H, Xu W, Yu H. Policy Expansion for Bridging Offline-to-Online Reinforcement Learning[J]. arXiv

preprint arXiv:2302.00935, 2023.

[34] Nakamoto M, Zhai Y, Singh A, et al. Cal-QL: Calibrated Offline RL Pre-Training for Efficient Online Fine-Tuning[C]. Proceedings of Machine Learning Research: volume 202 Proceedings of the 40th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2023: 25675–25697.

[35] Zhao K, Ma Y, Liu J, et al. Improving Offline-to-Online Reinforcement Learning with Q-Ensembles[C]. ICML Workshop on New Frontiers in Learning, Control, and Dynamical Systems. [S.l.: s.n.], 2023.

[36] Yang J, Chen X, Wang S, et al. Model-based Offline Reinforcement Learning with Pessimism-Modulated Dynamics Belief[J]. arXiv preprint arXiv:2302.12279, 2023.

[37] Chen T, Kornblith S, Norouzi M, et al. A Simple Framework for Contrastive Learning of Visual Representations[C]. Proceedings of Machine Learning Research: volume 119 Proceedings of the 37th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2020: 1597–1607.

[38] van den Oord A, Li Y, Vinyals O. Representation Learning with Contrastive Predictive Coding[C]. arXiv preprint arXiv:1807.03748. [S.l.: s.n.], 2018.

[39] Fujimoto S, van Hoof H, Meger D. Addressing Function Approximation Error in Actor-Critic Methods[C]. Proceedings of Machine Learning Research: volume 80 Proceedings of the 35th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2018: 1587–1596.

[40] Fu J, Kumar A, Nachum O, et al. D4RL: Datasets for Deep Data-Driven Reinforcement Learning[J]. arXiv preprint arXiv:2004.07219, 2020.

[41] Haarnoja T, Zhou A, Abbeel P, et al. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[C]. Proceedings of Machine Learning Research: volume 80 Proceedings of the 35th International Conference on Machine Learning (ICML). [S.l.]: PMLR, 2018: 1861–1870.

[42] Willett R, Nowak R, Castro R. Faster Rates in Regression via Active Learning[J]. Advances in Neural Information Processing Systems (NeurIPS), 2005, 18.

[43] Korostelev A. On Minimax Rates of Convergence in Image Models under Sequential Design[J]. Statistics & Probability Letters, 1999, 43(4): 369–375.

[44] Todorov E, Erez T, Tassa Y. MuJoCo: A physics engine for model-based control[J]. Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2012: 5026–5033.

[45] van der Maaten L, Hinton G. Visualizing Data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9(86): 2579–2605.

附录 A 程序清单

第三章 QAM 系统 CMA 算法程序（QAM programme 文件夹）

mainQAM_MSE_CMAvsCADAMA：QAM 系统，画 MSE 曲线主函数

mainQAM_SER_CMAvsCADAMA：QAM 系统，画 SER 曲线主函数

mainDQAM_SER_PhaseRotate：差分 QAM 系统，相位旋转下，画 SER 曲线主函数

mainDQAM_SER_Doppler：差分 QAM 系统，多普勒频移下，画 SER 曲线主函数

mainDQAM_SER_SNR：差分 QAM 系统，不同 SNR 下，画 SER 曲线主函数

第四章 QPSK 系统 CMA 算法程序（PSK programme 文件夹）

mainDPSK_SER_PhaseRotate：差分 PSK 系统，相位旋转下，画 SER 曲线主函数

mainDPSK_SER_Doppler：差分 PSK 系统，多普勒频移下，画 SER 曲线主函数

mainDPSK_SER_SNR：差分 PSK 系统，不同 SNR 下，画 SER 曲线主函数

FunQPSK：QPSK 编码子函数

FunDeQPSK_b：QPSK 解码子函数 (输出为比特)

第五章 CMA 频域均衡系统程序（FDE programme 文件夹）

main_CMAFDE：CMA 频域均衡主函数

FunCAZACSeGen：产生 CAZAC 序列子函数

Fun8PSK：8PSK 调制子函数

FunDe8PSK_s：8PSK 解调输出符号子函数

FunQPSK1：QPSK 调制幅度为 1 子函数

FunDeQPSK1_s：QPSK 解调输出符号幅度为 1 子函数

FunSDCMA22f：频域均衡 (2 2)SDCMA 算法子函数

附录 B 攻读专业学位硕士期间撰写的论文

[1] ** *, ** *, ** *, et al. **********[J]. IEEE Transactions on Wireless Communications, 2017, 6(8):360-371. （SCI 二区：000000000000001）

[2] ** *, ** *. **********[J]. Journal of China Universities of Posts & Telecommunications, 2016, 23(5):82-87.（EI：000000000000002）

[3] **，**********，电子学报，已录用。

附录 C 攻读专业学位硕士期间申请的专利

[1] 作者一，作者二，作者三. 专利名称，专利申请号，专利申请日期，专利授权日期；

[2] 张三，李四. 一种面向代理的安全传输方法，2007062.5，2016.1,2017.10；

[3] 张三. 一种实用的网络路由方法，200845610.5，2017,1,2018.1。

附录 D 攻读专业学位硕士期间参加的科研项目

[1] 项目类型，项目名称（项目编号）；

[2] 国家自然科学基金，基于安全移动代理新一代网络研究 (000000000001)；

[3] 国家自然科学基金，移动代理机制关键技术研究 (000000000002)。